
多模态大模型系列报告

从 Transformer 到多模态基座：现代大模型的架构基础

拆解 2017-2026 年间构成现代多模态基座模型的八个核心基件——Transformer 骨架、位置编码、注意力效率变体、MoE、视觉骨干、预训练范式、扩展定律与对齐技术

多模态大模型系列报告

2026-09-29

本报告为系列技术综述，内容基于公开论文整理，仅供学习研究使用。

目录

1 引言：本方向在多模态版图中的位置	4
1.1 为什么“第 0 篇”要回到纯文本时代	4
1.2 本方向的核心问题	5
1.3 时间线总览	5
2 基础知识	5
2.1 从 RNN 到注意力：为什么需要 Self-Attention	5
2.2 自注意力 (Self-Attention)：数学形式	6
2.3 多头注意力 (Multi-Head Attention)	7
2.4 前馈网络 (FFN) 与激活函数	7
2.5 残差连接与归一化：Post-Norm 到 Pre-Norm	7
2.6 位置编码：让模型知道“谁在哪”	8
2.7 注意力效率变体：MQA / GQA / MLA 与 FlashAttention	9
2.8 混合专家 (MoE)：用稀疏激活解耦参数与计算	10
2.9 预训练范式：MLM 与 CLM 的分野	11
2.10 Scaling Laws：规模的可预测性	12
2.11 对齐技术栈：RLHF / DPO / GRPO	12
3 经典方法谱系	14
3.1 关键论文一览表	14
3.2 谱系的内在逻辑	15
4 代表作深度剖析	16
4.1 Attention Is All You Need (Transformer, 2017) [1]	16
4.2 An Image is Worth 16×16 Words (ViT, 2020) [29]	16
4.3 Training Compute-Optimal Large Language Models (Chinchilla, 2022) [6]	17
4.4 Training Language Models to Follow Instructions with Human Feedback (InstructGPT, 2022) [7]	18
4.5 Direct Preference Optimization (DPO, 2023) [14]	18
4.6 DeepSeek-V3 Technical Report (2024) [23]	19
5 研究前沿 (2025–2026)	19
6 点题：这些基件如何被多模态模型复用	20

7 技术路线对比与权衡	21
7.1 注意力变体对比	21
7.2 位置编码对比	22
7.3 对齐方法对比	22
7.4 Dense vs MoE	23
8 开放问题与未来方向	23
9 研究机会点评（给入门研究者的建议）	24
10 术语表	25
11 参考文献	26

摘要 本篇是整个多模态大模型报告系列的第 0 篇，也是地基篇。今天的多模态基座模型——无论是 LLaVA 式的视觉-语言模型、支持音频视频的全模态模型，还是视觉-语言-动作（VLA）具身模型——其内部并没有发明什么全新的骨架，而是复用了一整套在纯文本大模型时代被反复锤炼过的架构组件。本篇系统梳理这套” 基件库”：(1) Transformer 骨架，包括自注意力、多头机制、前馈网络、残差连接与归一化的设计动机与数学形式；(2) 位置编码的演进谱系，从正弦位置编码、可学习位置嵌入到 RoPE 与 ALiBi；(3) 注意力效率变体，包括 MQA/GQA/MLA 的 KV cache 压缩思想与 FlashAttention 的 IO 感知计算范式；(4) 混合专家（MoE）如何用稀疏激活解耦参数量与计算量；(5) Vision Transformer（ViT）如何确立” 视觉即 token 序列” 的编码范式；(6) BERT 式掩码语言建模与 GPT 式因果语言建模两大预训练范式的分野；(7) 从 Kaplan 幂律到 Chinchilla 计算最优定律再到多模态扩展的 scaling law 方法论；(8) RLHF、DPO 与 GRPO 构成的对齐技术栈。每个基件我们都回答三个问题：它解决了前人的什么痛点、它的数学本质是什么、它在多模态模型中被如何复用。本篇结尾将把这些基件拼回完整图景，为后续各专题篇（视觉-语言、音频、视频、全模态、生成、具身等）提供统一的概念坐标系。

1 引言：本方向在多模态版图中的位置

1.1 为什么” 第 0 篇” 要回到纯文本时代

一个常见误解是：多模态大模型是一类与语言模型平行发展的新物种。事实恰恰相反——2017 年 Transformer 诞生以来的几乎全部架构进步，首先发生在纯文本语言模型上，随后被原封不动或稍作修改地搬运到多模态领域。LLaVA 用大语言模型当” 大脑”；Qwen-VL、InternVL 等模型直接把 ViT 编码器接到 LLM 的词表接口上；视频模型沿用时序 token + 因果注意力；具身模型把动作离散化成 token 走同一条自回归管线。**理解现代多模态模型的最低成本路径，就是先彻底吃透语言模型的架构基件，再学习” 接入层” 如何把这些基件扩展到新模态。**

本篇对应整个系列报告的学习地图最底层。所谓” 最基础、最扎实”，体现在两个标准上：一是本篇的每个概念都给出完整数学形式而非名词解释——attention、RoPE 旋转、MoE 门控、PPO/DPO 损失，这些公式在后续每一篇都会不加推导地复用；二是本篇的每个方法都追问” 它解决了前人的什么痛”——只有理解了痛点，才能在后续遇到新模态变体时判断它是真创新还是旧酒新瓶：



01 视觉-语言 (connector、投影、指令微调)
02 音频语音 / 03 视频 / 04 全模态
05 生成 (扩散 vs 自回归) / 06 具身 (VLA)
07 Agent 与工具 / 08 效率 / 09 对齐安全
10 评测 / 11 数据与训练 / 12 前沿展望

1.2 本方向的核心问题

本篇贯穿三条核心问题线索：

1. **表达与效率的张力**：自注意力赋予任意两位置 $O(1)$ 的交互路径，代价是 $O(n^2)$ 的计算与存储。这条线索驱动了 MQA/GQA/MLA（压缩推理期 KV cache）、FlashAttention（压缩访存）、滑窗与稀疏注意力（压缩计算图）、乃至 linear attention / 状态空间模型（换掉注意力本身）等一系列工作。
2. **规模与数据的张力**：模型变大几乎总是变好，但算力与数据都是稀缺资源。给定预算，参数与数据如何配比？规模之外何时出现质变？这条线索驱动了 Kaplan 幂律、Chinchilla 计算最优、涌现能力研究与多模态 scaling 扩展。
3. **能力与人意的张力**：next-token prediction 训练出的是“互联网文本续写机”，不是“助手”。如何让强大但野生的模型变得有用、诚实、无害？这条线索驱动了 SFT → RLHF → DPO → RLVR 的整段后训练史。

三条线索共享一个隐含主题：**大模型研究的本质是在多重约束（算力、数据、显存、带宽、人类偏好）下做受约束优化**，每一个经典基件都是对某个具体约束的响应。

这三条线索在 2024–2026 年汇聚于多模态：多模态模型把序列变得更长（图像几千 token、视频几万 token），效率问题更尖锐；多模态数据远少于文本，scaling 的数据约束更紧；多模态输出的安全性与有用性，对齐技术同样直接复用。

1.3 时间线总览

上图给出了 2017–2026 年间的代表性模型时间线。可以看到一个清晰模式：文本侧的架构创新（Transformer、RoPE、GQA、MoE、FlashAttention）通常领先多模态应用 1–3 年，随后被多模态模型批量吸收。本篇讲述的正是时间线左侧这些“被吸收的基件”。

2 基础知识

2.1 从 RNN 到注意力：为什么需要 Self-Attention

在 Transformer 之前，序列建模的主力是 RNN/LSTM。RNN 的根本缺陷有二：其一，计算必须沿时间步串行进行，第 t 步的隐状态依赖第 $t-1$ 步，无法并行——这意味着序列长度直接乘在训练时间上，GPU 的并行算力被结构性浪费；其二，信息必须逐步传递，长距离依赖在反复的非线性压缩中衰减（梯度消失问题的另一种表现），LSTM 的门控机制缓解了但并未根除




图 1 2017-2026 多模态模型时间线

这个问题。CNN 系的方案（如 ConvS2S）可以并行，但感受野随层数线性增长，建模全局依赖需要堆很多层。注意力机制（attention）最初是作为 RNN 编码器-解码器之间的辅助对齐工具出现的——解码每个词时“回头看”源句的哪些词最相关。而 Vaswani 等人在 2017 年提出了一个激进的观点：既然注意力已经足够强，为什么不抛弃循环与卷积，只用注意力？这就是《Attention Is All You Need》[1]。回看历史，这个“激进”判断的赌注在于：它赌硬件的并行红利会补偿注意力 $O(n^2)$ 的复杂度劣势——在当时序列长度只有几十上百的机器翻译场景，这个赌注稳赢。

2.2 自注意力 (Self-Attention)：数学形式

给定输入序列的 token 表示矩阵 $X \in \mathbb{R}^{n \times d}$ (n 为序列长度, d 为模型维度), 通过三组可学习投影矩阵 $W^Q, W^K, W^V \in \mathbb{R}^{d \times d_k}$ 得到查询 (query)、键 (key)、值 (value):

$$Q = XW^Q, \quad K = XW^K, \quad V = XW^V$$

缩放点积注意力 (scaled dot-product attention) 定义为:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

逐行看: 第 i 个 token 的输出是所有 token 的 value 向量的加权和, 权重由它的 query 与每个 key 的点积相似度经 softmax 归一化得到。这里有两个关键设计决策:

- **为什么用点积:** 点积可整块用矩阵乘法实现, 高度并行, 充分利用 GPU 的矩阵乘单元;
- **为什么除以 $\sqrt{d_k}$:** 当 d_k 较大时, 点积的方差随维度线性增长, softmax 会进入梯度极小的饱和区。除以 $\sqrt{d_k}$ 使注意力分数的方差维持在 $O(1)$, 这是原作者基于“query/key 分量独立同分布、均值 0 方差 1”假设推出的缩放因子 [1]。

自注意力一次性建立了任意两个位置之间的直接通路——路径长度为 $O(1)$, 彻底解决了 RNN 的长距离依赖衰减问题; 代价是 $QK^\top$ 矩阵带来 $O(n^2d)$ 的计算与 $O(n^2)$ 的注意力矩阵存储, 这是后面所有效率变体要对付的“原罪”。

一个有助直觉的类比：把每个 token 想成图书馆里的读者，query 是”我想找什么资料”，key 是”我能提供什么资料”的索引卡，value 是资料本身。每个读者拿自己的 query 去匹配所有人的索引卡，按匹配度加权取回资料——一轮操作后，每个位置都聚合了全序列的相关信息。RNN 里信息要”口口相传”，距离 k 的两个位置需要 k 步传递且每步都有损耗；注意力则相当于一次全员大会，代价是会议规模随人数的平方增长。

因果掩码 (causal masking)：用于自回归语言建模时，第 i 个位置不允许”看到”未来，实现上在 softmax 之前把 $QK^\top$ 的上三角 ($j > i$ 的部分) 置为 $-\infty$ 。这一改动把 Transformer 从双向编码器变成了从左到右的生成器，是 GPT 系列的起点（见 2.8 节）。

2.3 多头注意力 (Multi-Head Attention)

单一注意力分布只能在一个表示子空间里计算相似度。多头注意力把 Q, K, V 分别切成 h 份（每份维度 $d_k = d/h$ ），并行计算 h 组注意力再拼接投影：

$$\text{\$MHA}(X) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O, \quad \text{head}_i = \text{Attention}(XW_i^Q, XW_i^K, XW_i^V)\text{\$}$$

直觉上，不同 head 可以学习不同性质的关系（语法依存、指代、位置邻近等）——后续的可解释性研究确实在特定 head 中观察到了可辨识的句法与语义角色。多头的计算量与单头（同总维度）几乎相同，却显著增强了表达能力。原始 Transformer 的 base/big 配置为 $d = 512/1024$ ， $h = 8/16$ [1]；当代大模型如 7B 量级常用 $d = 4096$ ， $h = 32$ 。

一个实用的比例经验：head 维度 d_k 通常固定在 64-128，扩大模型时优先加 head 数而非加大 d_k 。过小的 d_k 让每个 head 的”相似度判断”欠参数化，过大的 d_k 则浪费并行的多样性。这个看似琐碎的工程约定，在 2.7 节的 KV cache 讨论中会突然变得重要——head 数与 d_k 的乘积直接决定缓存体积。

2.4 前馈网络 (FFN) 与激活函数

每个 Transformer 块里，注意力之后是一个逐位置 (position-wise) 两层 MLP：

$$\text{\$FFN}(x) = W_2 \sigma(W_1 x + b_1) + b_2\text{\$}$$

隐层维度通常为 $4d$ （原论文 $d_{ff} = 2048$ 对 $d = 512$ ）[1]。FFN 占模型参数量的约 2/3，被认为是模型的”知识存储器”，而注意力负责”信息搬运”。

激活函数经历了 ReLU $\rightarrow$ GELU $\rightarrow$ SwiGLU 的演进。当代开源模型的标准配置是 **SwiGLU**：

$$\text{\$SwiGLU}(x) = (\text{Swish}(xW_1) \odot xW_3)W_2, \quad \text{Swish}(x) = x \cdot \text{sigmoid}(x)\text{\$}$$

门控结构 (element-wise 乘一个线性分支) 带来更平滑的优化景观；为保持参数量不变，隐层维度通常从 $4d$ 调整到约 $8d/3$ 。SwiGLU 是 LLaMA、Qwen、Mistral、DeepSeek 等现代模型的共同选择 [13, 19, 22]。

2.5 残差连接与归一化：Post-Norm 到 Pre-Norm

深网络训练的两个敌人是梯度消失与表示漂移。Transformer 用残差连接 $x + \text{SubLayer}(x)$ 保证梯度有直通路程，用层归一化 (LayerNorm) 把每层输入拉回稳定分布。二者的组合方式有重要分野：

- **Post-Norm** (原始 Transformer): $x \leftarrow \text{LayerNorm}(x + \text{SubLayer}(x))$ 。归一化施加在残差相加之后,意味着”主干”上的表示每过一层就被重新归一一次;浅层时这有利于表示规整,但层数加深后,反向传播的梯度要穿过每一层的 LayerNorm 雅可比,深层模型在训练初期极易出现梯度爆炸/消失,必须配合精心设计的学习率 warmup 才能启动。
- **Pre-Norm**: $x \leftarrow x + \text{SubLayer}(\text{LayerNorm}(x))$ 。归一化只作用在分支内部,残差主干从第一层到最后一层是纯粹的恒等累加——反向传播时梯度沿主干无损直达任意深度。这就是为什么 GPT-3 时代的 96 层、PaLM 的 118 层能够稳定训练: Pre-Norm 把”深度”从优化难题变成了简单的超参数。代价是理论上表示能力略弱(主干缺乏正则),实践中无人介意。

归一化层本身也在简化: **RMSNorm** 去掉了 LayerNorm 的均值中心化,只做均方根缩放:

$$\text{RMSNorm}(x) = \frac{x}{\sqrt{\frac{1}{d} \sum_{i=1}^d x_i^2 + \epsilon}} \cdot g$$

实验表明中心化贡献有限而计算可省约一半归一化开销。RMSNorm + Pre-Norm + SwiGLU + RoPE 构成 2023 年后开源大模型的”现代配方”四件套 [13, 22]。

2.6 位置编码: 让模型知道”谁在哪”

自注意力本身是**置换等变**(permutation-equivariant)的: 打乱输入顺序, 输出也仅被打乱。但语言里顺序即意义, 必须显式注入位置信息。

(1) **正弦绝对位置编码 (Sinusoidal)** [1]: 为每个位置 pos 构造一个确定性的向量, 维度 $2i$ 与 $2i + 1$ 分别为

$$\text{PE}(pos, 2i) = \sin\left(\frac{pos}{10000^{2i/d}}\right), \quad \text{PE}(pos, 2i + 1) = \cos\left(\frac{pos}{10000^{2i/d}}\right)$$

不同频率的正弦/余弦构成一组”位置基”, 任意偏移 k 后 $\text{PE}(pos + k)$ 是 $\text{PE}(pos)$ 的线性函数, 理论上便于学习相对位置。优点是零参数、可外推到任意长度; 实践中直接加到 token 嵌入上。

(2) **可学习位置嵌入 (Learned PE)**: BERT、GPT-2、ViT 给每个位置一个可训练向量。效果略优于正弦编码, 但训练时见过最长 $n_{\max}$ 个位置, 推理时无法超出——外推性差是其致命伤。

(3) **相对位置编码与 ALiBi** [10]: 与其编码绝对位置, 不如直接在注意力分数里加入与相对距离有关的偏置。ALiBi (**A**ttention with **L**inear **B**iases) 把它推到极致:

$$\text{score}(q_i, k_j) = \frac{q_i \cdot k_j}{\sqrt{d_k}} - m_h \cdot |i - j|$$

每个 head 用一个固定的斜率 m_h (按 $2^{-8h/H}$ 几何数列设置), 距离越远惩罚越大。ALiBi 完全不加位置向量, 却能实现出色的长度外推: 论文报告 1.3B 模型在 1024 长度上训练, 可外推到 2048 长度且困惑度与训练到 2048 的正弦位置模型相当 [10]。缺点是线性偏置表达能力有限, 长距离信息被硬性衰减。

(4) **旋转位置编码 RoPE (Rotary Position Embedding)** [8]: 当代大模型的事实标准。核心思想是: 把 d 维向量两两分组, 对位置 m 的 query/key 向量施加一个与 m 成正比的二维旋转。形式化地, 将嵌入维度两两配对为 (x_{2i}, x_{2i+1}) , 定义旋转矩阵

$$R_{\Theta,m} = \begin{pmatrix} \cos m\theta_i & -\sin m\theta_i \\ \sin m\theta_i & \cos m\theta_i \end{pmatrix}, \quad \theta_i = 10000^{-2i/d}$$

对位置 m 的 query 与位置 n 的 key 分别旋转后做点积，利用旋转矩阵的性质 $R_{\Theta,m}^\top R_{\Theta,n} = R_{\Theta,n-m}$ ，注意力分数只依赖**相对位置** $n - m$ ：

$$\langle R_{\Theta,m} q, R_{\Theta,n} k \rangle = \langle q, R_{\Theta,n-m} k \rangle$$

这实现了”以绝对方式实现、以相对方式生效”：实现上只是对 Q, K 各做一次逐位置的旋转（可以用复数乘法高效计算——把每对维度看作一个复数，位置 m 的旋转就是乘以 $e^{im\theta_i}$ ），效果上注意力天然感知相对距离，且远程依赖随距离自然衰减（RoPE 论文证明的长程衰减性质）[8]。

值得玩味的是各维度的频率分工：低维（ i 小）对应的 θ_i 大、旋转快，负责编码近距离的精细位置差；高维旋转慢、周期长达上万，负责粗粒度的远程结构。这种”多尺度时钟”结构与原始正弦编码一脉相承——RoPE 可以看作把正弦编码从”加在嵌入上”改为”乘在 Q/K 上”，从而让相对性成为内禀性质而非需要学习的巧合。RoPE 的主要弱点是训练长度外的外推能力差，由此催生了位置插值（Position Interpolation）、NTK-aware 缩放与 **YaRN**（按频率分组做差异化插值，少量微调即可数倍扩展上下文窗口）[18] 等一系列长上下文技术。2026 年的位置编码综述把这条谱系总结为：absolute $\rightarrow$ relative $\rightarrow$ RoPE $\rightarrow$ 长上下文 scaling [27]。

2.7 注意力效率变体：MQA / GQA / MLA 与 FlashAttention

自回归推理时，每生成一个 token 都要用它与**所有历史 token** 做注意力。为避免重复计算，历史 token 的 K, V 被缓存下来（KV cache）。KV cache 的大小为 $O(n \cdot h \cdot d_k \cdot L)$ （ L 为层数），长序列 + 大 batch 下显存带宽成为推理瓶颈——这正是 MQA/GQA/MLA 的靶心。

先建立一个关键的数量级直觉：解码阶段每个新 token 都要从 HBM 读入**全部**历史 KV cache，而矩阵-向量乘的算术强度极低——解码是纯粹的访存受限（memory-bound）操作。也就是说，推理速度几乎与 FLOPs 无关，正比于 KV cache 的字节数。于是”压缩 KV cache”与”加速推理”变成了同一件事，这就是下面三种方案的统一逻辑，差别只在压缩手法。

- **MQA (Multi-Query Attention, 2019)** [4]: 所有 query head 共享同一组 K, V 。KV cache 缩小 h 倍，解码显著加速；代价是质量下降。
- **GQA (Grouped-Query Attention, 2023)** [16]: 把 h 个 query head 分成 g 组，每组共享一组 K, V 。 $g = 1$ 退化为 MQA， $g = h$ 退化为 MHA。论文表明 GQA-8 的质量几乎与 MHA 持平、推理速度接近 MQA，并可通过对已有 MHA 检查点用 5% 预训练算力”uptraining”转换而来 [16]。GQA 如今是 Llama 2/3、Mistral、Qwen 等开源模型的标配。
- **MLA (Multi-head Latent Attention, DeepSeek-V2/V3, 2024)** [21, 23]: 不再共享 K/V head，而是把每个 token 的 K, V 联合低秩压缩到一个潜在向量 $c_t \in \mathbb{R}^{d_c}$ ($d_c \ll h \cdot d_k$)，推理时只缓存 c_t （及 RoPE 所需的少量解耦 key），使用时再升维重构：

$$c_t = W^{DKV} x_t, \quad k_t = W^{UK} c_t, \quad v_t = W^{UV} c_t$$

由于 W^{UK} 可与 W^Q 在推理时合并（矩阵乘结合律），升维几乎不产生额外计算。DeepSeek-V2 报告 KV cache 减少 93.3%、最大生成吞吐提升至 5.76 倍 [21]。MLA 代表了从”删 head”

到”压表示”的思路升级：缓存的是信息的低秩瓶颈而非删减后的原表示。

- **FlashAttention (2022)** [12]: 与前三个改架构的方法不同, FlashAttention 是**不改变数学结果的系统层优化**。标准实现把 $n \times n$ 注意力矩阵整体物化到 GPU 高带宽显存 (HBM), 读写开销 $O(n^2)$; FlashAttention 利用 GPU 片上 SRAM 分块 (tiling) 计算注意力, 配合在线 softmax (online softmax, 逐块维护归一化常数) 避免物化整个矩阵, HBM 访问量从 $O(n^2)$ 降到 $O(n^2 d^2 / M)$ (M 为 SRAM 大小), 显存复杂度降为线性, 并带来端到端加速 (论文报告 BERT-large 训练 15% 墙钟时间加速) [12]。FlashAttention-2 进一步优化并行划分 (沿序列维度并行而非仅 batch $\times$ head) 与 warp 分工 (减少共享内存读写与同步), 速度再翻倍 [17]。

一个常见误解需要澄清: FlashAttention 并没有降低注意力的 FLOPs—— $QK^T V$ 的乘加次数一次不少。它优化的是**内存墙**: 现代 GPU 的算力增长远快于显存带宽, 许多 kernel 的实际瓶颈是把数据在 HBM 与 SRAM 之间来回搬运。FlashAttention 把 $O(n^2)$ 的中间矩阵读写从 HBM 挪进片上 SRAM, 于是同样的数学、同样的精度, 换来数倍的墙钟加速和线性的显存占用。它的深远影响在于确立了一个方法论: **架构创新必须与硬件内存层级协同设计**, 这一视角在 2025 年 DeepSeek 团队的硬件复盘文中被系统化 [25]。今天, ”是否 FlashAttention 友好”事实上成为新注意力变体能否被社区采纳的隐形门槛。

2.8 混合专家 (MoE): 用稀疏激活解耦参数与计算

稠密 (dense) 模型的每个 token 都流经全部参数, 参数量与计算量死死绑定——想把模型做大以容纳更多知识, 就必须等比例付出训练和推理 FLOPs。**混合专家 (Mixture-of-Experts, MoE)** 打破这个绑定: 把每层 FFN 复制成 N 份”专家”, 配一个轻量路由网络 (router/gating network), 每个 token 只被分派给 $k \ll N$ 个专家。参数量扩大 N 倍, 每 token 的计算量只扩大 k 倍。

形式上, 给定 token 表示 x , 路由器产生专家打分并经 softmax 得到门控权重:

$$p_i(x) = \text{softmax}(W_r x)_i, \quad \text{MoE}(x) = \sum_{i \in \text{TopK}(x)} g_i(x) \text{FFN}_i(x)$$

其中 $g_i(x)$ 为 top- k 选中专家的 (重归一化) 门控权重。Shazeer 等人 2017 年的稀疏门控 MoE [2] 首次在 LSTM 堆叠中验证了这一思想, 并在打分中加入可学习噪声以促进负载均衡。但朴素 top- k 路由有一个工程灾难: 如果路由坍塌到少数专家 (”赢者通吃”), 其余专家得不到训练、被选中专家又超出单卡容量, 整个系统崩溃。围绕**负载均衡**的技术演进构成 MoE 史的主线:

- **辅助均衡损失**: Switch Transformer (top-1 路由, 把路由简化到极致, 证明万亿参数可训练) [9] 与 GLaM (1.2T 参数、top-2 路由、等算力下优于 GPT-3 级 dense 模型) [11] 都使用辅助损失惩罚专家负载的不均匀: $\mathcal{L}_{aux} = \alpha \cdot N \sum_i f_i \cdot P_i$, 其中 f_i 是分派给专家 i 的 token 比例、 P_i 是路由分配给它的平均概率。代价是辅助损失与主损失存在目标冲突, 系数 α 需要小心调节。
- **容量因子 (capacity factor)**: 每个专家每步最多处理 $C = c \cdot (T/N)$ 个 token (T 为 batch 内 token 总数), 超出的 token 被丢弃 (dropped) 由残差连接旁路——这提醒我们 MoE 本质上是”有损”的稀疏化。

- **DeepSeek 路线的两次升级**：DeepSeekMoE [31] 提出**细粒度专家切分**（把专家切得更小、选得更多，如 64 选 8 而非 8 选 2）加**共享专家**（一个始终激活的通用专家捕获公共知识，让路由专家专注差异化），逼近专家专业化的上界；DeepSeek-V3 [23] 进一步提出**无辅助损失的负载均衡**——不给主损失加干扰项，而是给路由打分加逐专家的动态偏置项 b_i ，过载专家的偏置自动下调、欠载的上调（只影响路由选择、不影响加权重），从机制上消除了辅助损失的目标冲突 [23]。
- **开源侧的代表**：Mixtral 8×7B [20] 每层 8 个专家、top-2 路由，每 token 可访问 47B 参数但推理只用 13B 激活参数，质量对标 GPT-3.5 [20]——它向社区证明了稀疏 MoE 在开源预算下的可行性。

系统层面，MoE 的代价藏在通信里：专家通常按**专家并行**（expert parallelism）分布在不同 GPU 上，每个 token 被路由到哪个专家，就要把它的激活值通过 all-to-all 通信发到对应卡上，算完再发回。负载不均在这里是双重打击——既浪费训练信号，又让最快的卡等最慢的卡。DeepSeek-V3 能把 671B MoE 的训练控制在 2.788M H800 小时 [23]，一半功劳在架构，另一半在与 all-to-all 通信深度协同的流水线设计。

MoE 对多模态的意义超出效率本身：不同模态、不同任务天然形成“专家分工”的想象空间，多模态 MoE（按模态路由、模态内细粒度路由）是 2025 年后活跃的研究方向。

2.9 预训练范式：MLM 与 CLM 的分野

Transformer 块是通用的，差别在于训练目标：

- **掩码语言建模 (MLM, BERT, 2018)**：双向编码器，随机遮盖 15% token 并预测之。表征质量高，适合理解类任务；但预训练-微调不一致（推理时没有 [MASK]），且天然不适合生成。
- **因果语言建模 (CLM, GPT 系列)**：单向解码器，标准 next-token prediction：给定 $x_{<t}$ 最小化 $-\log P(x_t | x_{<t})$ 。目标与生成完全一致，配合 scaling 展现出惊人通用性。

2019-2021 年间曾有 encoder-decoder (T5)、prefix-LM 等多种变体之争，争论的焦点是：双向上下文带来的表征质量，值不值得牺牲与生成的统一性？历史给出了裁决——随着 GPT-3 证明 CLM + 大规模可以“通吃”理解与生成（in-context learning 让理解任务也能被表述为条件生成），纯解码器 CLM 成为大模型唯一主流范式。这个裁决的逻辑值得记取：**不是双向编码输了，而是“统一接口”赢了**——当一切任务都能写成 next-token prediction，scaling 的红利就能无差别地灌溉所有任务。BERT 式双向编码并未消亡——它活在 ViT 的视觉预训练（如 MAE 的掩码图像建模）与 CLIP 类视觉编码器里，这正是多模态时代两条范式重新汇合的地方。现代预训练在这个骨架上发展出一系列工程实践：**填充目标**（FIM, fill-in-the-middle——把一段文本中间挖空、让模型在已知前后缀的条件下补全，训练时通过特殊 token 重排语序，使模型获得“补全”而非只会“续写”的能力，对代码模型尤其关键）；**多阶段训练与退火**（annealing——预训练末期混入高质量数据并快速衰减学习率，以低成本换取显著的知识注入）；**数据配比课程**（先通识后专业、先短后长的 curriculum）。这些技巧的细节属于第 11 篇（数据与训练）的范畴，但它们共享一个前提：CLM 目标的简单性使一切数据操作都可以安全地叠加在其上。

2.10 Scaling Laws: 规模的可预测性

大模型时代最深刻的方法论发现是：损失随规模的变化是平滑、可预测的幂律。

Kaplan 定律 (2020) [5]: OpenAI 团队发现交叉熵损失 L 随参数量 N 、数据量 D 、算力 C 呈幂律，跨越七个数量级依然成立；且大模型的样本效率显著更高，因此给定算力应优先把预算投给参数（“大模型优先”），在远未收敛时停止训练。这一结论直接指导了 GPT-3（175B 参数、仅 300B token）的设计。

Chinchilla 定律 (2022) [6]: DeepMind 训练了 400 余个 70M–16B 参数的模型、覆盖 5B–500B token，用三种独立方法拟合，得出相反结论：此前的大模型普遍训练不足 (undertrained)；计算最优要求参数量与 token 数同比扩展——大约每参数 20 token。据此训练的 70B 模型 Chinchilla（1.4T token）在与 280B 的 Gopher 相同算力下全面反超，MMLU 达 67.5%（较 Gopher 提升超过 7 个百分点）[6]。Chinchilla 改写了整个行业的训练配方，LLaMA 系列“小模型 + 超量数据”的策略正是其直接后裔 [13]。

数学形式：把两条定律写成可操作的式子。Kaplan 发现损失对参数量 N 、数据量 D 、算力 C 分别满足 $L \propto N^{-\alpha_N}$ 、 $L \propto D^{-\alpha_D}$ （指数在 0.05–0.1 量级，跨越七个数量级仍成立）[5]；Chinchilla 则用三方拟合给出联合形式

$$L(N, D) = E + \frac{A}{N^\alpha} + \frac{B}{D^\beta}$$

其中 E 是不可约损失（数据的内在熵），后两项分别是“模型不够大”与“数据不够多”的惩罚项。给定算力预算 $C \approx 6ND$ （Transformer 训练 FLOPs 的经典近似），对 N, D 做约束优化即可解出计算最优分配 $N^*(C) \propto C^a$ 、 $D^*(C) \propto C^b$ ，且拟合结果显示 $a \approx b \approx 0.5$ ——这就是“同比扩展”的定量含义 [6]。理解这个框架比记住“20 token/参数”更重要：它是用可承受的小规模实验外推不可承受的大规模决策的方法论范本。

涌现现象的另一面：与平滑幂律并存的是“涌现”（emergent abilities）——某些能力（如多步算术、思维链推理）在模型规模跨越阈值前接近随机水平、之后突然可用 [30]。后续研究表明部分“涌现”是评测指标的伪影（不连续指标把平滑进步显示成跳变），但它准确刻画了一个实践事实：scale 不只是量变。这场争论至今未完全平息，也是 scaling 文献中少有的概念性争议。

多模态扩展：把 scaling law 推广到多模态时，数据侧出现新问题——高质量图文对、视频-文本对的规模远小于纯文本，**数据受限 (data-constrained)** 条件下的 scaling（重复数据的边际收益递减）、混合模态的配比最优解成为前沿问题。加上 2024 年后 test-time compute（推理时扩展，如长思维链）的兴起，“scale”一词已从单一的预训练算力扩展为“预训练 + 数据 + 推理”三维资源分配问题。

2.11 对齐技术栈：RLHF / DPO / GRPO

预训练让模型“什么都会”，对齐让它“按人的意图做”。

RLHF 三段式 (InstructGPT, 2022) [7]:

1. **SFT (监督微调)**: 用标注员撰写的示范回答微调预训练模型；
2. **RM (奖励模型)**: 对同一 prompt 的多个模型回答做人工排序，训练一个标量奖励模型 $r_\theta(x, y)$ ，常用 Bradley-Terry 偏好模型：

$$\mathcal{L}_{RM} = -\mathbb{E}_{(x, y_w, y_l)} [\log \sigma(r_\theta(x, y_w) - r_\theta(x, y_l))] \$$$

1. **PPO 强化学习**：以 SFT 模型为初始策略 π_ϕ ，最大化期望奖励同时用 KL 散度防止跑偏：

$$\max_{\phi} \mathbb{E}_{y \sim \pi_\phi(\cdot|x)} [r_\theta(x, y)] - \beta \text{KL}(\pi_\phi \| \pi_{ref}) \$$$

PPO (Proximal Policy Optimization) [3] 用 clipped surrogate objective 约束每步策略更新幅度：

$$\mathcal{L}^{CLIP}(\phi) = \mathbb{E}_t \left[\min(\rho_t \hat{A}_t, \text{clip}(\rho_t, 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \right], \quad \rho_t = \frac{\pi_\phi(a_t|s_t)}{\pi_{\phi_{old}}(a_t|s_t)} \$$$

InstructGPT 的标志性结果是：1.3B 参数的 InstructGPT 在人类偏好评估中优于 175B 的 GPT-3——“对齐带来的”“可用性”增益超过 100 倍参数规模的差距 [7]。

这套管线也暴露了三个后来反复被研究的结构性问题：其一，**奖励模型是真实偏好的有损代理**，策略对它优化过度时会出现 reward hacking——回答越来越长、越来越迎合格式偏置而未必更好；KL 正则项 $\beta \text{KL}(\pi_\phi \| \pi_{ref})$ 正是为拉住策略、不让它跑离参考分布太远。其二，**PPO 训练的系统性成本**——actor、critic、reward model、reference model 四个模型同时在内存中，加上在线采样的 rollout 开销，使 RLHF 阶段的工程复杂度远超预训练。其三，**alignment tax**——对齐后模型在部分原始能力基准上退化，需要混入预训练梯度等手段缓解。这三个问题分别定义了后续研究的三个出口：更好的奖励 (RLVR)、更简单的优化 (DPO)、更温和的目标 (各种正则化变体)。

DPO (Direct Preference Optimization, 2023) [14]：RLHF 需要训练奖励模型 + 跑不稳定的在线 RL，工程负担重。DPO 的洞察是：KL 约束下的最优策略与奖励函数存在闭式关系 $r(x, y) = \beta \log \frac{\pi^*(y|x)}{\pi_{ref}(y|x)} + \beta \log Z(x)$ ，代入 Bradley-Terry 偏好模型，配分函数 $Z(x)$ 在成对比较中消去，直接得到对策略的分类损失：

$$\mathcal{L}_{DPO}(\pi_\phi; \pi_{ref}) = -\mathbb{E}_{(x, y_w, y_l)} \left[\log \sigma \left(\beta \log \frac{\pi_\phi(y_w|x)}{\pi_{ref}(y_w|x)} - \beta \log \frac{\pi_\phi(y_l|x)}{\pi_{ref}(y_l|x)} \right) \right] \$$$

无需奖励模型、无需在线采样、无需 PPO 超参调优，一次普通的梯度训练即完成偏好对齐。DPO 在情感控制、摘要、对话任务上匹配或超过 PPO-based RLHF [14]，迅速成为开源社区后训练默认选项，并衍生出 IPO、KTO、ORPO 等方法族；2026 年的理论综述已将这一族方法统一在偏好学习框架下 [26]。

GRPO (Group Relative Policy Optimization) 与 RLVR (2025) [24]：DeepSeek-R1 把强化学习推向新方向。GRPO 去掉了 PPO 的 value network (critic)，改为对同一 prompt 采样一组 G 个回答，用组内奖励的相对排名构造优势：

$$\hat{A}_i = \frac{r_i - \text{mean}(\{r_1, \dots, r_G\})}{\text{std}(\{r_1, \dots, r_G\})} \$$$

配合与 PPO 类似的 clipped 目标与 KL 正则更新策略。去掉 critic 的收益是双重的：省掉一个与 policy 同规模的价值网络的训练（显存与不稳定性的主要来源），且组内基线天然自适应——同一 prompt 的难样本获得负优势、易样本获得正优势，无需学习绝对的价值标度。

关键转折在于奖励来源：**RLVR (Reinforcement Learning with Verifiable Rewards)** 用可程序化验证的奖励（数学答案是否正确、代码是否通过测试）替代 learned reward model，从根上规避了 reward hacking——你无法欺骗一个编译器或一个等号判定。DeepSeek-R1 证明纯 RL 即可激发长思维链、自我反思与验证等推理行为，不依赖人工标注的推理轨迹 [24]：论文记录了训练过程中模型的平均回答长度自发增长、出现“等等，让我重新检查”式的自我修正，这些行为没有出现在任何训练数据里，是 RL 压力下的自发产物。这直接重塑了 2025–2026 年

后训练的技术主线，也把”推理”从 prompting 技巧升格为可训练的能力维度。

3 经典方法谱系

3.1 关键论文一览表

论文	年份	核心思想	架构要点	备注
Attention Is All You Need [1]	2017	纯注意力架构取代循环/卷积	MHA + FFN + Post-Norm, encoder-decoder	一切基件之源
Sparse MoE (Shazeer 等) [2]	2017	稀疏门控解耦参数与计算	top-k 路由 + 噪声均衡	MoE 开山
PPO [3]	2017	clipped 目标稳定 on-policy RL	策略比值截断	后成 RLHF 默认算法
MQA [4]	2019	共享单组 K/V	KV cache 缩 h 倍	推理加速先驱
Kaplan Scaling Laws [5]	2020	损失随规模幂律变化	主张大模型优先	GPT-3 的理论依据
ViT [6b→见 29]	2020	图像切块直过 Transformer	patch embedding + CLS	视觉骨干范式确立
RoFormer (RoPE) [8]	2021	旋转注入相对位置	$R_{\Theta, n-m}$ 相对性	现代 LLM 标配
Switch Transformer [9]	2021	top-1 路由简化 MoE	容量因子 + 辅助均衡损失	万亿参数可训练
ALiBi [10]	2021	线性距离偏置	无位置向量、可外推	短训长推
GLaM [11]	2021	1.2T 稀疏 MoE	top-2 路由	等算力超 GPT-3 级 dense
InstructGPT [7]	2022	SFT→RM→PPO 三段式	RLHF 流程定型	对齐开山
Chinchilla [6]	2022	参数/数据同比扩展 (~20 tok/param)	400+ 模型拟合	改写训练配方
PaLM [28]	2022	540B dense + Pathways	大规模系统协同	涌现能力展示
FlashAttention [12]	2022	IO-aware 精确注意力	tiling + online softmax	算法-系统协同标杆
Emergent Abilities [30]	2022	规模阈值后的能力涌现	评测现象学	scaling 讨论核心

论文	年份	核心思想	架构要点	备注
LLaMA [13]	2023	公开数据训开源基座	Pre-Norm/RMSNorm/SwiGLU/RoPE	开源生态引爆点
DPO [14]	2023	闭式偏好优化	无 RM、无在线 RL	后训练简化
GQA [15/16]	2023	分组共享 K/V	质量 MHA、速度 MQA	现代标配
Llama 2 [15]	2023	商用许可开源 + RLHF 配方	GQA (70B)	开源基座标准
FlashAttention2 [17]	2023	并行度优化	再提速约 2×	训练基础设施
YaRN [18]	2023	RoPE 分频插值	少数据扩窗	长上下文主流
Mistral 7B [19]	2023	GQA + 滑窗注意力	小模型架构优化	效率示范
Mixtral 8×7B [20]	2024	开源稀疏 MoE	top-2 路由、47B/13B 激活	对标 GPT-3.5
DeepSeekMoE [31]	2024	细粒度专家 + 共享专家	专业化上界	DeepSeek 系谱基础
DeepSeek-V2 (MLA) [21]	2024	低秩压缩 KV cache	236B/21B 激活、cache -93.3%	MLA 首次落地
Qwen2 [22]	2024	现代配方代表	GQA/RoPE/SwiGLU 全系	开源系列标杆
DeepSeek-V3 [23]	2024	671B MoE 全栈工程	MLA + 无辅助损失均衡 + MTP	2.788M H800 小时
DeepSeek-R1 [24]	2025	纯 RL 激发推理	GRPO + 可验证奖励	reasoning RL 转折点
Hardware-AI 反思 [25]	2025	架构-硬件协同复盘	设计决策的硬件约束	co-design 时代宣言

3.2 谱系的内在逻辑

这张表看似繁杂，内在结构其实是四幕剧。读这张表的正确姿势不是记住每篇的名字，而是识别**每篇论文在解决前一篇的哪个遗留问题**——这正是本系列报告反复强调的”问题接力”视角：

第一幕（2017–2020）确立骨架：Transformer 定义了 MHA+FFN 的基本块；MoE 提供了稀疏扩展路线；ViT 证明同一骨架可以消化图像；Kaplan 定律给出了规模扩张的信心。

第二幕（2021–2022）训练配方定型：RoPE/ALiBi 解决位置编码；Chinchilla 修正 scaling 实践；FlashAttention 打通长序列训练的系统瓶颈；InstructGPT 建立对齐管线。到 2022 年底，”如何训练一个大模型”的全套方法论已经闭环。

第三幕（2023–2024）开源与效率：LLaMA 把配方开放给社区，GQA/FlashAttention-2/MQA-系 KV 压缩让推理成本骤降；Mixtral/DeepSeekMoE/MLA 把 MoE 从实验室推向生产；YaRN 等把上下文窗口推向 128K 甚至更长。

第四幕（2025-2026）推理与协同：DeepSeek-R1 开启 RLVR 推理范式；架构设计进入硬件感知阶段（V3 的 2.788M H800 GPU 小时训练 671B 模型是标志性数字 [23]）。多模态模型在这一幕中成为最大受益者——它直接站在所有基件的成熟态之上。

4 代表作深度剖析

4.1 Attention Is All You Need (Transformer, 2017) [1]

研究问题：序列转导模型（如机器翻译）能否彻底摆脱循环与卷积结构？

关键洞察：注意力机制本身就足以建模序列内任意位置间的依赖；循环结构是并行计算的障碍而非表达能力的必需品。

技术方法：encoder-decoder 各 6 层， $d_{model} = 512$ (base) / 1024 (big)， $h = 8/16$ 头， $d_{ff} = 2048/4096$ ；缩放点积注意力 + 正弦位置编码 + Post-Norm 残差；训练用 Adam、带 warmup 的学习率调度、label smoothing 与 dropout 正则。

实验结果：WMT 2014 英德翻译 28.4 BLEU，超越此前最佳（含集成模型）超过 2 BLEU；英法翻译 41.8 BLEU 创单模型纪录，且仅用 8 张 GPU 训 3.5 天——训练成本只是同期最佳模型的一小部分 [1]。

批判性分析：优点是结构简洁、并行度极高、可扩展性被后续九年反复验证；还有一个事后才看清的优点——它足够“空”。Transformer 几乎不内置任何关于语言的归纳偏置（不像 CNN 的局部性、RNN 的时间性），这意味着它既不限模型学什么，也不限模型从哪种模态学。这个“空”正是它能从文本迁移到图像、音频、视频、动作的根本原因：通用架构 + 数据 + 算力的组合击败了各种领域特化设计，即所谓“bitter lesson”的架构注脚。局限在于论文本身未预见 $O(n^2)$ 注意力在长序列下的代价，也未解决位置外推、训练稳定性（Post-Norm 需要 warmup）等问题——本篇 2.5-2.7 节的全部内容，都可以读作对这篇论文遗留问题的九年修复史。可复现性极佳——代码与超参全部公开，衍生出 Tensor2Tensor 与无数复现。

一句话评价：现代深度学习史上被引用最多的架构论文，整个报告系列的一切都在这里生长。评级：★★★★★（必读原文）。

4.2 An Image is Worth 16×16 Words (ViT, 2020) [29]

研究问题：图像识别能否像 NLP 一样，不依赖卷积归纳偏置，直接用纯 Transformer？

关键洞察：把图像切成固定大小的 patch（如 16×16 像素）拉平成向量序列，图像就变成了“一句话”；Transformer 在足够大的预训练数据下能自己学会 CNN 赖以成名的局部性与平移等变性。

技术方法：图像 $x \in \mathbb{R}^{H \times W \times C}$ 切成 $N = HW/P^2$ 个 $P \times P$ patch，每个 patch 经线性投影成 d 维向量，加上可学习位置嵌入，序列前拼接可学习 [CLS] token，送入标准 Transformer encoder；用 [CLS] 输出做分类。模型族 ViT-B/L/H 分别为 86M/307M/632M 参数。

实验结果：在 JFT-300M 等大规模数据上预训练后，ViT 在 ImageNet、CIFAR-100、VTAB 等基准上达到或超越当时最优 CNN，且预训练所需计算资源更少 [29]。但论文同样诚实地指出：在中等规模数据（ImageNet 级别，约 1.3M 图）上，ViT 不如同级别 ResNet——大数据是 ViT 发

挥作用的前提。

批判性分析：优点是彻底统一了视觉与语言的建模范式，使"视觉编码器输出 token 序列 → 喂给 LLM"的多模态管线成为可能（后续 CLIP、SigLIP、Qwen-VL 的视觉塔全部是 ViT 变体）；从工程角度看，ViT 还带来一个隐性红利——视觉与文本共享同一套训练基础设施（kernel、并行策略、混合精度），跨模态团队/system 栈得以统一。局限同样清晰：二次复杂度对高分辨率图像代价高（分辨率翻倍、序列长度翻四倍、注意力开销翻十六倍），后续 Swin 等用滑窗层级结构缓解，但多模态大模型仍以纯 ViT 为主流视觉塔（因为预训练好的纯 ViT 权重生态最丰富）；patch 化丢失像素级细节，影响 OCR、细粒度定位等任务——多模态模型后来用动态分辨率、多尺度裁剪等技巧打补丁，都是对这个原始缺陷的回应。可复现性好，官方权重公开。

一个常被忽视的观察：ViT 论文标题说"一张图值 16×16 个词"，但它的真正遗产是把图像变成了可被 LLM 直接消费的离散序列。没有这一步，后续"视觉 token 拼进文本 token 一起做自回归"的整个 MLLM 范式无从谈起。从这个意义上说，ViT 与其说是视觉论文，不如说是多模态论文——它提前五年为多模态基座模型准备好了接口协议。

一句话评价：把视觉带入 Transformer 纪元的论文，多模态大模型视觉塔的直系祖先。评级：★★★★★。

4.3 Training Compute-Optimal Large Language Models (Chinchilla, 2022) [6]

研究问题：给定固定训练算力预算 C ，模型参数量 N 与训练 token 数 D 应如何分配？

关键洞察：Kaplan 定律的"大模型优先"结论是在数据不受限的假设下得出的；当把 N 与 D 作为联合变量拟合 $L(N, D)$ 时，最优解要求二者同比扩展。

技术方法：训练超过 400 个模型（70M–16B 参数、5B–500B token），用三种独立方法估计计算最优前沿：(1) 固定模型族规模、扫描 token 数取各算力下损失最低点；(2) 固定 FLOPs 预算、扫描模型规模取 isoFLOP 曲线谷底；(3) 直接拟合参数化损失函数 $L(N, D) = E + A/N^\alpha + B/D^\beta$ （不可约损失 + 参数项 + 数据项）。三种方法一致指向 $D \approx 20N$ 。

实验结果：按此结论训练的 Chinchilla（70B 参数、1.4T token）在与 Gopher（280B、300B token）相同算力下，在绝大多数下游任务上显著反超 Gopher、GPT-3（175B）、Jurassic-1（178B）、Megatron-Turing NLG（530B）；MMLU 平均 67.5%，较 Gopher 提升超 7 个百分点 [6]。

批判性分析：方法论是经验科学的典范——三路径交叉验证、幂律外推有明确的置信区间；其研究设计本身就值得每位入门者抄笔记：不是训练一个超大模型然后写故事，而是训练数百个中小模型、把"预测大模型行为"当作一个可以被证伪的回归问题来处理。局限在于：(1) "20 token/参数"是训练计算最优而非推理成本最优，推理时代小模型超量训练（LLaMA 式）反而成为主流；(2) 数据质量差异、数据重复（data-constrained 场景）未纳入模型；(3) 未预见 test-time compute 范式——长思维链模型的最优配比可能系统性地偏向更小模型 + 更多推理算力。结论部分可复现（LLaMA 等公开模型间接验证了其预测）。

一句话评价：大模型时代最重要的一篇"如何花钱"的论文，其框架至今是所有训练预算讨论的起点。评级：★★★★★。

4.4 Training Language Models to Follow Instructions with Human Feedback (InstructGPT, 2022) [7]

研究问题：大模型能力强大，但输出经常不符合用户意图（编造、有害、跑题）——如何让模型"对齐"？

关键洞察：把"符合人类意图"从抽象目标变成可优化的奖励信号：让人类对模型输出排序，用排序训练奖励模型，再用 RL 最大化该奖励。

技术方法：即 2.10 节的 SFT→RM→PPO 三段式。数据来自标注员撰写的 prompt 与 OpenAI API 真实用户 prompt；标注团队约 40 人，经过严格培训与标注者间一致性筛选——论文用了相当大的篇幅讨论标注协议，因为整个方法的成立前提就是"排序信号足够干净"。模型上以 GPT-3 各尺寸（1.3B/6B/175B）为起点，逐级走完三段流程。PPO 训练中混入预训练梯度（PPO-ptx）以缓解公共 NLP 基准上的能力退化（alignment tax），这个细节预示了后来所有对齐工作都要面对的"对齐-能力"跷跷板。

实验结果：在 API prompt 分布的人工评估中，1.3B InstructGPT 的输出偏好率超过 175B GPT-3——百倍参数差距被对齐抹平；真实性提升、有毒输出减少，公共 NLP 基准退化轻微 [7]。

批判性分析：历史性贡献在于确立了"预训练→SFT→RLHF"这一沿用至今的范式（本系列后续对齐篇的 fig_training_pipeline 三阶段图即源于此）；局限包括：标注分布狭窄（40 名标注者的偏好能否代表全人类？）、奖励模型可被策略模型过优化（reward hacking 的早期体现）、PPO 训练不稳定且昂贵。这些局限恰好定义了后续 DPO、RLVR 要解决的目标。部分可复现（代码未公开，但配方细节充分，开源社区已有大量复现）。

一句话评价：把"对齐"从哲学讨论变成工程管线的论文，ChatGPT 时代的技术起点。评级：★★★★★。

4.5 Direct Preference Optimization (DPO, 2023) [14]

研究问题：RLHF 的三段式管线（RM + PPO）复杂且不稳定，能否绕开显式奖励模型与在线强化学习，直接优化偏好？

关键洞察：在 KL 正则的 RLHF 目标下，最优策略对任意奖励函数有闭式解；反过来，奖励可以被最优策略与参考策略的对数比解析地参数化——代入 Bradley-Terry 模型后，配分函数消去，偏好学习退化为一个二分类问题。

技术方法：推导骨架值得再走一遍。KL 正则 RLHF 目标 $\max_{\pi} \mathbb{E}[r(x, y)] - \beta \text{KL}(\pi \| \pi_{ref})$ 对每个 prompt x 是独立的优化问题，其闭式最优解为 $\pi^*(y|x) \propto \pi_{ref}(y|x) \exp(r(x, y)/\beta)$ ——软最大化（softmax）形式的策略。反解出 $r(x, y) = \beta \log \frac{\pi^*(y|x)}{\pi_{ref}(y|x)} + \beta \log Z(x)$ 代入 Bradley-Terry 模型，未知的配分函数 $Z(x)$ 在 $r(x, y_w) - r(x, y_l)$ 的差中精确消去，剩下的就是 2.10 节的 $\mathcal{L}_{DPO}$ ：一个只含策略对数概率的 logistic 回归损失。实现上只需 SFT 模型（兼作 π_{ref} 与初始化 π_{ϕ} ）与偏好数据集，一次监督式梯度训练即完成对齐；超参数只有 β （KL 强度）与学习率。

实验结果：在情感控制、单轮对话、摘要等任务上，DPO 匹配或超过 PPO-based RLHF，且训练稳定性与计算成本显著更优 [14]。

批判性分析：优点是优雅（理论推导干净）+ 实用（工程简化一个数量级），迅速成为开源后训练事实标准；局限包括：偏好数据是离线的（off-policy），随着策略漂移，数据分布与当前策略脱节——PPO 的在线采样能持续"问自己现在会答成什么样"，DPO 只能问"当初那个模型答

成什么样";对偏好数据质量敏感,一个已知的系统性问题是长度偏置——标注者普遍偏好更长的回答,DPO 会忠实地把这个偏置放大为冗长输出; β 控制隐式 KL 强度,极端偏好对下可能出现"赢家概率也被压低"的退化现象(只追求拉开差距而非抬高赢家),后续 length-normalized 与约束变体都在修补这一点。这些局限催生了在线 DPO、IPO、KTO 等改进族。2026 年的统一理论框架 [26] 证明 DPO 族与 RLHF 在数学上是同一目标的不同参数化——"去 RL 化"并非解开 RL,而是把 RL 的解折叠进了监督目标。

一句话评价:一行损失函数掀翻整条 RLHF 流水线的论文,理论与实践结合的最佳范例。评级:★★★★★。

4.6 DeepSeek-V3 Technical Report (2024) [23]

研究问题:能否在受限硬件(出口管制下的 H800,互联带宽受限)上,以可承受的成本训练一个与顶级闭源模型同档的开源 MoE 模型?

关键洞察:把此前分散验证的架构创新(MLA、细粒度 MoE)与系统创新(FP8 训练、通信-计算重叠、无辅助损失均衡)组装成一个协同设计的整体——每个决策都同时回应"质量"与"硬件约束"两个目标,而非先后优化。

技术方法:671B 总参数、每 token 激活 37B;注意力采用 MLA 低秩压缩 KV cache;FFN 采用 DeepSeekMoE 细粒度专家 + 共享专家;负载均衡不用辅助损失,改用可动态调整的路由偏置项(见 2.7.1);训练目标加入多 token 预测(MTP,同时预测未来多个 token 以 densify 监督信号);预训练 14.8T token;全程 FP8 混合精度。

实验结果:训练全程仅消耗 2.788M H800 GPU 小时,且没有发生任何不可恢复的损失尖峰、没有回滚 [23];综合评测超越全部开源模型、与顶级闭源模型相当。作为参照,同档 dense 模型的训练成本通常是其数倍。

批判性分析:这是"架构-系统-硬件"三位一体的工程杰作,其意义不在于某个单点创新(每个组件此前都有论文),而在于证明了中国开源生态可以在硬件受限条件下重构前沿配方——2025 年的硬件复盘 [25] 把这种协同设计上升为方法论。局限同样明显:报告是工程文档而非科学论文,大量消融实验(每个组件的独立贡献)未公开;2.788M GPU 小时的数字不含前期研究与失败的消融,读者不应把它当作"可复现成本"而应当作"下界参考"。可复现性中等——权重开源、推理可验证,但训练栈(框架、数据配比)未完整公开。

一句话评价:单篇浓缩 MLA、MoE 均衡、FP8、流水线四大工程主题的"现代大模型训练百科全书",理解 2025 年后所有旗舰模型的必读文献。评级:★★★★★。

5 研究前沿 (2025–2026)

(1) 推理范式转向 RL: DeepSeek-R1 [24] 之后,"RLVR + 长思维链"成为后训练主线,2025 年几乎所有旗舰模型的发布都包含一个"reasoning 版本"。GRPO 类 value-free 算法被开源社区广泛采用,并衍生出去 KL 项、去方差归一化、token 级优势等一系列变体——细节之争背后是一个共同的观察:当奖励是稀疏的 0/1 验证信号时,PPO 时代精心设计的许多组件不再必要。前沿问题是:可验证奖励如何推广到不可验证领域(写作、开放式问答——rubric 评分与 LLM-as-judge 是目前两条探路)、推理长度与正确率的 trade-off ("overthinking"——模型在简单题上浪费数千 token——已成为新的优化目标)、以及多模态推理(视觉 CoT)的 RLVR 化。

(2) MoE 架构定型并下探：DeepSeek-V3 [23] 确立了"MLA + 细粒度 MoE + 无辅助损失负载均衡 + 多 token 预测 (MTP)" 的组合配方，671B 总参、37B 激活、14.8T token 预训练、全程仅 2.788M H800 GPU 小时且无不可恢复的损失尖峰 [23]。Qwen3、GLM、Kimi 等系列跟进类似设计。前沿问题包括：专家专业化是否真的发生、细粒度与共享专家的最优比例、MoE 的 scaling law 形式化。

(3) 硬件感知架构设计：DeepSeek 团队的 V3 复盘 [25] 标志着架构创新进入"硬件 co-design" 阶段——MLA 的低秩结构、FP8 混合精度训练（用 8 位浮点做大部分矩阵乘、关键累加留在高精度）、流水线并行的气泡消除（DualPipe 式双向流水调度），都是为具体硬件（H800 受限的互联带宽）量身定制的决策。这篇复盘最启发性的一点是：许多被社区当作"算法创新"的设计，其实是对硬件约束的最优响应——如果互联带宽不同，同样的模型可能会长出不同的路由与压缩方案。这意味着未来架构论文将越来越多地包含系统层的约束分析，脱离硬件语境讨论"哪个架构更好"正在失去意义。

(4) 高效架构的百家争鸣：2025–2026 年的高效架构综述 [32] 反映了社区焦点的扩散：linear attention、sparse attention、状态空间模型（Mamba 系）、混合架构（hybrid：少量全注意力层 + 大量线性层）都在争夺"后 Transformer" 的位置。位置编码综述 [27] 则显示长上下文技术（NTK、YaRN、插值）已收敛为成熟工具箱。对多模态而言，这些高效架构尤为关键——视频理解动辄数万 token，纯二次注意力难以为继。

(5) 对齐理论收敛：RLHF→DPO→RLVR 的接力已清晰，理论综述 [26] 把偏好学习方法族统一到同一框架；2026 年的新动向包括 rubric（评分细则）引导的 RL、多目标对齐（有用/无害/诚实的帕累托前沿）、以及多模态场景的安全对齐（图像输入的越狱攻击面）。

6 点题：这些基件如何被多模态模型复用

让我们把视角拉回整个系列的开篇问题：一个 2026 年的多模态基座模型，内部到底装了什么？答案是——几乎全是本篇讲过的基件，只是换了一种拼装方式：

1. 语言主干 = 现代配方全家桶。主流多模态大模型（MLLM）的语言侧就是一个标准 decoder-only LLM：Pre-Norm + RMSNorm 残差、SwiGLU FFN、RoPE 位置编码、GQA 或 MLA 注意力、FlashAttention 内核、dense 或 MoE 前馈。Qwen-VL、InternVL、Kimi、GPT-4o 级系统的语言塔无一不在这条谱系上。理解本篇第 2 节，就等于理解了任何 MLLM 一半以上的参数量在做什么。
1. 视觉骨干 = ViT 的直接后裔。视觉塔几乎清一色是 ViT 变体（CLIP/SigLIP 对比学习预训练的 ViT），输出 patch token 序列——ViT 把"图像即 token 序列"这件事确立之后，视觉接入语言模型就变成了纯粹的 token 对齐问题（connector/投影层），这是第 01 篇（视觉-语言）的全部出发点。
1. 位置编码与长上下文技术 = 多模态的刚需放大器。一张高清图可以是数千 token，一分钟视频可以是数万 token；RoPE + YaRN 式插值 [18] 与 ALiBi 式外推思想被直接搬到图像二维位置、视频时空位置编码上（2D-RoPE、时空分解旋转等变体），长上下文技术从"文本奢侈品"变成"多模态基础设施"。

1. 注意力效率变体 = 多模态推理成本的生命线。多模态序列长、图像 token 冗余度高，KV cache 压力成倍放大；GQA/MLA [21] 与滑窗注意力 [19] 的每一项都直接决定视觉-语言模型能否实时交互。视觉 token 的剪枝与压缩，则可以看作 MQA/MLA" 压缩信息而非删减结构" 思想在模态维度上的延伸。
1. MoE = 多模态容量扩展的主通道。当模型要同时掌握文本、图像、音频、视频、动作时，" 总参大、激活小" 的 MoE 结构 [20, 23] 成为容纳多模态知识而不爆推理成本的自然选择；按模态/任务分化专家，是 MoE 语义在多模态下的再诠释。
1. 预训练范式 = 多模态目标的模板。CLM (next-token prediction) 不仅统治文本生成，也被推广为"next-patch/next-image-token prediction" (自回归图像生成，见第 05 篇)；BERT 式掩码建模则活在 MAE 式视觉自监督里。两大范式的分野与汇合贯穿整个系列。
1. Scaling laws = 多模态预算分配的方法论。Chinchilla 的 $L(N, D)$ 拟合框架 [6] 被逐字搬到多模态 scaling 研究：图文配比对、视觉 token 数与语言参数的最优配比、数据受限下的重复训练，都是 Kaplan→Chinchilla 方法论的直接后代（第 11 篇数据与训练将展开）。
1. 对齐技术栈 = 原封不动的移植。SFT → DPO → RLVR 的三段式后训练对多模态模型几乎不加修改地复用：多模态指令微调就是 SFT、多模态偏好数据上的 DPO 就是 DPO、视觉数学/图表题上的可验证奖励就是 RLVR [24]。多模态对齐的特殊性（幻觉、跨模态安全）是第 09 篇的主题，但工具箱就是本篇 2.10 节的那一套。

一句话总结本篇的立场：多模态大模型不是新架构，而是旧基件的新编排。吃透这八个基件的动机、数学与权衡，后续每一篇专题报告对你而言都将只是" 这个基件在这个模态下长什么样" 的具体化练习。

7 技术路线对比与权衡

本节把前面分散在各基件里的" 选择问题" 集中到四张表：推理时注意力怎么选（6.1）、位置编码怎么选（6.2）、对齐管线怎么搭（6.3）、前馈用 dense 还是 MoE（6.4）。这四个选择基本决定了一个现代基座模型的架构画像——2026 年你读到任何一份新模型技术报告，前四页大概率就是在回答这四个问题。

7.1 注意力变体对比

方案	KV cache（相对 MHA）	质量	推理速度	代表模型	适用场景
MHA	1×	最高	基线	GPT-3	训练、质量优先
MQA	1/h	有可见损失	最快	PaLM 部分变体	极端延迟敏感

方案	KV cache（相对 MHA）	质量	推理速度	代表模型	适用场景
GQA	1/g（ $g \approx 4-8$ ）	$\approx$ MHA	$\approx$ MQA	Llama 2/3、Qwen2	通用默认
MLA	低秩压缩（V2 报告 -93.3% [21]）	$\approx$ MHA 甚至更好	高吞吐	DeepSeek-V2/V3	大 MoE + 长上下文
滑窗 注意 力	窗口内全量	长程略降	长序列友好	Mistral [19]	中小模型长文本

核心权衡是缓存大小 vs 表达容量。值得强调：MLA 的思路（低秩瓶颈而非删减 head）可能是更本质的方向，因为它保留了逐 head 的多样性，只是约束其位于低维子空间。

还有一个常被忽略的部署维度：这些方案与训练方式耦合。MQA/GQA 可以从头训练，也可以像 GQA 论文 [16] 那样从已有 MHA 检查点 uptraining（5% 预训练算力）；MLA 的低秩结构则基本需要从头训练（或在架构改造时付出较大转换成本），因为它改变了注意力内部的投影拓扑。对于手握大量 MHA 时代检查点的团队，GQA 的"可转换性"是它在 2023 年迅速胜出的隐性原因——架构竞争有时不由质量曲线决定，而由迁移成本决定。

7.2 位置编码对比

方案	类型	外推性	相对位置感知	现状
Sinusoidal	绝对	理论可外推，实践差	隐式	历史意义
Learned PE	绝对	不可外推	弱	ViT 内部仍常用
ALiBi	相对偏置	好	显式	少数模型（如早期 BLOOM/MPT）
RoPE	旋转相对	需插值/YaRN 辅助	显式 + 长程衰减	文本 LLM 绝对主流

表中"现状"一栏值得一个解释：为什么外推性更好的 ALiBi 没有赢？三个原因。其一，线性偏置把"距离衰减"硬编码为固定斜率，而真实语言中有些长程依赖（如跨段落的指代、代码中遥相呼应的括号）恰恰不应衰减——RoPE 的衰减是可学习的函数形状，ALiBi 的是先验常数。其二，RoPE 只作用于 Q/K 而不改注意力结构，与 FlashAttention 等 kernel 完全兼容；ALiBi 的加性偏置矩阵在分块计算里需要额外处理（实践中也已解决，但生态跟进慢了一拍）。其三，YaRN 等插值技术 [18] 基本补齐了 RoPE 的外推短板，竞争窗口随之关闭。这段历史提醒我们：架构竞争的胜负往往由"短板可否被廉价补齐"决定，而非长板有多高。

7.3 对齐方法对比

方法	奖励来源	是否在线	训练成本	主要风险	代表
PPO-RLHF	learned RM	在线	高 (actor+critic+RM+ref 四模型)	reward hacking、训练不稳	InstructGPT [7]
DPO	隐式 (对数比参数化)	离线	低 (两模型、监督式)	分布漂移、长度偏置	Zephyr、众多开源模型 [14]
GRPO/RLVR	程序化验证	在线	中 (无 critic)	仅适用可验证任务	DeepSeek-R1 [24]

实践中的现代配方往往是组合拳：SFT → DPO（或在线偏好优化）打底通用偏好，RLVR 专项强化推理/代码/数学。

三者的深层差异其实是监督信号的来源：PPO-RLHF 的信号来自 learned RM（拟合人类但可被欺骗），DPO 的信号来自静态偏好对（干净但会过时），RLVR 的信号来自程序验证（不可欺骗但覆盖面窄）。这个"来源光谱"解释了为什么没有任何单一方法能终结对齐研究——覆盖面、抗欺骗性、时效性构成不可能三角，每家实验室都在按自己的风险偏好选点。对入门者而言，这个三角也是评估任何新对齐论文的第一把尺子：它在三角上牺牲了什么、换来了什么？

7.4 Dense vs MoE

维度	Dense	Sparse MoE
参数/计算	耦合	解耦（总参大、激活小）
训练稳定性	高	需负载均衡技巧（辅助损失或无辅助策略 [23]）
推理成本	与参数成正比	与激活参数成正比，但显存需装全部专家
通信开销	标准张量并行	专家并行的 all-to-all 通信是系统难点
代表	LLaMA、Qwen2-dense	Mixtral [20]、DeepSeek-V3 [23]

2024–2026 年的趋势清晰：旗舰模型几乎全面转向 MoE，因为训练 FLOPs 相同时 MoE 质量更高、推理激活参数更少；dense 模型退守中小尺寸与端侧。但"转向"有一个重要的例外逻辑值得说明：当推理部署的显存预算紧张时（端侧、单卡场景），MoE"激活小但总参大"的特性反而是劣势——13B 激活的 Mixtral 仍需装下全部 47B 参数。所以 MoE 是数据中心推理的赢家，dense 仍统治边缘推理，这个分裂在可预见的将来不会消失。

8 开放问题与未来方向

1. 注意力的"后二次"时代何时到来：linear/sparse/hybrid 架构在基准上不断逼近全注意力，但在长程检索、in-context learning 等关键能力上仍有差距。多模态长序列（视频、长文档图像）会是这场竞赛的试金石。

2. 数据受限下的 scaling law: 文本数据逼近枯竭, 多模态高质量配对数据更稀缺。数据重复的收益递减曲线、合成数据的 scaling 性质、跨模态迁移对配比的修正, 都缺乏 Chinchilla 级别的系统性研究。
3. MoE 的理论理解: 专家为何专业化、何时失效, 路由的梯度动力学, 细粒度专家的上界——目前几乎全是经验结论。
4. RLVR 的边界: 可验证奖励之外, 如何为开放式、主观性任务设计抗 hacking 的奖励? rubric-based 奖励与 learned RM 的混合是否是终局?
5. 架构-硬件协同的自动化: V3 的设计决策由专家手工完成; 能否把硬件约束纳入架构搜索 (hardware-aware NAS for LLM)?
6. 统一的多模态 scaling 理论: 文本、图像、视频、音频 token 的最优混合比例随算力如何变化? 这是把 Kaplan/Chinchilla 框架推广到多模态的核心问题, 也是本系列后续篇章反复回到的理论锚点。
7. 推理时扩展与训练时扩展的联合最优: RLVR 时代, 同一个模型既要被训练 (花算力) 又要会推理时思考 (花 token)。给定总预算, "训练更大" 与 "想更久" 之间是否存在类似 Chinchilla 的配比定律? 初步证据表明最优解强烈依赖任务的可验证性, 但系统性的拟合研究尚未出现。
8. 位置编码的二维/时空推广: RoPE 在文本的一维序列上是优雅的, 但图像的高度-宽度、视频的时间-空间、音频的帧-频结构如何共享或分解旋转基? 目前各家 MLLM 的方案 (2D-RoPE、时空分解、简单可学习嵌入) 高度碎片化, 缺乏一维 RoPE 当年那样的统一理论。

9 研究机会点评（给入门研究者的建议）

算力门槛适中、问题清晰的子方向:

- 长上下文位置编码与检索评测: YaRN 类方法 [18] 的改进只需 7B 级模型 + 数张 GPU 微调即可验证; 长上下文评测 (如大海捞针类任务的更严谨版本) 仍有方法学空白。
- DPO 族的算法改进: 离线偏好优化的理论 (何时退化、如何校正分布漂移) 与改进算法, 单卡即可做 1B-8B 级实验, 顶会产出稳定。
- KV cache 压缩: MLA 之后的下一步 (量化 + 低秩 + 稀疏的组合), 与推理系统结合紧密, 工程与学术价值兼备。
- 小规模 scaling law 研究: 用 400 个小模型复刻 Chinchilla 式拟合在学术预算内可行 (这正是 Chinchilla 论文自己的方法), 数据质量、数据重复、多模态配比等修正项都是好题目。

需要正视的"巨头游戏":

- 旗舰 MoE 预训练: DeepSeek-V3 级别 (2.788M H800 小时) 的投入是学术机构无法企及的; 学术界应做配方创新 (新路由、新均衡策略) 并在中小规模验证, 而非正面竞争。
- 大规模 RLHF/RLVR 训练: 在线 RL 的系统复杂度 (rollout 集群、vLLM 推理引擎协同) 本身就是工程壁垒; 但算法层创新 (新优势估计、新奖励塑形) 可以用小模型完成概念验证。
- 基础架构替代 (linear attention/SSM): 需要在与 Transformer 同等规模的公平对比中取胜

才有人信服，这个"同等规模"的门槛正在逐年抬高。

一条务实建议：入门者的第一篇工作尽量选"小模型上可完整复现的配方级问题"（如 GQA 组数的选择、RoPE base 频率的敏感性、DPO 的 β 与数据质量交互），这类问题基件级、可复现、且结论能迁移到大模型，是建立学术信誉的最快路径。

第二条建议关于读论文的顺序：本篇第 4 节的六篇深读是按"叙事骨架"而非难度排序的——Transformer（架构原点）→ ViT（模态扩展）→ Chinchilla（规模方法论）→ InstructGPT（对齐原点）→ DPO（对齐简化）→ DeepSeek-V3（现代集成）。按这个顺序读，你会发现每篇论文都在回答前一篇留下的问题，这种"问题接力"的读法比按时间线泛泛而读有效得多。

第三条建议：尽早建立自己的复现环境。哪怕只是用开源框架在小模型上跑一次 DPO、测一次 RoPE 外推曲线，亲手观察 loss 曲线的形状与超参的敏感性，是把"读过的知识"变成"可用的直觉"的唯一途径。大模型研究入门最大的陷阱不是算力不足，而是只读不做。

10 术语表

1. Self-Attention（自注意力）：序列内部任意两位置直接计算相关性并加权聚合的机制，Transformer 的核心。
2. MHA / MQA / GQA / MLA：多头注意力及其 KV 压缩变体族：全量 K/V、单组共享、分组共享、低秩潜在压缩。
3. KV cache：自回归推理时缓存的历史 token 的键值对，决定推理显存与带宽开销。
4. FFN（前馈网络）：Transformer 块内逐位置的两层 MLP，承担约 2/3 参数，被认为是知识存储单元。
5. SwiGLU：带门控分支的 Swish 激活 FFN 变体，现代开源 LLM 标准配置。
6. Pre-Norm / RMSNorm：残差前归一化与均方根归一化，深层 Transformer 稳定训练的关键组合。
7. RoPE（旋转位置编码）：对 Q/K 施加与位置成正比的二维旋转，使注意力分数只依赖相对位置的编码方案。
8. ALiBi：在注意力分数上叠加与距离成正比的线性惩罚的位置方案，外推性好。
9. YaRN：按频率分组对 RoPE 做差异化插值的长上下文扩展方法。
10. FlashAttention：通过 SRAM 分块与在线 softmax 避免物化注意力矩阵的 IO 感知精确算法。
11. MoE（混合专家）：用路由网络把每个 token 分派给少数专家子网络，稀疏激活以解耦参数量与计算量。
12. ViT（Vision Transformer）：把图像切成 patch 序列直接过 Transformer 的视觉骨干。
13. CLM / MLM：因果语言建模（从左到右预测下一 token）与掩码语言建模（双向预测被遮盖 token）两大预训练目标。
14. Scaling Law：损失随参数/数据/算力呈幂律变化的经验规律，用于预测与分配训练预算。
15. Chinchilla 最优：参数与 token 数同比扩展（约 20 token/参数）的计算最优训练点。
16. SFT（监督微调）：用示范数据对预训练模型做指令跟随微调，对齐管线第一步。

17. Reward Model (奖励模型): 从人类偏好排序中学到的标量评分函数, RLHF 的奖励来源。
18. PPO: 用 clipped surrogate objective 约束更新幅度的 on-policy 强化学习算法, 经典 RLHF 的优化器。
19. DPO: 把偏好学习闭式化为监督式分类损失的对齐方法, 无需奖励模型与在线 RL。
20. GRPO / RLVR: 去掉 critic、用组内相对奖励构造优势的 RL 算法, 与程序化可验证奖励结合激发推理能力。

11 参考文献

- [1]] Attention Is All You Need, Vaswani et al., 2017, arXiv:1706.03762, <https://arxiv.org/abs/1706.03762>
- [2]] Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer, Shazeer et al., 2017, arXiv:1701.06538, <https://arxiv.org/abs/1701.06538>
- [3]] Proximal Policy Optimization Algorithms, Schulman et al., 2017, arXiv:1707.06347, <https://arxiv.org/abs/1707.06347>
- [4]] Fast Transformer Decoding: One Write-Head is All You Need, Shazeer, 2019, arXiv:1911.02150, <https://arxiv.org/abs/1911.02150>
- [5]] Scaling Laws for Neural Language Models, Kaplan et al., 2020, arXiv:2001.08361, <https://arxiv.org/abs/2001.08361>
- [6]] Training Compute-Optimal Large Language Models, Hoffmann et al., 2022, arXiv:2203.15556, <https://arxiv.org/abs/2203.15556>
- [7]] Training language models to follow instructions with human feedback, Ouyang et al., 2022, arXiv:2203.02155, <https://arxiv.org/abs/2203.02155>
- [8]] RoFormer: Enhanced Transformer with Rotary Position Embedding, Su et al., 2021, arXiv:2104.09864, <https://arxiv.org/abs/2104.09864>
- [9]] Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity, Fedus et al., 2021, arXiv:2101.03961, <https://arxiv.org/abs/2101.03961>
- [10]] Train Short, Test Long: Attention with Linear Biases Enables Input Length Extrapolation, Press et al., 2021, arXiv:2108.12409, <https://arxiv.org/abs/2108.12409>
- [11]] GLaM: Efficient Scaling of Language Models with Mixture-of-Experts, Du et al., 2021, arXiv:2112.06905, <https://arxiv.org/abs/2112.06905>
- [12]] FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness, Dao et al., 2022, arXiv:2205.14135, <https://arxiv.org/abs/2205.14135>
- [13]] LLaMA: Open and Efficient Foundation Language Models, Touvron et al., 2023, arXiv:2302.13971, <https://arxiv.org/abs/2302.13971>
- [14]] Direct Preference Optimization: Your Language Model is Secretly a Reward Model, Rafailov et al., 2023, arXiv:2305.18290, <https://arxiv.org/abs/2305.18290>
- [15]] Llama 2: Open Foundation and Fine-Tuned Chat Models, Touvron et al., 2023, arXiv:2307.09288, <https://arxiv.org/abs/2307.09288>
- [16]] GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints, Ainslie et al., 2023, arXiv:2305.13245, <https://arxiv.org/abs/2305.13245>
- [17]] FlashAttention-2: Better Attention with Better Parallelism and Work Partitioning, Dao, 2023, arXiv:2307.08691,

- <https://arxiv.org/abs/2307.08691>
- [18]] YaRN: Efficient Context Window Extension of Large Language Models, Peng et al., 2023, arXiv:2309.00071, <https://arxiv.org/abs/2309.00071>
 - [19]] Mistral 7B, Jiang et al., 2023, arXiv:2310.06825, <https://arxiv.org/abs/2310.06825>
 - [20]] Mixtral of Experts, Jiang et al., 2024, arXiv:2401.04088, <https://arxiv.org/abs/2401.04088>
 - [21]] DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model, DeepSeek-AI, 2024, arXiv:2405.04434, <https://arxiv.org/abs/2405.04434>
 - [22]] Qwen2 Technical Report, Yang et al., 2024, arXiv:2407.10671, <https://arxiv.org/abs/2407.10671>
 - [23]] DeepSeek-V3 Technical Report, DeepSeek-AI, 2024, arXiv:2412.19437, <https://arxiv.org/abs/2412.19437>
 - [24]] DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning, DeepSeek-AI, 2025, arXiv:2501.12948, <https://arxiv.org/abs/2501.12948>
 - [25]] Insights into DeepSeek-V3: Scaling Challenges and Reflections on Hardware for AI Architectures, DeepSeek-AI, 2025, arXiv:2505.09343, <https://arxiv.org/abs/2505.09343>
 - [26]] From RLHF to Direct Alignment: A Theoretical Unification of Preference Learning for Large Language Models, 2026, arXiv:2601.06108, <https://arxiv.org/abs/2601.06108>
 - [27]] Position Encoding in Transformers: From Absolute and Relative Methods to Rotary Position Embeddings and Long-Context Scaling, 2026, arXiv:2608.10021, <https://arxiv.org/abs/2608.10021>
 - [28]] PaLM: Scaling Language Modeling with Pathways, Chowdhery et al., 2022, arXiv:2204.02311, <https://arxiv.org/abs/2204.02311>
 - [29]] An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale, Dosovitskiy et al., 2020, arXiv:2010.11929, <https://arxiv.org/abs/2010.11929>
 - [30]] Emergent Abilities of Large Language Models, Wei et al., 2022, arXiv:2206.07682, <https://arxiv.org/abs/2206.07682>
 - [31]] DeepSeekMoE: Towards Ultimate Expert Specialization in Mixture-of-Experts Language Models, DeepSeek-AI, 2024, arXiv:2401.06066, <https://arxiv.org/abs/2401.06066>
 - [32]] Speed Always Wins: A Survey on Efficient Architectures for Large Language Models, 2025, arXiv:2508.09834, <https://arxiv.org/abs/2508.09834>
 - [33]] A Survey on Multimodal Large Language Models, Yin et al., 2023, arXiv:2306.13549, <https://arxiv.org/abs/2306.13549>
 - [34]] Efficient Large Language Models: A Survey, Wan et al., 2023, arXiv:2312.03863, <https://arxiv.org/abs/2312.03863>
 - [35]] A Survey of Generative Categories and Techniques in Multimodal Generative Models, 2025, arXiv:2506.10016, <https://arxiv.org/abs/2506.10016>