
多模态大模型系列报告

听见与开口：音频语音多模态大模型

从自监督表征到全双工对话——语音如何被”听见”、被”说出”、被”理解”

多模态大模型系列报告

2026-09-29

本报告为系列技术综述，内容基于公开论文整理，仅供学习研究使用。

目录

1	引言：本方向在多模态版图中的位置	4
1.1	为什么语音是”最像文本”的非文本模态	4
1.2	学习地图	4
1.3	本报告的核心问题	5
2	基础知识	5
2.1	音频信号的数字化：从波形到谱图	5
2.2	传统语音管线：被深度化前后	6
2.3	自监督语音表征：对比与掩码预测	6
2.4	矢量量化与 RVQ：把声音变成 token（重点）	7
2.5	离散 token 上的语言建模与 flattening 问题	8
3	经典方法谱系	8
3.1	关键论文一览表	9
4	代表作深度剖析	10
4.1	Whisper：用规模碾过领域偏移（OpenAI, 2022）	11
4.2	SoundStream 与 EnCodec：把声音压成 token（Google 2021 / Meta 2022）	11
4.3	VALL-E：TTS 的语言模型化与 NAR+AR flattening（Microsoft, 2023）	12
4.4	Qwen2-Audio：语音理解 LLM 的开源标杆（Alibaba, 2024）	14
4.5	Moshi：全双工语音对话的完整开源答卷（Kyutai, 2024）	14
5	研究前沿（2025-2026）	16
5.1	全双工与实时对话成为主战场	16
5.2	Omni 化：语音并入全模态主干	16
5.3	TTS 的流式化与生产化	16
5.4	Codec 的语义化、低帧率化与统一化	16
5.5	评测体系成型与可信性议题	17
6	技术路线对比与权衡	17
6.1	三组根本分野	17
6.2	flattening 模式横向对比	18
7	开放问题与未来方向	18

8 研究机会点评（给入门研究者的建议）	19
9 术语表	19
10 参考文献	21

摘要 音频与语音是多模态大模型版图中最特殊的一块拼图：它既是输入模态（让模型“听见”），又是输出模态（让模型“开口”），还天然承载语言内容，与文本 LLM 的关系比任何其他模态都更纠缠。本报告以一条清晰的技术演化主线组织这一领域：**语音表征学习**（wav2vec 2.0 的对比式自监督、HuBERT 的掩码预测式自监督）解决了“没有标注怎么学语音表示”的问题；**Whisper** 用 68 万小时弱标注数据证明了“规模化的弱监督”可以压过精巧的自监督，成为事实上的 ASR 基座与众多 audio-LLM 的听觉前端；**神经音频 codec**（SoundStream、EnCodec、SpeechTokenizer）用残差矢量量化（RVQ）把连续波形压缩成离散 token 序列，使“对声音做语言建模”成为可能——本报告将完整推导 RVQ 的数学原理与码率-质量权衡；在此之上，**AudioLM/MusicLM** 开创了 semantic token + acoustic token 分层生成的音频语言模型范式，**VALL-E** 把 TTS 改写成 codec token 上的条件语言建模（AR 首层 + NAR 其余层的 flattening 模式是本报告重点之一）；**Qwen-Audio/Qwen2-Audio**、**SALMONN** 把音频编码器接入 LLM，实现语音指令理解；最终，**GPT-4o voice** 与 **Moshi** 把语音对话从“ASR→LLM→TTS 三段式管线”推进到端到端、全双工、200 毫秒级延迟的实时交互。报告对 Whisper、SoundStream/EnCodec、VALL-E、Qwen2-Audio、Moshi 五篇（组）代表作做深度剖析，系统对比 cascade 与 end-to-end、semantic token 与 acoustic token、连续表征与离散 token 三组根本分野，并讨论全双工、流式 TTS、codec-LM 统一建模等 2025-2026 前沿与入门研究机会。

1 引言：本方向在多模态版图中的位置

1.1 为什么语音是“最像文本”的非文本模态

在视觉-语言方向（见本系列第 1 篇），核心难题是“两种异构模态如何对齐”：图像是二维连续信号，文本是一维离散符号，二者之间隔着巨大的表示鸿沟，需要 CLIP 式的对比学习或 connector 模块去搭桥。语音与文本的关系则完全不同——**语音在本质上就是“被声学化的文本”**。一句话的语音信号里同时编码了三个层次的信息：

1. **语言内容 (linguistic content)**：说了什么字、什么词、什么句——这一层与文本几乎一一对应；
2. **副语言信息 (paralinguistics)**：谁在说（音色）、怎么说（韵律、语速、情绪）；
3. **非语言声音 (non-speech audio)**：环境声、音乐、笑声、叹息——它们不对应任何文字，却强烈影响语义。

这带来语音方向的独特张力：一方面，语音 → 文本的映射（ASR）和文本 → 语音的映射（TTS）都是定义良好的经典任务，各自有半个世纪的积累；另一方面，“把语音当作 LLM 的一种输入输出模态”要求模型同时保留这三层信息，而传统的 ASR/TTS 管线恰恰会系统性地丢弃第 2、3 层。GPT-4o 的原生语音对话之所以震撼，正是因为它在交互中保留了情感与副语言线索——这是级联管线在原理上做不到的。

1.2 学习地图

阅读本方向需要的前置概念与推进路径如下：

已有基础（读者已会）本方向核心概念 通向

CNN / RNN / Transformer → 音频信号处理（STFT、mel 谱）→ Whisper、codec 编码器

自监督学习（对比学习、

masked prediction）→ wav2vec 2.0 / HuBERT → semantic token

VQ-VAE → RVQ、神经音频 codec → acoustic token

自回归语言建模 → codec token 上的 LM → AudioLM / VALL-E / Moshi

多模态 connector → 音频编码器 + adapter 接 LLM → Qwen2-Audio / SALMONN

本方向与其他方向的关系：语音理解 LLM 在架构上是 vision-language 的”音频版”（编码器 + projector + LLM）；TTS 的 LM 化与图像生成的 token 化（见 generation 篇）互为镜像；端到端语音对话与 omni 全模态模型（见 omni 篇）在 2025 年后几乎合流——Qwen2.5-Omni、Qwen3-Omni 已把语音从独立方向并入统一多模态主干。

1.3 本报告的核心问题

全篇围绕三个问题展开：

- **Q1 (表示)**: 连续、冗余、变长的音频信号，应该被表示成什么形式，才能被 Transformer/LLM 消化？——连续表征（wav2vec2/HuBERT/Whisper 编码器输出）与离散 token（codec code）两条路线的根本分野。
- **Q2 (生成)**: 给定文本或上文音频，如何生成自然、可控、可流式输出的语音？——codec-LM 范式、flattening 模式、NAR 加速与流匹配解码。
- **Q3 (交互)**: 如何让模型在”听懂”之上实现接近人类的实时对话？——端到端 vs 级联、全双工多流建模、延迟工程。

2 基础知识

2.1 音频信号的数字化：从波形到谱图

声音是空气压力随时间的变化，麦克风把它变成连续电压信号 $x(t)$ 。数字化需要两步：**采样**（sampling）以固定频率 f_s 离散化时间轴（电话语音 8 kHz、宽带语音 16 kHz、音乐与高质量合成 24/44.1/48 kHz），**量化**把振幅离散为有限精度（16-bit PCM 可表示 65536 级）。根据 Nyquist 定理，采样率必须高于信号最高频率的两倍。

原始波形对神经网络并不友好：16 kHz 采样意味着每秒 16000 个采样点，一分钟音频就是近百万维的序列。工程上的标准做法是短时傅里叶变换（STFT）：把波形切成 20–30 ms 的交叠帧，对每帧做傅里叶变换得到频谱，再按人耳感知的非线性频率刻度（mel 刻度）压缩为 80–128 个频带，得到 **log-mel 谱图**（log-mel spectrogram）。Whisper 的输入就是 80 维 log-mel 谱，帧移 10 ms，即每秒 100 帧。这个”谱图作为图像”的视角，使得为视觉设计的 CNN/Transformer 可以直接搬到音频上——这也是 2015 年后深度学习语音革命的入口。

2.2 传统语音管线：被深度化前后

经典 ASR 是一个复杂的多组件系统：声学模型 (HMM-GMM, 后为 DNN) 给出音素后验、发音词典做音素到词的映射、语言模型约束词序列。深度学习把每个组件逐步替换为神经网络，最终端到端化：CTC、RNN-T、attention encoder-decoder。到 Whisper 出现前，端到端 ASR 在学术基准（如 LibriSpeech）上已很强，但**换领域就崩**——LibriSpeech 上 WER 2% 的模型面对真实会议、口音、噪声时性能暴跌。理解这一点，才能理解 Whisper 的 motivation：问题不在架构，在数据分布。

TTS 的演化与之平行：拼接合成 → 统计参数合成 → 两阶段神经 TTS (Tacotron 类模型生成 mel 谱 + WaveNet/HiFi-GAN 类声码器合成波形)。两阶段范式在 2022 年前是主流，其痛点在于：mel 谱是手工设计的中间表示，声码器与声学模型误差累积，且模型容量被“逐帧回归连续谱图”的目标函数限制。codec-LM 范式正是对这一痛点的回应（见 §4.3）。

2.3 自监督语音表征：对比与掩码预测

语音标注昂贵（转写一分钟音频需熟练标注员数分钟），而无标注音频近乎无限——这是自监督学习的理想土壤。

wav2vec 2.0 (Meta, 2020) 的思路是把 BERT 式预训练和对比学习结合起来。模型由三部分组成：卷积特征编码器把波形下采样为每 20 ms 一帧的隐表示 z_t ；Transformer 上下文网络产出上下文化表示 c_t ；一个量化模块把 z_t 映射为离散编码 q_t （用 Gumbel-softmax 在多个码本组上选择条目并拼接）。训练时随机 mask 掉一部分时间步，让模型在 c_t 上从 K 个干扰项中挑出正确的量化目标 q_t ，对比损失为：

$$\mathcal{L}_m = -\log \frac{\exp(\text{sim}(c_t, q_t)/\kappa)}{\sum_{\tilde{q} \sim Q_t} \exp(\text{sim}(c_t, \tilde{q})/\kappa)} + \alpha \mathcal{L}_d$$

其中 $\mathcal{L}_d$ 是码本多样性正则，防止码本坍塌。效果惊人：在 53k 小时无标注 Libri-Light 上预训练后，**仅用 10 分钟**标注微调即可在 LibriSpeech 上取得 4.8/8.2 的 WER (clean/other)，用全部 960h 标注微调达到 1.8/3.3——论文摘要直接宣称“10 分钟标注的语音识别是可行的”。

HuBERT (Meta, 2021) 走了另一条路：不对比，而是**预测离线聚类标签**。先用 MFCC 特征做 k-means (100 类) 得到伪标签，模型对 mask 区域做 BERT 式交叉熵预测；训练一轮后再用模型自身的中间层特征重新聚类、重新训练，迭代两到三轮。其关键设计是**只对 mask 区域计算损失**——这迫使模型同时学习声学模型与“语言模型”（对未 mask 上下文的利用）。HuBERT 证明了语音自监督不依赖对比目标也能达到甚至超过 wav2vec 2.0：1B 参数版本在 dev-other/test-other 上相对 WER 降低达 19%/13%。

对初学者而言，两者的差异比相似更重要：wav2vec 2.0 的量化目标是**与模型联合学习的**（端到端，但有坍塌风险，需要多样性正则），HuBERT 的目标是**外部、迭代改进的**（训练更稳定，且目标天然就是“语义化”的音素级单元）。后者为什么重要？因为 HuBERT 的 k-means 标签后来被发现近似对应音素/子词单元——**这就是 semantic token (语义 token) 的源头**。AudioLM、SpeechTokenizer、VALL-E 之后的整个 codec-LM 世界，都建立在“语音可以被离散化成近似语言的符号序列”这一 HuBERT 式发现之上。

2.4 矢量量化与 RVQ：把声音变成 token（重点）

VQ-VAE 回顾。 矢量量化 (VQ) 的思想：编码器输出连续向量 z ，用码本 $C = \{e_1, \dots, e_K\}$ 中最近邻的码字替换它：

$$q(z) = e_k, \quad k = \arg \min_j \|z - e_j\|_2$$

量化不可导，训练时用 straight-through estimator（前向用 $q(z)$ ，反向把梯度原样拷贝给 z ），并加 commitment loss $\|z - \text{sg}[q(z)]\|^2$ 让编码器输出向码字靠拢。单一码本的问题：要无损刻画音频这种高信息密度信号，码本大小 K 需指数增长—— K 个码字只能区分 $\log_2 K$ bit 信息。1024 大小的码本每帧只提供 10 bit，对高质量音频远远不够。

RVQ：用”残差”换指数级容量。 SoundStream (2021) 把 RVQ 引入神经音频 codec，这是本方向最重要的工具之一，值得完整推导。思想类似矢量量化版的”梯度提升”：第一层量化器捕捉粗结构，后续每层只量化前一层的**残差**：

$$\begin{aligned} r_0 &= z \\ \hat{z}_1 &= Q_1(r_0), \quad r_1 = r_0 - \hat{z}_1 \\ \hat{z}_2 &= Q_2(r_1), \quad r_2 = r_1 - \hat{z}_2 \\ &\vdots \\ \hat{z} &= \sum_{i=1}^{N_q} \hat{z}_i = \sum_{i=1}^{N_q} Q_i(r_{i-1}) \end{aligned}$$

每个时间步 t 因此由 N_q 个离散 code ($c_t^1, c_t^2, \dots, c_t^{N_q}$) 表示， $c_t^i \in \{1, \dots, K\}$ 。**信息容量是乘法的：总码率**

$$R = f_r \cdot N_q \cdot \log_2 K \quad (\text{bit/s})$$

其中 f_r 是帧率。以 EnCodec 24 kHz 模型为例：编码器下采样 320 倍， $f_r = 75$ Hz；每个量化器码本 $K = 1024$ (10 bit)；用 8 个量化器时 $R = 75 \times 8 \times 10 = 6$ kbps，而 32 个量化器对应 24 kbps。对比：原始 24 kHz/16-bit 音频是 384 kbps，压缩率 16–256 倍。SoundStream 用 3–18 kbps 可变码率训练（对量化器层做 structured dropout，随机只用前 k 层），单模型覆盖全码率段；在 3 kbps 时主观质量超过 12 kbps 的 Opus、接近 9.6 kbps 的 EVS——而 Opus/EVS 是数十年手工信号处理的结晶。

为什么 RVQ 对 LM 如此关键？ 三点：其一，RVQ 把音频变成**离散符号序列**，天然适配 softmax 交叉熵训练的语言模型；其二，分层残差结构制造了**重要性排序**——第 1 层 code 承载大致内容（响度、基频、粗谱形），越往后越是细节（谐波纹理、相位近似），这为”先生成粗、后生成细”的层级生成 (AudioLM) 和”只建模第 1 层、其余 NAR 补全” (VALL-E) 提供了结构基础；其三，码率可调意味着可以在”LM 可建模的序列长度”与”重建保真度”之间做显式权衡。

EnCodec (Meta, 2022) 是 SoundStream 的工业级改进版：流式卷积 encoder-decoder、单一多尺度谱图判别器（替代 SoundStream 的多判别器，简化训练且减少伪影）、以及一个 loss

balancer (让各损失项按其权重占据总梯度的固定份额, 解耦超参与损失尺度)。EnCodec 证明 24 kHz 单声道、乃至 48 kHz 立体声都能高保真压缩, 且可用一个小型 Transformer 对已量化 token 再无损压缩约 40%。它随后成为 LLM 时代事实标准的 **acoustic tokenizer**: VALL-E、AudioGen、MusicGen 及大量后续工作直接冻结 EnCodec 作为音频的“分词器”。

Semantic vs acoustic token 的裂痕与弥合。 RVQ codec 的 code 为保真而生, 捕捉的是声学细节而非语言内容——实验表明其第 1 层与文本的对齐很弱。反过来, HuBERT/WavLM 特征 k-means 得到的 semantic token 与音素/文本强对齐, 却丢失了音色与声学细节, 无法直接重建高质量语音。**SpeechTokenizer** (2023) 提出统一方案: 在 RVQ codec 框架内, 用语义教师 (HuBERT) 对第 1 个量化层的输出做蒸馏 (如 cosine 相似度损失), 使第 1 层承载语义、其余层补声学残差——“第一层即语义”的分层解耦。CosyVoice (2024) 则给出更工程化的答案: 直接在 ASR 编码器中插入矢量量化, 用 ASR 监督信号训出“监督式 semantic token”, 与文本对齐更好、内容一致性更强。Moshi 的 Mimi codec 同样在第 1 层蒸馏 WavLM 语义。到 2024 年, “RVQ 第 1 层语义化”已成为 codec 设计的共识。

2.5 离散 token 上的语言建模与 flattening 问题

有了 codec token, 音频生成就变成了“对离散序列做语言建模”。但 RVQ 给每帧 N_q 个 code, 序列是二维的: 时间维 $T \times$ 层维 N_q 。如何用自回归 LM 建模 $p(c_{1:T}^{1:N_q})$? 这就是 **flattening (展平) 模式**问题, 本方向的核心设计空间之一。主要方案:

1. **层级/两阶段 (AudioLM)**: 先生成 semantic token (序列短、结构稳定), 再以 semantic token 为条件生成 acoustic token。每个阶段是一维序列, 简单但管线长、误差逐阶段传播。
2. **逐帧内层间展平 (VALL-E 的 NAR+AR, 重点, 见 §4.3)**: 时间上自回归, 每帧内部第 1 层用 AR、其余层用并行的 NAR——牺牲一点层间依赖换 7 倍序列长度缩减。
3. **分组并行 (VALL-E 2 的 Grouped Code Modeling)**: 把 N_q 层分为若干组, 组内并行、组间自回归, 进一步压缩序列。
4. **多流/延迟交错 (MusicGen、Moshi)**: 各层并行预测, 但第 i 层相对第 1 层延迟 $i-1$ 步 (delay pattern), 用浅层依赖换取完全并行的低延迟流式生成。
5. **放弃离散层, 回归连续 (CosyVoice 的 flow matching)**: LM 只生成第 1 层 semantic token, 声学细节交给条件流匹配 (conditional flow matching) 在连续空间生成 mel 谱, 再由声码器出波形——把“难建模的高码率残差”外包给连续生成模型。

这五种模式构成 §4–§6 反复出现的骨架。

3 经典方法谱系

音频语音多模态的演化可以概括为四次范式转移:

第一次 (2020–2021): 自监督表征取代标注数据。 wav2vec 2.0、HuBERT 把语音从“标注饥渴”中解放出来, 确立了“大规模无标注预训练 + 少量标注微调”的范式, 与 NLP 的 BERT 时刻对应。

第二次 (2021–2022): codec 与弱监督双轨确立。 SoundStream/EnCodec 证明神经网络

可以把通用音频压到个位数 kbps 且高保真，给出了”声音 token 化”的工具；Whisper 则反其道而行，用 68 万小时弱标注数据做监督学习，证明规模可以弥补标注噪声。二者分别奠定了”生成侧”与”理解侧”的基础设施。

第三次（2022–2024）：音频的 LM 化。 AudioLM 首次把音频续写做成纯 LM 任务；VALL-E 把 TTS 改写为条件 codec LM 并涌现 in-context 声音克隆；MusicLM 扩展到音乐；Qwen-Audio、SALMONN 把音频接入 LLM 实现通用听觉理解；CosyVoice 把 TTS 推向流式生产。

第四次（2024–2026）：端到端对话与 omni 合流。 GPT-4o 确立原生语音对话的产品标杆；Moshi 以开源方式完整给出全双工技术方案；Qwen2.5-Omni/Qwen3-Omni 把语音并入统一全模态主干，”speech 只是 omni 的一种模态”。

3.1 关键论文一览表

论文	年份	核心思想	架构要点	备注
wav2vec 2.0 [1]	2020	对比式自监督 + 量化目标	CNN 编码器 + Transformer + Gumbel 量化	10 分钟标注 微调即可用
HuBERT [2]	2021	掩码预测离线聚类标签	BERT 式 MLM，迭代聚类	semantic token 的源头
SoundStream [3]	2021	RVQ 神经 codec	全卷积 + RVQ，3–18 kbps 可变码率	codec token 技术起点
Whisper [4]	2022	68 万小时弱监督规模化	标准 encoder-decoder Transformer	鲁棒 ASR 基座，零微调迁移
EnCodec [5]	2022	高保真流式 codec	单判别器 + loss balancer	LLM 时代标准 acoustic tokenizer
AudioLM [6]	2022	semantic+acoustic 分层 LM	w2v-BERT token → SoundStream token	语音 LM 范式开山
VALL-E [7]	2023	TTS = 条件 codec LM	AR 第 1 层 + NAR 其余层	3 秒 prompt 零样本克隆
MusicLM [8]	2023	文本条件音乐生成	层级 seq2seq，24 kHz	发布 MusicCaps 数据集
AudioPaLM [9]	2023	语音文本统一词表	PaLM 系，听说一体	统一建模的早期尝试
SpeechTokenizer [10]	2023	语义蒸馏统一 token	RVQ 第 1 层蒸馏 HuBERT	SLMTokBench 基准
SALMONN [11]	2023	双编码器通用听觉	Whisper + BEATs → Vicuna	ICLR 2024 Spotlight

论文	年份	核心思想	架构要点	备注
Qwen-Audio [12]	2023	30+ 任务多任务预训练	单音频编码器 + Qwen-7B	中文开源代表
VALL-E 2 [13]	2024	分组 codec 建模 + 重复感知采样	Grouped Code Modeling	宣称零样本 TTS 人类水平
CosyVoice [14]	2024	监督 semantic token + flow matching	LLM 生 token，流匹配出谱	工程化开源 TTS
Qwen2-Audio [15]	2024	语音聊天 + 音频分析双模式	Whisper 系编码器 + Qwen-7B，DPO	AIR-Bench 超 Gemini-1.5-pro
Mini-Omni [16]	2024	文本-音频并行流式生成	”边想边说”	开源流式先驱
LLaMA-Omni [17]	2024	低延迟 speech-to-speech	编码器 +adapter 直连 LLaMA + NAR 解码	
Moshi [18]	2024	全双工多流建模	Mimi codec + 双通道 + Inner Monologue	理论延迟 160 ms，全开源
GPT-4o System Card [19]	2024	原生端到端语音	未公开细节	范式标志，非技术论文
Freeze-Omni [20]	2024	冻结 LLM 主干训语音层	模态适配器方案	低算力可行路径
CosyVoice 2 [21]	2024	流式 TTS	FSQ + 分块因果流匹配	首包延迟 200 ms 级
Step-Audio [22]	2025	130B 级统一理解-生成	多模态大模型框架	中文团队旗舰
Qwen2.5-Omni [23]	2025	Thinker-Talker 解耦 + TMRoPE	双轨 AR Talker，流式 DiT 声码	omni 合流标志
Kimi-Audio [24]	2025	1300 万小时音频预训练	通用 audio foundation model	覆盖 ASR/AQA/TTS/对话
Qwen3-Omni [25]	2025	MoE omni，多语言流式对话		2025 末开源全模态旗舰

4 代表作深度剖析

本节深读五篇（组）：Whisper（理解侧基座）、SoundStream/EnCodec（codec 与 RVQ）、VALL-E（codec-LM 的 flattening 典范）、Qwen2-Audio（语音理解 LLM）、Moshi（全双工端到端对话）。选择理由：它们分别回答了 §1.3 的 Q1/Q2/Q3，且组合起来恰好覆盖了”连续表征 vs 离散 token”的根本分野。

4.1 Whisper: 用规模碾过领域偏移 (OpenAI, 2022)

研究问题。2022 年的 ASR 存在一个尴尬的鸿沟: 学术基准上接近人类的模型, 面对真实世界的口音、噪声、混响、专业术语时脆弱不堪。根本原因是训练数据——主流系统只用几千小时的“干净朗读”语料 (LibriSpeech 960h、Common Voice 数千小时), 分布太窄。OpenAI 的问题是: 能否不设计任何新架构, 纯粹靠数据规模与多样性解决鲁棒性?

关键洞察。互联网上存在海量自带字幕的音频 (播客、视频、有声书), 转写质量参差但信号真实。与其继续精巧地自监督, 不如把这些弱标注数据“全部吃下”——当一个编码器-解码器见过 68 万小时、96 种语言、各种噪声环境的音频后, 鲁棒性会成为数据规模的副产品。这是对“标注噪声是否致命”这一经典问题的实证回答: 在 68 万小时量级上, 噪声标注的坏处被多样性带来的分布覆盖所淹没。

技术方法。架构刻意平庸: 标准 Transformer encoder-decoder (log-mel 谱输入 80 维、30 秒定长窗口), 模型从 39M (tiny) 到 1550M (large) 参数五个规格。创新全在数据与任务格式:

- **数据:** 680,000 小时多语言、多任务音频-文本对, 其中约 1/3 为非英语。配套自动清洗流水线 (如用语言检测、启发式规则剔除机器生成的字幕)。
- **多任务格式:** 用特殊 token 在解码器开头指定任务——<|transcribe|> 转写、<|translate|> 翻译成英语、语言标记、<|notimestamps|> 等。单一模型因此同时是 ASR、语音翻译、语言识别、时间戳对齐器。
- **零样本评测哲学:** 论文刻意不在任何基准上微调, 全部 zero-shot, 以检验“真正的分布外泛化”。

实验结果。Whisper-large 在无任何微调的情况下, 在多数英文基准上与此前全监督 SOTA 相当, 鲁棒性测试 (跨数据集评估) 大幅领先——论文标题“Robust Speech Recognition via Large-Scale Weak Supervision”即结论。多语言方面, 低资源语言的 WER 仍偏高, 但与监督数据量呈可预测的 scaling 关系。对人类的对比上, 论文声称模型“接近人类的准确性与鲁棒性”。

批判性分析。优点: 重新定义了 ASR 的问题设定 (从“拟合基准”转向“真实世界泛化”); 开源权重 + 推理代码使其成为整个社区的免费基础设施——今天几乎所有 audio-LLM (Qwen-Audio、SALMONN、Moshi 的 ASR 头) 都以 Whisper 或其变体为听觉前端, 这是论文最大的实际影响。局限: 其一, 训练数据未公开, “68 万小时”无法复现, 学术界只能通过蒸馏 (Distil-Whisper) 或自行收集弱标注追赶; 其二, 逐字转写目标丢弃了全部副语言信息, Whisper 表示更偏“内容”, 对情感/说话人任务并非最优; 其三, 30 秒定长窗口与自回归解码导致长音频需要滑窗拼接, 长上下文一致性一般, 且 autoregressive 解码有重复/幻觉转写问题 (在无声段“编”出字幕的现象有据可查)。可复现性: 推理完全可复现, 训练不可复现。

一句话评价: 语音界的“GPT-2 时刻”——架构零创新、数据定胜负, 其真正遗产是成为万物皆可插的听觉前端。评级: ★★★★★ (里程碑)。

4.2 SoundStream 与 EnCodec: 把声音压成 token (Google 2021 / Meta 2022)

研究问题。数字音频压缩是通信的老问题: Opus、EVS 等标准编解码器基于数十年手工信号处理, 在低码率 (<10 kbps) 下对通用音频 (尤其音乐) 质量骤降。更根本的动机在 2020 年后才显影: 如果要把音频放进语言模型, 必须先把它离散化成 token——传统 codec 的码流不是为“被

Transformer 建模"设计的。SoundStream 要回答：端到端学习的神经 codec 能否在 3–18 kbps 这种"语音专用码率"上压缩通用音频并打败手工标准？

关键洞察。两个：(1) RVQ 是让 VQ 扩容的正确方式——单码本容量瓶颈用残差分层破解（推导见 § 2.4），且残差结构自带"粗到细"的重要性排序；(2) 感知质量应该由判别器保证而不是手工 loss——把 TTS/语音增强里成熟的"重建 loss + 对抗 loss"组合搬到 codec，让 GAN 判别器充当可学习的感知度量。

技术方法（SoundStream）。全卷积 encoder-decoder：编码器把波形逐层下采样到帧率约 75 Hz 的隐表示，经 N_q 层 RVQ 量化，解码器对称上采样回波形。训练目标三项：时频域重建损失（多分辨率 mel 距离）、对抗损失（波形域 + 谱域判别器）、码本 commitment loss。两个杀手级设计：quantizer dropout——训练时随机只保留前 k 层量化器，使单模型支持 3–18 kbps 任意码率（低层先学粗结构，天然兼容残差语义）；可流式——全部因果卷积，可在手机 CPU 实时运行且支持低延迟流式推理。

技术方法（EnCodec 的改进）。Meta 团队把 SoundStream 工程化：用单一多尺度 STFT 判别器（在多个 STFT 分辨率上各一个判别头）替代多判别器，简化训练并有效抑制伪影；提出 loss balancer——不再给每个 loss 一个固定权重，而是规定每个 loss 占总梯度的目标份额，用在线归一化实现，解耦了"loss 权重"与"loss 尺度"这对纠缠的超参；系统性研究了 24 kHz 单声道与 48 kHz 立体声、1.5–24 kbps 的全码率段，并演示了用小型 Transformer 对量化 token 做熵编码可再压缩约 40%（这已经预告了"codec token 天然适合 LM 建模"）。MUSHRA 主观评测显示其在所有评测设置下超过基线。

实验结果。SoundStream：24 kHz 音频上 3 kbps 主观质量超过 12 kbps Opus、接近 9.6 kbps EVS——4 倍码率优势；且同一权重覆盖全码率段。EnCodec：24 kHz/6 kbps 取得接近透明的语音重建，音乐与通用音频同样成立；后续成为 VALL-E、MusicGen、AudioGen 的官方 tokenizer。度量上需要注意：codec 质量的黄金标准是主观听测（MUSHRA/MOS），客观指标（PESQ、STOI、ViSQOL）仅作参考——这是评估音频生成时初学者最易踩的坑。

批判性分析。优点：方法论干净、工程完成度极高，EnCodec 开源后成为社区标准件，其"冻结 codec 当音频分词器"的用法定义了整个 codec-LM 子领域。局限：其一，RVQ code 为保真而非语义设计，token 序列长度长（6 kbps 下 75 帧/秒 $\times$ 8 层 = 每秒 600 个 code），直接全层 LM 建模代价高——这逼出了 VALL-E 的 NAR 折中；其二，GAN 训练不稳定、对伪影敏感，训练 codec 至今仍是"手艺活"；其三，codec 是压缩器而非理解器，其 token 空间对语义任务（如直接做语音翻译）并不友好。可复现性：EnCodec 完全开源可复现；SoundStream 未开源但原理被多方复现（如社区版 AudioCraft 中的实现）。

一句话评价：没有 RVQ codec 就没有音频的"GPT 时刻"——它是把声波翻译成符号的那本词典。评级：★★★★★（基础设施级）。

4.3 VALL-E: TTS 的语言模型化与 NAR+AR flattening (Microsoft, 2023)

研究问题。2022 年前的零样本 TTS（给几秒钟参考音频克隆陌生说话人）被两阶段范式卡住：说话人编码器提取的嵌入向量对未见说话人泛化差，mel 回归目标限制了表现力上限。VALL-E 的问题：TTS 能否完全抛弃"声学模型 + 声码器"管线，改写成纯粹的条件语言建模？

关键洞察。一旦 EnCodec 把语音变成离散 token，TTS 就和机器翻译在形式上没有任何区别：源序列是文本（音素）token，目标序列是 codec token。于是 LLM 的两件武器——大规模

语料预训练与 in-context learning——可以直接搬过来。VALL-E 把训练数据从此前系统的几百小时一举扩到 60,000 小时 (LibriLight) 英文语音, 比当时最大 TTS 系统大两个数量级; "3 秒注册音频" 不再是提取说话人嵌入, 而是作为声学 prompt 前缀拼进解码上下文——声音克隆变成了 GPT 式的 in-context 续写。

技术方法 (flattening 模式, 本报告重点)。设 EnCodec 8 层 RVQ 的 token 矩阵为 $C \in \{1..K\}^{T \times 8}$ 。VALL-E 的条件概率分解为:

$$p(C | x) = \underbrace{\prod_{t=1}^T p(c_t^1 | c_{<t}^1, x)}_{\text{AR: 第 1 层, 逐帧自回归}} \times \underbrace{\prod_{t=1}^T \prod_{i=2}^8 p(c_t^i | c_t^{<i}, C_{<t}, x)}_{\text{NAR: 第 2-8 层, 帧内逐层、帧间并行}}$$

即两个模型的分工:

- AR 模型: 只建模第 1 层 (每帧 1 个 code、75 token/秒), 输入为音素序列 x 与 prompt 音频的第 1 层 token, 自回归生成目标语音的第 1 层序列。第 1 层承载内容与粗声学结构, 是"最难也最关键"的序列——值得用完整自回归。
- NAR 模型: 条件于完整第 1 层 + 文本 + prompt, 逐层 (第 2 层条件于第 1 层, 第 3 层条件于 1-2 层……) 但层内所有时间步并行预测。因为第 2-8 层只是残差细节, 层内的强条件 (同帧第 1 层已知) 使并行解码损失很小。

这个设计的精妙在于精确匹配 RVQ 的信息结构: 残差量化保证第 1 层信息量最大、后续层是条件易预测的细节, 因此"AR 只负责一层"几乎不损失质量, 却把自回归序列长度从 $8T$ 压到 T , 推理延迟下降近一个数量级。这是"利用数据结构先验来设计生成模式"的教科书案例, 与图像领域 MaskGIT 的 NAR 思路遥相呼应。

实验结果。在 LibriSpeech 与 VCTK 零样本设置下, VALL-E 的自然度 (CMOS) 与说话人相似度 (SMOS) 显著超过当时 SOTA 的零样本 TTS 系统 (YourTTS); 论文还展示了 prompt 的情感与声学环境 (如回声) 被保留到合成语音中——这是说话人嵌入管线无法做到的。后续 VALL-E 2 (2024) 用 Grouped Code Modeling (把 8 层分组并行, 进一步缩短序列) 与 Repetition Aware Sampling (在 nucleus sampling 中惩罚解码历史里的重复, 解决 AR 模型在长句/重复文本上的死循环) 宣称在 LibriSpeech/VCTK 上首次达到人类水平零样本 TTS。

批判性分析。优点: 范式意义巨大——此后三年几乎所有 TTS (包括工业界) 都转向 codec-LM 或其变体; in-context 克隆免去了说话人编码器训练, 优雅且强大。局限: 其一, 模型与权重均未开源 (仅 demo 页), 60k 小时数据与完整训练配方不可复现, 社区只能靠开源复现 (如 lifeiteng/vall-e、各类 open VALL-E) 逼近; 其二, AR 解码存在 codec-LM 的通病: 对长难句、重复短语会出现漏词、重复、陷入循环 (VALL-E 2 的 Repetition Aware Sampling 正是打这个补丁, 等于承认问题真实存在); 其三, NAR 层与 AR 层分离意味着非流式、两段推理, 且对 codec 质量完全依赖——EnCodec 换成本文其他 codec, 结论未必迁移; 其四, 零样本声音克隆的 deepfake 风险直接触发了后续 TTS 安全研究。可复现性: 弱 (闭源), 但思想已被广泛复现验证。

一句话评价: 把 TTS 从信号处理问题改写成 NLP 问题的分水岭; NAR+AR flattening 是近五年音频生成最被低估的设计。评级: ★★★★★ (范式级, 但闭源扣分)。

4.4 Qwen2-Audio: 语音理解 LLM 的开源标杆 (Alibaba, 2024)

研究问题。2023 年起, "给 LLM 装上耳朵" 成为显学: GPT-4 系列展示了语音交互的产品价值, 但开源社区缺少能听懂语音指令、分析环境声与音乐的通用模型。Qwen-Audio 系列的问题是: 如何让一个文本 LLM 以最小代价获得通用听觉 (语音 + 音频事件 + 音乐), 并且能直接用语音下指令?

关键洞察。与 vision-language 的演化同构: 冻结一个强音频编码器 (Whisper 系), 用 adapter/projector 将其输出映射进 LLM 的词嵌入空间, 再用大规模多任务音频-文本数据对齐两种模态。Qwen2-Audio 相对一代的两个关键简化: (1) 抛弃 Qwen-Audio 的层级化任务标签, 改为自然语言 prompt 区分任务——更接近真实指令分布, 也更易扩展数据; (2) 不加 system prompt 区分 "语音聊天" 与 "音频分析" 两种模式, 让模型自己从音频内容判断该回答指令还是分析声音——把模式切换变成了隐式的理解能力测试。

技术方法。架构为经典三段式: Whisper-large-v 系音频编码器 (30 秒窗口内处理) → 投影层降维对齐 → Qwen-7B 语言模型。训练分两阶段: 多任务预训练 (ASR、翻译、音频 caption、情感、声音事件、音乐分析等数十类任务的自然语言化混合) + 指令微调 (SFT), 再加 DPO (直接偏好优化) 提升事实性与指令遵循。交互上分 voice chat (纯语音对话) 与 audio analysis (音频 + 文字指令分析) 双模式。

实验结果。官方报告显示 Qwen2-Audio 在 AIR-Bench (音频指令跟随基准) 上超过 Gemini-1.5-pro 等此前 SOTA, ASR 上在常见基准接近或达到 Whisper 基线水平, 在音频事件与音乐理解任务上显著强于前代 Qwen-Audio。作为对照脉络: SALMONN (2023, ICLR 2024 Spotlight) 采用 Whisper 编码器 + BEATs 音频事件编码器双编码器接 Vicuna-13B, 并用 window-level Q-Former 融合, 展示了语音翻译到未训练语言、音频讲故事等 "涌现" 能力, 并研究了 LoRA 激活调优; Qwen2-Audio 用单编码器 + 更大数据 + DPO 达到更强且更稳的效果, 说明在这个方向上数据与对齐的规模压过架构精巧。

批判性分析。优点: 完全开源 (权重 + 推理代码)、中英双语强、双模式设计贴近真实产品形态, 是 2024 年最适合入手的 audio-LLM 研究基座; 其 "自然语言 prompt 代替任务标签" 的数据组织方式被后续广泛效仿。局限: 其一, 架构上无新意——cascade 式 "编码器 + adapter + LLM" 在视觉侧早已成熟, 论文贡献主要在数据工程与训练配方, 细节 (数据配比、清洗) 披露有限; 其二, 音频编码器窗口有限 (长音频需切块), 长时音频理解 (如一小时播客总结) 能力受结构制约; 其三, 只 "听见" 不 "开口"——输出仍是文本, 语音对话体验依赖外挂 TTS, 这正是 2025 年 Qwen2.5-Omni (Thinker-Talker) 要补的课; 其四, 音频指令微调后文本能力有可见退化 (灾难性遗忘), 论文坦承但缓解手段有限。可复现性: 强 (开源权重), 训练配方中等。

一句话评价: 不是最优雅的架构, 却是把 "LLM 听觉" 做到开箱即用的工程标杆; 它示范了数据工程如何战胜架构创新。评级: ★★★★★☆ (开源基础设施级)。

4.5 Moshi: 全双工语音对话的完整开源答卷 (Kyutai, 2024)

研究问题。GPT-4o (2024.5) 演示了低延迟、有情感的语音对话, 但细节完全封闭。传统语音对话是四段级联: VAD (语音活动检测) → ASR → LLM → TTS, 三大原罪: 延迟以秒计; 文本中间表示丢弃情绪、语气、环境声; 严格的回合制 (turn-taking) 无法处理打断、插话、重叠说话。Moshi 要一次性解决: 能否用一个模型直接做 speech-to-speech 生成, 同时建模自己和用户的语音流, 实现理论 160 ms 延迟的全双工对话?

关键洞察。三个层层递进：(1) 把对话从"回合"重新定义为两条并行时间流——用户流与机器流都按 codec 帧率 (12.5 Hz) 逐帧推进，模型每一时刻同时读用户的下一帧、写自己的下一帧，于是"打断"不再是需要检测的异常事件，而只是用户流中出现了非静音 token；(2) 文本不应被消除，而应被对齐复用——Inner Monologue 方法在生成音频 token 前先预测时间对齐的文本 token 作为前缀，让强文本 LLM 的语言能力"垫"在音频生成下面，同时白送流式 ASR/TTS 字幕；(3) 所有组件 (codec、语言模型) 必须为流式 causal 设计，延迟不是事后优化而是架构约束。

技术方法。系统由三层组成：

- Mimi codec：为 Moshi 定制的流式 RVQ codec，12.5 Hz 帧率（比 EnCodec 的 75 Hz 低 6 倍，直接决定序列长度与延迟），1.1 kbps；蒸馏 WavLM 语义到第 1 层 (semantic+acoustic 混合)，纯因果卷积 + Transformer，流式编解码。
- 双通道多流 LM (Depth Transformer)：每帧 12.5 Hz 上同时建模多路 token 流——机器的文本 token、机器的 8 层音频 token、用户的音频 token。层间用 delay pattern (第 i 层延迟 $i-1$ 帧) 实现完全并行预测；结构上一个小型时间维 Transformer (处理 12.5 Hz 的长程依赖) + 一个帧内 depth Transformer (处理 8 层 + 文本的层间依赖)，把二维序列分解为"时间 AR $\times$ 深度 AR"。
- Inner Monologue：文本 token 与音频 token 时间对齐 (padding 补齐)，生成时文本先行、音频随后，实验证明显著提升生成语音的语言质量 (困惑度、可懂度)，同时天然产出流式转写。

训练用 700 万小时级无标注语音 (Helium 文本 LM 初始化的 7B backbone)，多阶段：音频-文本预训练 $\rightarrow$ 多流微调 (含合成的双通道对话数据，用 TTS 把文本对话"说出声"再分离通道) $\rightarrow$ 指令与偏好微调。全书式技术报告公开了全部配方、权重与推理代码。

实验结果。系统级成就：理论延迟 160 ms、实测约 200 ms (含 codec 帧对齐)，是首个实时全双工开源语音 LLM；语音质量 MUSHRA 式评测显著优于非流式基线，Inner Monologue 带来明确的语言质量增益；作为副产品，Moshi 的流式 ASR 与 TTS 各自达到可用水平。作为对照：GPT-4o 同期产品化展示了更高自然度与情感表现力但零细节；GLM-4-Voice (智谱，仅 GitHub 技术报告) 采用流式 codec + 中文优化的类似路线；Freeze-Omni、LLaMA-Omni 等则探索"冻结 LLM 主干"的低算力替代方案。

批判性分析。优点：这是 2024 年音频方向最重要的开源工作，没有之一——它第一次把端到端全双工从"GPT-4o 黑箱演示"变成任何人可复现、可拆解、可改进的完整系统；多流建模对"打断"问题的化解 (从检测问题变成分布内生成问题) 是真正漂亮的概念转换；Inner Monologue 是文本-语音统一建模最优雅的工程方案。局限：其一，12.5 Hz/1.1 kbps 的 Mimi 是延迟与音质的硬权衡——音质明显弱于 24 kHz 高码率 codec，声音表现力受限；其二，对话能力受 7B backbone 与合成对话数据限制，深度对话远逊文本前沿模型；其三，全双工评测尚不成熟 (如何量化"打断处理得好"仍是开放问题)；其四，训练需要的大规模流式 codec + 多流数据工程，复现门槛远高于"下载权重推理"。可复现性：权重、代码、配方全开，社区已复现训练。

一句话评价：语音对话的"Linux 时刻"——不一定最强，但把整栋楼的设计图纸公开了。评级：★★★★★ (开源里程碑)。

5 研究前沿 (2025–2026)

5.1 全双工与实时对话成为主战场

Moshi 之后, 全双工从单点突破变成子领域, 2025 年已有专题综述 [30]。活跃问题包括: 多流架构的变体 (双通道 vs 单通道时分复用); 打断与回话 (barge-in) 的显式建模——何时倾听、何时抢话、何时用 "嗯""对" 等 backchannel 回应, 人类对话中这些信号承载语义, 现有模型只会机械延续; 副语言生成——笑、叹、犹豫、语气词的自然插入, Moshi 已具备初步能力但控制性差; 延迟-质量的帕累托前沿——Mimi 的 12.5 Hz 是不是最佳帧率? 有工作探索更高帧率 + 更激进并行。Freeze-Omni [20] 代表的低算力路线 (冻结文本 LLM、只训语音头尾) 使该方向对学术界开放。

5.2 Omni 化: 语音并入全模态主干

2025 年最确定的结构性变化: 独立 audio-LLM 正在被全模态模型吸收。Qwen2.5-Omni [23] 的 Thinker-Talker 架构是代表: Thinker 是负责文本与理解的大模型, Talker 是双轨自回归语音头, 直接消费 Thinker 的隐表示流式产出音频 token, 二者端到端联合训练——设计上刻意解耦以避免文本与语音生成的相互干扰, 并配 TMRoPE (时间对齐多模态 RoPE) 处理音视频交错输入。Qwen3-Omni [25] 进一步 MoE 化并扩展多语言流式对话。Step-Audio [22] (130B 级) 与 Kimi-Audio [24] (1300 万小时音频预训练) 则展示了中国团队在 "音频原生基础模型" 上的规模化投入。"speech 只是 omni 的一种模态" 已成为主流认知——这对语音研究者是双刃剑: 基础设施问题 (codec、流式、对齐) 仍有独立价值, 但纯架构创新越来越需要放在全模态语境下讲。

5.3 TTS 的流式化与生产化

CosyVoice 2 [21] 代表 LLM-based TTS 从学术 demo 走向生产的关键一跃: 用 finite-scalar quantization (FSQ) 替代 RVQ 提升码本利用率; text-speech LM 直接以预训练 LLM 为主干; chunk-aware 因果流匹配让单一模型同时支持流式与非流式合成——按块生成 mel 谱、首包延迟压到 200 ms 级, 同时流式模式质量 "几乎无损"。VALL-E 2 [13] 的 Grouped Code Modeling 则从纯 AR 侧缩短序列。两条路线 (LM 全 token vs LM+flow matching 混合) 的竞争在 2026 年仍未分出胜负: 前者优雅统一, 后者工程实用、音质上限高。

5.4 Codec 的语义化、低帧率化与统一化

codec 设计的三个明确趋势: (1) 语义蒸馏进第 1 层已成标配 (SpeechTokenizer、Mimi、CosyVoice 的监督式 token); (2) 低帧率——从 75 Hz (EnCodec) 到 25/12.5 Hz (Mimi 及后续), 每帧信息密度更高、序列更短, 直接利好 LM 建模与延迟; (3) 统一词表——AudioPaLM [9] 开创的 "文本 token 与音频 token 共享词表联合训练" 被更多 omni 模型采纳, 目标是消除模态词表鸿沟。一个开放张力是: codec 越语义化越利理解与生成一致性, 但重建保真与音色保留越受损——semantic 与 acoustic 的 "单流统一" 是否可能, 是 2026 年的核心问题之一。

5.5 评测体系成型与可信性议题

2025 年后领域从"能做"进入"可信地评估"阶段：LALM 评测综述 [29] 系统整理了理解/生成/推理/安全四类能力分类学与基准全景（AIR-Bench、VoiceBench 等）；2026 年最新综述 [31] 把重心转向泛化性与可信性——幻觉（语音中不存在的声源被"听"出来）、鲁棒性（噪声、口音）、安全（声音克隆滥用、deepfake 检测、音频注入攻击）。全双工对话的评测仍是方法论荒原：延迟好测，"对话自然度""打断得体性"缺乏共识指标，多依赖人工评测，成本高且难复现。

6 技术路线对比与权衡

6.1 三组根本分野

分野一：连续表征 vs 离散 token ("音频如何进 LLM")。

维度	连续表征（Whisper/wav2vec2 编码器 + projector）	离散 token（RVQ codec）
信息保真	高（无量化损失，但经 ASR 训练的编码器偏语义）	有量化损失，码率可调
序列长度	25–50 Hz 下仍偏长，需下采样	帧率 × 层数，更膨胀，需 flattening
与 LLM 兼容	需 adapter 映射到词嵌入空间	原生兼容（扩词表即可），可统一词表
支持生成	不能直接出声音（需外接解码器/声码器）	对称：既能进也能出，speech-in speech-out 闭环
语义对齐	Whisper 系强（ASR 监督）	原始 code 弱，语义蒸馏后可改善
代表	Qwen2-Audio、SALMONN	Moshi、VALL-E、AudioLM

经验结论：理解侧连续表征占优（信息无损、训练简单），生成与全双工侧离散 token 占优（输出对称、可流式）。Omni 模型（Qwen2.5-Omni、Moshi）的实际选择是理解用连续编码、生成用 codec token——混合架构是当前共识解。

分野二：cascade vs end-to-end（语音对话系统组织方式）。

维度	级联（ASR→LLM→TTS）	端到端 speech-to-speech
延迟	秒级（各段串联）	200 ms 级（Moshi 实测）
副语言信息	在 ASR 处丢失（情绪、语气不可恢复）	端到端保留并可生成
语言能力	继承最强文本 LLM	受限于 backbone 规模与语音训练数据
工程复杂度	模块成熟、易拼装调试	训练数据（对齐多流对话）极难构建

维度	级联（ASR→LLM→TTS）	端到端 speech-to-speech
可控性	每段可独立替换、审计	黑箱，安全对齐更难
代表	传统语音助手、多数语音 Agent 产品	GPT-4o voice、Moshi、GLM-4-Voice

短期看级联仍是多数产品（尤其 Agent 场景）的务实选择——语言能力即正义；端到端是体验天花板，GPT-4o 与 Moshi 证明可行后差距会收窄。

分野三：semantic token vs acoustic token（语音离散化的信息取向）。semantic token（HuBERT k-means、监督 ASR token）与文本强对齐、序列短、利于 LM 建模"说什么"，但丢音色丢细节、不可直接高保真重建；acoustic token（EnCodec RVQ）保真完备、可重建任意声音，但语义对齐弱、序列长。SpeechTokenizer/Mimi 的"第 1 层语义化"与 AudioLM 的"semantic 先生成、acoustic 后补全"是调和二者的两大范式；CosyVoice 的监督式 token + flow matching 则干脆让 LM 只管语义、声学交给连续生成。这一分野至今没有终极答案，是编解码器研究的活水。

6.2 flattening 模式横向对比

模式	代表	序列长度（每帧）	并行度	流式能力	音质-延迟权衡
层级两阶段	AudioLM1	(semantic) + N_q (acoustic)	阶段内 AR	弱	质量高、管线长
AR+NARVALL-E		AR 1 + NAR 并行	NAR 层帧内并行	弱（两段）	AR 短序列降延迟近 N_q 倍
分组 codec	VALL-E 2	组数 ($< N_q$)	组内并行	中	进一步压缩
延迟交错多流	MusicGen, Moshi	N_q 并行 (delay pattern)	全并行	强（天然流式）	浅层依赖换实时性
LM + flow matching	CosyVoice 2	4 (semantic token)	流匹配分块并行	强（chunk 流式）	工程最优，音质上限高

一句话总结：生成模式的选择 = 在"层间依赖的忠实度"与"序列长度/延迟"之间选点，而 RVQ 残差结构给出的先验（低层重要、高层细节）是所有方案的共同支点。

7 开放问题与未来方向

- 1. 全双工的"对话智能"：现有模型解决的是延迟与重叠的物理层问题，对话的社交智能——何时抢话、backchannel 的语义、多人会话的话轮管理——几乎没有被建模。这需要数据（真实对话而非合成）与评测（社会性指标）的双重突破。
- 2. semantic-acoustic 统一 token：能否设计单一离散空间同时满足文本级语义对齐与透明级重建？FSQ、多码本联合蒸馏、对比正则都是候选工具；成功将同时简化管理、生成与统一词

表三条线。

3. 音频 token 的效率: codec token 序列比文本长 1-2 个数量级 (一分钟音频在 $12.5 \text{ Hz} \times 8$ 层下是 6000 token), 长音频理解 (播客、会议) 与长音乐生成受困于此。token 去重、层级 pooling、稀疏化是活跃方向。
4. 端到端与文本能力的差距: speech-to-speech 模型的语言智能普遍落后同代文本 LLM 一至两年。Inner Monologue 证明文本可作 "认知支架", 但如何在全语音训练中不牺牲文本推理能力 (灾难性遗忘), 是 omni 模型的核心训练难题。
5. 评测科学: 全双工自然度、副语言保真度、音频指令遵循的自动指标缺位; 人类评测 (MUSHRA) 昂贵不可复现。LALM 评测体系 [29] 刚起步, 谁建立标准谁定义领域。
6. 安全与可信: 零样本声音克隆的滥用已是现实威胁; audio LLM 的幻觉 (虚构声源)、对抗性音频注入、生成语音水印与溯源, 在 2026 年综述 [31] 中被列为首要议题。生成能力与安全机制 (水印、检测、授权克隆) 需要协同设计而非事后补丁。
7. 低资源与多语言: Whisper 式弱监督对低资源语言增益有限; 多语言 codec 的音素覆盖、跨语言声音克隆的身份一致性, 仍有大片空白。

8 研究机会点评 (给入门研究者的建议)

算力门槛适中、问题清晰、有顶会潜力的方向:

- Codec 改进 (★ 推荐): 单张消费级 GPU 即可训练 16/24 kHz 语音 codec。具体切入口: FSQ vs RVQ 的系统比较、语义蒸馏策略、低帧率 (12.5 Hz 以下) 高保真、音乐专用 codec。评测客观 (重建指标 + 小规模听测), 失败成本低, 是整个生态的 "卖水" 生意。
- 全双工微创新 (★ 推荐): 基于开源 Moshi 做 backchannel 建模、打断策略、情感控制的增量工作; Freeze-Omni 路线使冻结主干的小数据实验可行。关键是找到可量化的对话级指标 (这本身可以是论文)。
- 音频 LLM 评测与幻觉分析 (★ 推荐, 低算力): 用开源模型 (Qwen2-Audio、SALMONN、Kimi-Audio) 系统性研究音频幻觉、噪声鲁棒、跨语言指令遵循, 构造诊断性基准。2025-2026 评测窗口期, bench 类工作引用率高。
- Flattening/生成模式消融 (中等算力): 在统一 codec 与数据上系统对比 § 6.2 的五种模式 (质量/延迟/RTF), 这类 "把设计空间扫干净" 的实证工作稀缺且有用。

坦诚说明是巨头游戏的方向: 大规模 speech-to-speech 预训练 (Moshi 级需数百 GPU $\times$ 月)、omni 旗舰 (Qwen3-Omni、GPT-4o 级)、1300 万小时级数据工程 (Kimi-Audio)。学术界应避免正面拼规模, 转而做巨头无暇顾及的: 评测方法、安全机制、低资源语言、以及 "用小模型验证大假设" 的科学问题。Whisper 与 Moshi 的历史共同表明: 这个领域的里程碑一半来自规模, 另一半来自把对的抽象 (RVQ、多流、Inner Monologue) 做干净——后者不挑出身。

9 术语表

- ASR (自动语音识别): 把语音转写为文本的系统, 核心指标 WER (词错误率)。

- log-mel 谱图：对 STFT 频谱按 mel 频率刻度压缩、取对数得到的时频表示，神经音频模型的标准输入。
- WER (Word Error Rate)：编辑距离/词数，ASR 标准指标，越低越好。
- 自监督预训练：用无标注数据设计代理任务（对比、掩码预测）学习通用表征。
- wav2vec 2.0：对比式语音自监督模型，量化目标与模型联合学习。
- HuBERT：掩码预测式语音自监督模型，预测离线 k-means 聚类标签；semantic token 的源头。
- semantic token (语义 token)：与语言内容（音素/文本）对齐的离散语音单元，来自自监督模型的特征聚类或 ASR 监督。
- acoustic token (声学 token)：神经 codec 量化得到的保真导向离散码，可高保真重建波形。
- VQ (矢量量化)：用码本最近邻码字替换连续向量的离散化操作。
- RVQ (残差矢量量化)：多层量化器逐层量化残差，容量随层数乘法增长；codec token 的核心机制。
- FSQ (finite-scalar quantization)：无码本的标量量化替代方案，码本利用率高。
- neural audio codec (神经音频编解码器)：端到端学习的音频压缩器（编码器 + 量化 + 解码器），如 SoundStream/EnCodec/Mimi。
- 码率 (bitrate)：每秒比特数；codec 的核心权衡轴（3–24 kbps 神经 codec vs 384 kbps 原始 PCM）。
- codec LM：在 codec token 上做语言建模的生成范式（VALL-E、AudioLM）。
- flattening (展平) 模式：把二维（时间 × 量化层）token 序列组织为一维生成顺序的策略空间。
- NAR (非自回归)：并行预测多个位置的解码方式，牺牲依赖换速度。
- cascade (级联)：ASR→LLM→TTS 的多组件语音对话管线。
- end-to-end speech-to-speech：不经文本中间表示、直接语音进语音出的对话建模。
- 全双工 (full-duplex)：双方可同时听说（如电话），相对半双工回合制；要求模型处理重叠与打断。
- barge-in (打断)：用户在机器说话时插话，全双工系统的标志性场景。
- backchannel：倾听者的简短反馈（“嗯”“对”），对话自然度的关键细节。
- Inner Monologue：Moshi 的方法，生成音频 token 前先出时间对齐文本 token，兼顾语言质量与流式字幕。
- Thinker-Talker：Qwen2.5-Omni 的架构，理解/文本 (Thinker) 与语音生成 (Talker) 双模型解耦。
- flow matching (流匹配)：连续空间的生成建模方法，学习从噪声到数据的向量场；CosyVoice 用它做 token→mel 谱。
- MUSHRA：带隐藏参考的多刺激主观听测标准，codec/TTS 质量的黄金评测。
- 零样本声音克隆：仅凭几秒参考音频合成陌生说话人的语音，无需微调。

- audio-LLM / LALM: 以 LLM 为核心、具备音频输入（或输出）能力的多模态模型。

10 参考文献

- [1]] wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations, Baevski et al. (Meta), 2020, arXiv:2006.11477, <https://arxiv.org/abs/2006.11477>
- [2]] HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units, Hsu et al. (Meta), 2021, arXiv:2106.07447, <https://arxiv.org/abs/2106.07447>
- [3]] SoundStream: An End-to-End Neural Audio Codec, Zeghidour et al. (Google), 2021, arXiv:2107.03312, <https://arxiv.org/abs/2107.03312>
- [4]] Robust Speech Recognition via Large-Scale Weak Supervision (Whisper), Radford et al. (OpenAI), 2022, arXiv:2212.04356, <https://arxiv.org/abs/2212.04356>
- [5]] High Fidelity Neural Audio Compression (EnCodec), Défossez et al. (Meta), 2022, arXiv:2210.13438, <https://arxiv.org/abs/2210.13438>
- [6]] AudioLM: a Language Modeling Approach to Audio Generation, Borsos et al. (Google), 2022, arXiv:2209.03143, <https://arxiv.org/abs/2209.03143>
- [7]] Neural Codec Language Models are Zero-Shot Text to Speech Synthesizers (VALL-E), Wang et al. (Microsoft), 2023, arXiv:2301.02111, <https://arxiv.org/abs/2301.02111>
- [8]] MusicLM: Generating Music From Text, Agostinelli et al. (Google), 2023, arXiv:2301.11325, <https://arxiv.org/abs/2301.11325>
- [9]] AudioPaLM: A Large Language Model That Can Speak and Listen, Rubenstein et al. (Google), 2023, arXiv:2306.12925, <https://arxiv.org/abs/2306.12925>
- [10]] SpeechTokenizer: Unified Speech Tokenizer for Speech Large Language Models, Zhang et al., 2023, arXiv:2308.16692, <https://arxiv.org/abs/2308.16692>
- [11]] SALMONN: Towards Generic Hearing Abilities for Large Language Models, Tang et al. (ByteDance & THU), 2023, arXiv:2310.13289, <https://arxiv.org/abs/2310.13289>
- [12]] Qwen-Audio: Advancing Universal Audio Understanding via Unified Large-Scale Audio-Language Models, Chu et al. (Alibaba), 2023, arXiv:2311.07919, <https://arxiv.org/abs/2311.07919>
- [13]] VALL-E 2: Neural Codec Language Models are Human Parity Zero-Shot Text to Speech Synthesizers, Chen et al. (Microsoft), 2024, arXiv:2406.05370, <https://arxiv.org/abs/2406.05370>
- [14]] CosyVoice: A Scalable Multilingual Zero-shot Text-to-speech Synthesizer based on Supervised Semantic Tokens, Du et al. (Alibaba), 2024, arXiv:2407.05407, <https://arxiv.org/abs/2407.05407>
- [15]] Qwen2-Audio Technical Report, Chu et al. (Alibaba), 2024, arXiv:2407.10759, <https://arxiv.org/abs/2407.10759>
- [16]] Mini-Omni: Language Models Can Hear, Talk While Thinking in Streaming, Xie & Wu (Tsinghua), 2024, arXiv:2408.16725, <https://arxiv.org/abs/2408.16725>
- [17]] LLaMA-Omni: Seamless Speech Interaction with Large Language Models, Fang et al. (CAS), 2024, arXiv:2409.06666, <https://arxiv.org/abs/2409.06666>
- [18]] Moshi: a speech-text foundation model for real-time dialogue, Défossez et al. (Kyutai), 2024, arXiv:2410.00037, <https://arxiv.org/abs/2410.00037>
- [19]] GPT-4o System Card, OpenAI, 2024, arXiv:2410.21276, <https://arxiv.org/abs/2410.21276> [官方发布/技术报告]

- [20]] Freeze-Omni: A Smart and Low Latency Speech-to-speech Dialogue Model with Frozen LLM, Wang et al. (Vivo & NJU), 2024, arXiv:2411.00774, <https://arxiv.org/abs/2411.00774>
- [21]] CosyVoice 2: Scalable Streaming Speech Synthesis with Large Language Models, Du et al. (Alibaba), 2024, arXiv:2412.10117, <https://arxiv.org/abs/2412.10117>
- [22]] Step-Audio: Unified Understanding and Generation in Intelligent Speech Interaction, Huang et al. (StepFun), 2025, arXiv:2502.11946, <https://arxiv.org/abs/2502.11946>
- [23]] Qwen2.5-Omni Technical Report, Xu et al. (Alibaba), 2025, arXiv:2503.20215, <https://arxiv.org/abs/2503.20215>
- [24]] Kimi-Audio Technical Report, Kimi Team (Moonshot AI), 2025, arXiv:2504.18425, <https://arxiv.org/abs/2504.18425>
- [25]] Qwen3-Omni Technical Report, Xu et al. (Alibaba), 2025, arXiv:2509.17765, <https://arxiv.org/abs/2509.17765>
- [26]] Recent Advances in Speech Language Models: A Survey, Cui et al., 2024, arXiv:2410.03751, <https://arxiv.org/abs/2410.03751>
- [27]] A Survey on Speech Large Language Models for Understanding, Wu et al., 2024, arXiv:2410.18908, <https://arxiv.org/abs/2410.18908>
- [28]] On The Landscape of Spoken Language Models: A Comprehensive Survey, 2025, arXiv:2504.08528, <https://arxiv.org/abs/2504.08528>
- [29]] Towards Holistic Evaluation of Large Audio-Language Models: A Comprehensive Survey, 2025, arXiv:2505.15957, <https://arxiv.org/abs/2505.15957>
- [30]] From Turn-Taking to Synchronous Dialogue: A Survey of Full-Duplex Spoken Language Models, 2025, arXiv:2509.14515, <https://arxiv.org/abs/2509.14515>
- [31]] A Survey of Large Audio Language Models: Generalization, Trustworthiness, and Outlook, 2026, arXiv:2605.20266, <https://arxiv.org/abs/2605.20266>