多模态大模型系列报告

从去噪目标到统一图像生成

推导训练量，核对采样过程，并分开质量、覆盖和计算预算

多模态大模型系列报告

2026-10-16

本报告为系列技术综述，内容基于公开论文整理，仅供学习研究使用。

目录

1 先构造一个可以直接采样的训练问题 **3**

1.1 真实后验为什么重要 3

2 从均值回归变成噪声回归 **4**

2.1 参数化变化也改变误差尺度 4

2.2 Flow matching 学习什么速度 5

2.3 网络输出怎样成为下一状态 5

3 一次 DiT 调用与一次完整采样不同 **6**

4 Guidance 改善 FID，为何可能减少覆盖 **6**

5 统一生成与理解要统一哪些接口 **7**

5.1 同一张图，两种输出序列 7

6 复现前的检查顺序 **8**

7 参考文献与证据 **8**

摘要 “反复去噪得到图像”没有解释网络为何可以学习这个过程，也没有说明换一种预测目标或增加采样步数会改变什么。本章从已知的前向加噪分布推导后验和训练目标，再沿着 latent、patch、Transformer 和解码器追踪一次采样。最后用 DiT 原文中同一分辨率、同一模型的 guidance 结果，展示 FID 改善与分布覆盖下降可以同时发生；统一理解与生成则被拆成表示、attention 与损失三个具体接口。

1 先构造一个可以直接采样的训练问题

DDPM [1] 定义前向过程 $q(x_t \mid x_{t-1}) = \mathcal{N}(\sqrt{1-\beta_t}x_{t-1}, \beta_t I)$。令 $\alpha_t = 1 - \beta_t$、$\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$。反复代入并利用独立高斯噪声之和仍为高斯，可得：

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon, \qquad \epsilon \sim \mathcal{N}(0, I).$$

因此训练时不必真的执行 t 次加噪：抽一个干净样本、一个时间步和一份噪声，就能直接得到 (x_t, t, ϵ)。这里 x_0 可以是像素，也可以是预先训练的 autoencoder latent；后者的重建瓶颈必须另外评估。

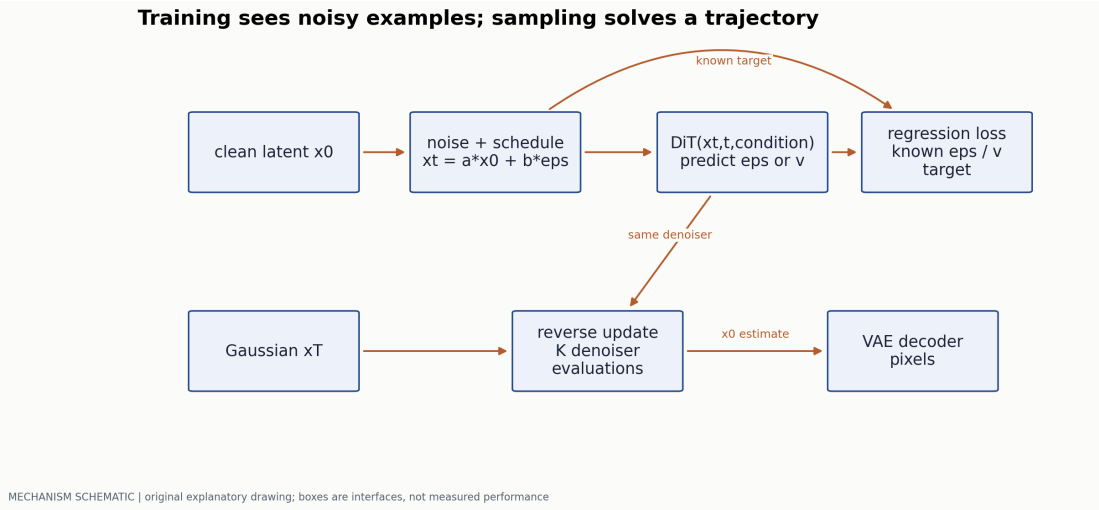


图 1 训练使用已知噪声回归；采样从高斯初态出发，多次调用同一 denoiser。两条路径共享网络，不共享已知的干净目标。

1.1 真实后验为什么重要

生成时不知道 x_0，但训练推导可以以它为条件。由贝叶斯公式，将 $q(x_t \mid x_{t-1})q(x_{t-1} \mid x_0)$ 的高斯指数配方，得到：

$$q(x_{t-1} \mid x_t, x_0) = \mathcal{N}(\tilde{\mu}_t, \tilde{\beta}_t I), \qquad \tilde{\beta}_t = \beta_t \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}.$$

$$\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t}x_0 + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}x_t.$$

后验均值是 x_0 与 x_t 的已知线性组合。模型要逼近的是这个条件后验的统计量，而不是凭空学一个任意“变清晰”算子。$t = 1$ 的重建项和终点先验项在完整 variational bound 中有各自位置，不应把所有时间步都笼统叫同一个 KL 项。

2 从均值回归变成噪声回归

取反向模型 $p_\theta(x_{t-1} \mid x_t) = \mathcal{N}(\mu_\theta(x_t, t), \sigma_t^2 I)$。将 $x_0 = (x_t - \sqrt{1-\bar{\alpha}_t}\epsilon)/\sqrt{\bar{\alpha}_t}$ 代入后验均值，可将模型均值写为：

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon_\theta(x_t, t)\right).$$

固定方差时，对两个高斯的 KL 会产生一个带时间权重的噪声平方误差；DDPM 的常用 simple objective 去掉了这部分权重：

$$\mathcal{L}_{simple} = \mathbb{E}_{x_0,t,\epsilon}\|\epsilon - \epsilon_\theta(x_t, t)\|_2^2.$$

“等价于最大似然”需要说明用了哪个 weighting、方差和离散时间设定。把 simple loss 与完整 ELBO 完全等同，会掩盖它对不同噪声级别的重新加权。

2.1 参数化变化也改变误差尺度

预测噪声得到的干净估计为 $\hat{x}_0 = (x_t - \sqrt{1-\bar{\alpha}_t}\hat{\epsilon})/\sqrt{\bar{\alpha}_t}$。若噪声预测存在误差 e，则干净估计误差是 $-\sqrt{(1-\bar{\alpha}_t)/\bar{\alpha}_t}\, e$。低信噪比时，固定的噪声误差会被放大。

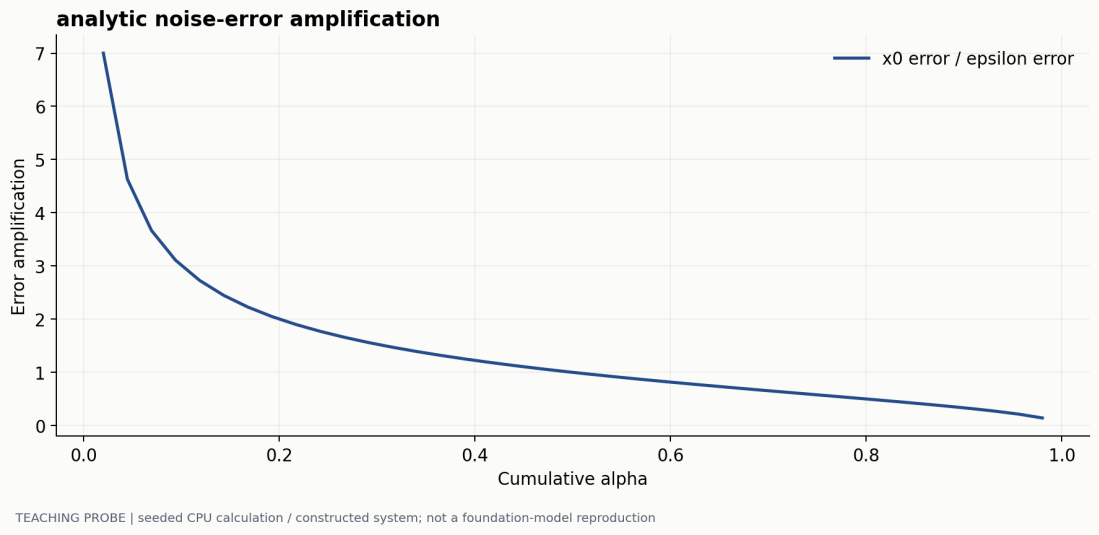


图 2 按上述代数关系计算的误差放大系数。固定噪声预测误差这个假设用于理解条件数，不表示真实 denoiser 的误差在所有 t 都相同。

常见的 $v = \sqrt{\bar{\alpha}_t}\epsilon - \sqrt{1-\bar{\alpha}_t}x_0$ 是另一种线性参数化；它与 flow matching 中沿插值轨迹定义的速度目标不是同一个符号约定。阅读论文时先写出插值和目标定义，再讨论“都在预测 velocity”。对同一数据换参数化，也要检查 t 分布和 loss weighting，不能只替换输出变量名称。

2.2 Flow matching 学习什么速度

为避免与 DDPM 的“x_0 表示数据”混淆，这里把噪声记为 $\eta \sim \mathcal{N}(0, I)$，数据记为 z，插值时间 $\tau = 0$ 为噪声、$\tau = 1$ 为数据。在 $\sigma_{min} \to 0$ 的教学极限下，最简单的条件路径为

$$x_\tau = (1-\tau)\eta + \tau z, \qquad u = z - \eta, \qquad L_{CFM} = \mathbb{E}\|v_\theta(x_\tau, \tau; c) - u\|^2.$$

其中 c 是文本、类别或其他条件；图像 latent 可以是 `[B,Cz,Hz,Wz]`，x_τ, u, v_θ 有同样 shape，时间为 `[B]` 并广播到空间维。训练时随机抽数据、噪声、时间即可形成监督，无须先数值积分出一条模型轨迹。条件 flow matching 通过可计算的条件路径学习边际流，是 FM 论文的核心构造。Flow Matching §3–4

平方回归还给出一个直接解释。对固定 (x, τ, c)，令 $m = E[u|x, \tau, c]$，则

$$E[\|v-u\|^2|x,\tau,c] = \|v-m\|^2 + E[\|u-m\|^2|x,\tau,c].$$

第二项不依赖 v，所以最优预测是条件平均速度。多条噪声–数据配对可能在相近位置相遇，网络学的是它们在该位置的平均；单条条件插值为直线，并不推出模型积分轨迹处处为直线。例如取教学配对 $\eta = -1, z = 3$，在 $\tau = 0.25$ 得到 $x = 0, u = 4$；以理想常速度走 $\Delta\tau = 0.25$ 到 1，恰好等于该条件直线的中点。这只是可手算的一条监督路径。

DDPM 常见 $v_{DDPM} = a_t\epsilon - b_t x_{data}$ 的目标由其噪声调度定义；上式 $u = z - \eta$ 由选定插值求导得到。实现中保存 `path_type/time_direction/prediction_type`，才有可能正确互换网络输出与采样方向。

2.3 网络输出怎样成为下一状态

对学到的 ODE $dx/d\tau = v_\theta(x, \tau; c)$，Euler 和 Heun 分别为

$$x' = x + h\, v_\theta(x, \tau; c),$$

$$k_1 = v_\theta(x,\tau;c), \quad \tilde{x} = x + hk_1, \quad k_2 = v_\theta(\tilde{x}, \tau+h; c), \quad x' = x + \tfrac{h}{2}(k_1+k_2).$$

Euler 每步一次网络调用，Heun 通常每步两次。用已知 ODE $dx/d\tau = x$、$x(0) = 1$、h=0.5 比较：Euler 为 1.5，Heun 为 1.625，精确解 $e^{0.5} \approx 1.6487$。这个有曲率的例子说明高阶更新在增加调用数后可能减少积分误差；训练向量场误差仍需另外评估。比较采样器时同时报告时间表、步数、NFE、每次 batch 中的条件分支数和 wall-clock 时间。

对 DDPM，模型给出的均值还需接上随机更新 $x_{t-1} = \mu_\theta(x_t, t) + \sigma_t\xi$，并规定最后一步的随机项。DDIM 可在同一噪声模型上使用确定性跳步：设 $s < t$，

$$\hat{x}_0 = \frac{x_t - \sqrt{1-\bar{\alpha}_t}\hat{\epsilon}}{\sqrt{\bar{\alpha}_t}}, \qquad x_s = \sqrt{\bar{\alpha}_s}\hat{x}_0 + \sqrt{1-\bar{\alpha}_s}\hat{\epsilon}.$$

这是 DDIM 随机系数取 0 的更新。DDPM Algorithm 2、DDIM §4 取 $x_t = 1, \hat{\epsilon} = 0.5, \bar{\alpha}_t = 0.25, \bar{\alpha}_s = 0.64$，先得到 $\hat{x}_0 \approx 1.1340$，再得到 $x_s \approx 1.2072$。由此可手查实现究竟用了累计 $\bar{\alpha}$ 还是单步 α、时间方向是否反转。

```
training: sample (data, condition), noise and time; regress the declared target
sampling: initialize noise with saved shape/seed
for each pair of times in the declared schedule:
    evaluate the declared prediction type
    convert to the vector/noise required by the chosen update
    apply Euler/Heun/DDIM/etc. with explicit random term
decode the final latent using the training-time scaling convention
```

训练正常但采样失败时，先拿一个二维高斯或一维已知向量场检查这个接口。时间从 1 走到 0 却沿正向 FM 速度积分、把 DDPM v 直接当 FM u、把 latent scaling 做两次，都会给出 shape 完全合法的错误采样。固定 seed 对比后，才扩展到质量、覆盖与提示遵循实验。

3 一次 DiT 调用与一次完整采样不同

DiT [2] 在 latent 上切 patch，形成 token 序列，用 Transformer 处理并注入时间/类别条件，再恢复 latent 网格。autoencoder、denoiser 和采样器分担了三个任务：压缩与重建、估计去噪方向、数值积分或离散反向更新。

若 latent 空间边长为 H_z, W_z，patch 边长为 p，token 数为 $N = H_z W_z / p^2$。降低 patch size 会使 token 数增加，attention 的配对量随之增大；提高 denoiser 表达能力的同时也提高每次调用成本。完整采样还要乘网络评估次数 NFE，并计条件/无条件分支与解码器。

```
# Pseudocode; the update rule belongs to the chosen sampler.
x = gaussian_noise(shape)
for t, t_next in schedule:
    eps_uncond = denoiser(x, t, null_condition)
    eps_cond = denoiser(x, t, condition)
    eps = eps_uncond + scale * (eps_cond - eps_uncond)
    x = sampler_update(x, eps, t, t_next)
image = latent_decoder(x)
```

这里的 scale 采用“无条件加差值”的 CFG 约定；一些论文用另一种系数定义，比较时必须先换算。条件与无条件可合在一个 batch 中计算，但不能据此声称 CFG 没有额外算力成本。采样器 NFE、推理 batch 和精度也是复现设置。

4 Guidance 改善 FID，为何可能减少覆盖

这组结果比跨模型排行榜更适合讨论取舍，因为模型与分辨率保持一致。更强 guidance 可以把采样推向更典型的条件样本，同时降低覆盖；这里的 FID 改善没有消除 recall 的下降。FID 使用特征分布统计，既不直接检验提示遵循，也不保证图中文字、计数和空间关系正确。

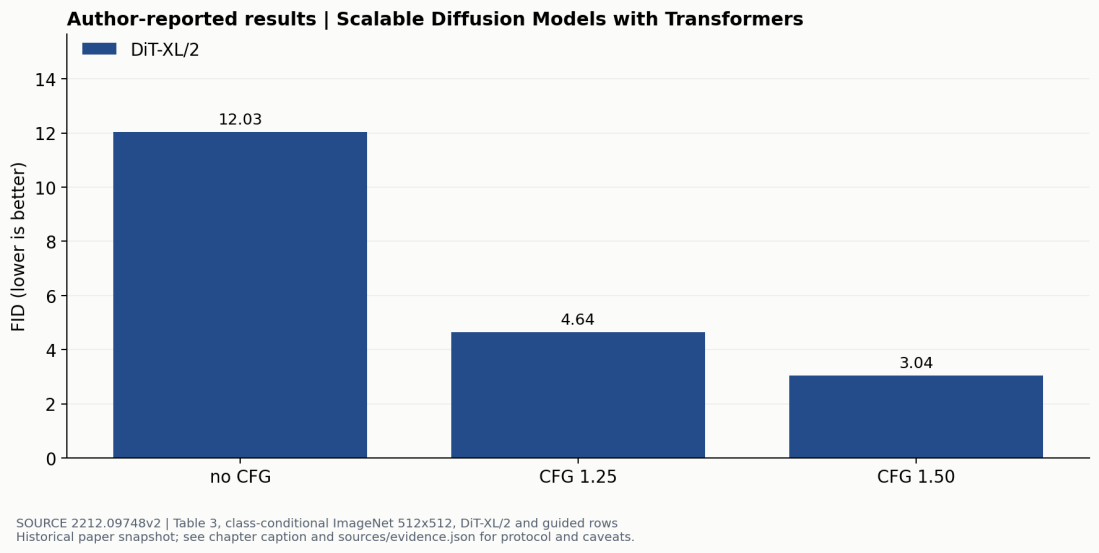


图 3 DiT 原文 Table 3，ImageNet 512×512、DiT-XL/2。无 CFG 的 FID 为 12.03；CFG 1.25 为 4.64，CFG 1.50 为 3.04。对应 recall 为 0.64、0.57、0.54。

还要区分“论文报告的原始主表”与“等预算消融”。模型训练步数、采样步数、图像数量和评估统计都会影响结果。不能把 256×256 的 2.27 填进这张 512×512 图，也不能用增加 NFE 得到的结果宣称每次 denoiser 调用更强。

5 统一生成与理解要统一哪些接口

离散图像路线先把图像量化成码，和文本一起做 next-token prediction。它获得统一的词表/序列接口，但图像 tokenizer 会限制可恢复细节，尤其需要检查小字和细线。连续路线保留 latent，图像区域用去噪目标、文字区域用交叉熵；Transfusion [3] 给出了一种将两类目标放进同一 Transformer 的具体实例。

统一参数并不意味着一个统一的 attention mask：文字生成需要防止读取未来答案，图像块内部可能允许双向交互，跨块又要满足条件关系。数据打包、时间步采样和模态 loss 权重共同决定梯度分配。仅看共享层数无法说明理解与生成是否真正互相促进。

一个可证伪的实验应比较：同样的数据、训练计算和参数预算下，独立模型与共享模型的理解准确率、生成质量、吞吐及负迁移。若共享模型额外看了更多图文数据，其收益不能全部归到架构统一。第 12 章将把这一问题写成具体对照设计。

已执行的代数检查用同一数据/噪声构造 x_t 与 DDPM v，互换 x_0、epsilon、v 后最大误差约 8.88×10^{-16}。它检查参数化接口的自洽性；网络预测误差、ODE 积分误差和图像质量仍是另三个测量对象。

5.1 同一张图，两种输出序列

取一张 512×512 图作接口例子。离散路线若 tokenizer 下采样 16 倍，得到 32×32=1024 个索引，码本大小 K，词表读出为 `[B,1024,K]`；逐 token AR 通常有 1024 个有顺序依赖的位置。连续路线若 autoencoder 下采样 8 倍且 latent channel 为 4，则 latent 是 `[B,4,64,64]`；DiT

使用 2×2 latent patch 时有 1024 个 16 维 patch。两者的 token 数恰好相同，但一个预测分类分布，一个反复更新整张连续 latent。

若后者 Euler 采样 20 步，就是 20 次整图向量场计算；用 Heun 通常约 40 次。CFG 的条件/无条件分支又会改变每次调用的实际 batch。前者的 1024 次串行位置可复用 KV，后者每次处理整组 token，不能凭“1024 对 20”得出速度比。应在相同分辨率、质量目标、硬件与 batch 下记录 NFE、串行依赖、总 FLOPs 和时间；tokenizer 的重建误差也要单独测。这些尺寸是用于比较的假设，不对应一个声称已训练的统一模型。

6 复现前的检查顺序

先固定噪声调度并检查前向采样的均值/方差，再检查 x_0 与噪声参数化的代数互换；然后在极小数据上做过拟合测试。保存 noise seed、time sampling、EMA 权重选择和采样器设置。固定 seed 的图片有助于逐例比较，但一组漂亮样图不能代替分布评估。

若训练 loss 正常、生成失败，先检查训练和推理是否使用同一种 latent scaling、时间索引、条件 dropout 和 prediction type。若 FID 改善但用户任务变差，加入提示遵循、对象属性和覆盖指标，而不是继续只优化一条曲线。

本站执行的是图 2 的解析计算；大型 DiT 的训练与 FID 没有在此声称复现。原文定量值及设置可在 `sources/evidence.json` 的 topic 05 逐条核对。

7 参考文献与证据

[1] Ho et al. Denoising Diffusion Probabilistic Models. 2020. 2 – 3 节，反向均值与 simplified objective。原文

[2] Peebles and Xie. Scalable Diffusion Models with Transformers. 2022. 架构与 Table 3。原文

[3] Zhou et al. Transfusion: Predict the Next Token and Diffuse Images with One Multi-Modal Model. 2024. 混合模态目标与 attention。原文