
多模态大模型系列报告

对齐、幻觉与安全：让多模态大模型可信

当模型学会“看图说话”之后，如何让它说真话、不做恶

多模态大模型系列报告

2026-09-29

本报告为系列技术综述，内容基于公开论文整理，仅供学习研究使用。

目录

1	引言：本方向在多模态版图中的位置	4
1.1	从”能用”到”可信”	4
1.2	学习地图	5
2	基础知识	5
2.1	MLLM 的对齐为何特殊	6
2.2	偏好学习的数学基础	6
2.3	幻觉的定义与分类	7
2.4	幻觉的三大成因	7
2.5	安全威胁模型的扩展	8
3	经典方法谱系	8
3.1	对齐：从指令微调到偏好优化	8
3.2	幻觉：度量、归因与缓解	9
3.3	安全：攻击、防御与评测	10
3.4	关键论文一览表	10
4	代表作深度剖析	12
4.1	POPE：给幻觉建立可量化的”体温计” (EMNLP 2023) [11]	12
4.2	VCD：用”看不清”反衬”看得清” (CVPR 2024) [13]	13
4.3	RLHF-V：把”哪里错了、应该怎么改”教给模型 (CVPR 2024) [14]	14
4.4	RLAIF-V：让开源模型自己教自己可信 (CVPR 2025) [16]	15
4.5	FigStep：把禁令印成图片，安全对齐就失效了 (AAAI 2025) [23]	16
4.6	补遗：OPERA 与注意力坍塌的解码侧治理 (CVPR 2024) [49]	16
5	研究前沿（2025-2026）	17
5.1	推理模型的幻觉放大：”思考越多，看见越少”	17
5.2	偏好优化的精细化与统一化	17
5.3	幻觉评估的对抗化与动态化	17
5.4	安全的自动化与体系化	18
6	技术路线对比与权衡	18
6.1	幻觉缓解路线对比	18
6.2	对齐范式对比	19

6.3 攻防权衡	19
6.4 可信 MLLM 的治理视角	19
7 开放问题与未来方向	20
8 研究机会点评（给入门研究者的建议）	21
9 术语表	21
10 参考文献	23

摘要 多模态大模型 (MLLM) 在视觉理解、推理与交互上取得了令人瞩目的进展, 但”能力”并不等于”可信”。本报告系统梳理 MLLM 可信性的三大支柱: 对齐、幻觉与安全。在对齐方面, 我们回顾从纯文本 RLHF/DPO 范式向视觉-语言场景迁移的完整技术谱系, 重点剖析细粒度修正人类反馈 (RLHF-V) 与开源 AI 反馈 (RLAIF-V) 两条路线的取舍, 并讨论 DPO 变体 (HA-DPO、V-DPO、mDPO) 如何处理多模态偏好中的条件忽视问题。在幻觉方面, 我们从语言先验主导、视觉 grounding 不足、数据偏置三大成因出发, 覆盖 CHAIR、POPE、MME、HallusionBench 等度量体系, 以及 VCD 对比解码、OPERA 过信任惩罚、训练侧与数据侧缓解方案。在安全方面, 我们分析视觉对抗样本、排版攻击、跨模态组合攻击三类越狱攻击面, 讨论安全微调、ECSO、BaThe 等防御机制与红队评测体系 (MM-SafetyBench、JailBreakV)。贯穿全报告的方法论立场有二: 其一, 幻觉不是孤立的”bug”, 而是训练数据、跨模态对齐与解码动力学共同作用的系统性症状, 因此有效的治理必须覆盖数据、训练、推理三个层面而非单点修补; 其二, 多模态安全的本质是攻击面的维度升级——连续高维的视觉输入让纯文本时代建立的防线出现结构性真空。报告最后指出: 推理模型的”思考越多、看见越少”现象、对齐税的量化、以及多模态红队的标准化, 是 2025-2026 年最值得关注的开放问题。面向入门研究者, 我们给出了若干算力门槛适中、问题清晰的具体切入点: 解码侧缓解的改进、细粒度幻觉归因、小数据高效对齐与幻觉评测方法论。

1 引言：本方向在多模态版图中的位置

1.1 从”能用”到”可信”

2022 年 Flamingo [1] 与 2023 年 LLaVA [4] 相继证明: 将预训练视觉编码器与大语言模型 (LLM) 桥接, 就能涌现出令人惊讶的视觉-语言能力。此后三年, MLLM 的能力边界被不断推远——从看图答题、文档理解到多步推理与具身操作。然而, 能力曲线快速上扬的同时, 可信性 (trustworthiness) 问题也日益尖锐: 模型会言之凿凿地描述图中不存在的物体 (幻觉); 会被一张看似无害的图片诱导输出有害内容 (越狱); 会在分布外场景突然抛弃训练时学会的安全约束 (对齐脆弱性)。

如果说架构、数据、效率回答的是”MLLM 能做什么”, 那么对齐、幻觉与安全回答的是”MLLM 敢不敢用”。在医疗影像、自动驾驶、内容审核、法律文档等高风险场景, 一次幻觉或一次越狱的代价远超一次普通错误。因此, 可信性研究不是锦上添花, 而是 MLLM 走向真实部署的门票。

值得强调的是, 这三个子问题之间并非并列, 而是层层递进又彼此纠缠的关系。幻觉是**真实性** (honesty) 维度的对齐失败: 模型没有把自己的输出锚定在视觉证据上。越狱是**无害性** (harmlessness) 维度的对齐失败: 模型在特定输入诱导下放弃了安全约束。而两者共享同一个深层根源——跨模态条件下的对齐不充分, 即模型对”以图像为条件”这件事的掌握, 远不如它对”以文本为条件”的掌握。理解这一点, 就能理解为什么本领域的许多工作看似分散 (解码技巧、偏好优化、攻击防御), 实则都在修补同一道裂缝的不同截面。

从产业视角看, 2023 年是幻觉问题被系统度量的一年 (POPE [11]、MME [34]), 2024 年是缓解技术百花齐放的一年 (VCD、OPERA、RLAIF-V、DPO 家族), 2025 年则出现了两个转折: 推理模型的普及让幻觉问题以”长链漂移”的新形态回归, Agentic 应用的兴起则把安全问题从”说什么”扩展到”做什么”。本报告将沿这条演进脉络展开。

1.2 学习地图

阅读本报告建议具备的先修概念：Transformer 与注意力机制；自回归语言建模与解码策略（贪心、采样、束搜索）；视觉编码器（ViT/CLIP）与跨模态桥接（Q-Former、MLP projector）；监督微调（SFT）的基本流程。若对 RLHF 的奖励模型 + PPO 两阶段流程不熟悉，建议先读第 2 节。

本方向的核心问题可归纳为三个：

- 1. **对齐**：如何让 MLLM 的输出符合人类偏好——不仅要”有用”，还要”真实”（不幻觉）、”无害”（不越界）？
- 2. **幻觉**：为什么 MLLM 会生成与图像不符的内容？如何度量、归因与缓解？
- 3. **安全**：多模态输入如何扩大攻击面？如何构建覆盖攻击、防御、评测的完整安全体系？

与其他方向的关系:幻觉与安全问题的根源部分在于视觉-语言对齐不充分(见 vision-language 篇)；评测依赖 benchmark 与 LLM-as-a-judge 方法论（见 benchmarks-eval 篇）；推理模型幻觉放大现象与 test-time compute 研究直接相关（见 frontier 篇）；对齐训练的数据构造属于 data-training 篇的范畴。对 MLLM 整体版图尚不熟悉的读者，建议先读综述 [7] 建立架构与训练流程的全景认知；BLIP-2 [2]、Kosmos-1 [3] 与 Kosmos-2 [5] 则分别代表了桥接式架构、多模态感知对齐与视觉接地（grounding）三条奠基性路线，是理解本报告反复出现的”视觉条件如何进入语言模型”这一问题的技术背景。




图 1 多模态模型三阶段训练流程：预训练对齐、指令微调、偏好对齐

图 1 展示了 MLLM 的标准三阶段训练流程。本报告关注的核心发生在第三阶段——偏好对齐，以及贯穿始终的幻觉与安全问题。

2 基础知识

2.1 MLLM 的对齐为何特殊

在纯文本 LLM 中，对齐（alignment）通常指通过人类反馈让模型输出符合“有用、诚实、无害”（helpful, honest, harmless, 3H）的价值观。将这套范式搬到 MLLM 时，会遇到三个纯文本场景不存在的结构性困难。

第一，条件模态的引入改变了“事实”的定义。文本对齐中，真实性大致可由世界知识判定；而在 MLLM 中，回答的真假必须以当前图像为条件——“图中有几只狗”的正确答案不取决于先验中狗的常见数量，而取决于此刻这张特定的图。这意味着幻觉本质上是一种**条件化失败**：模型没有充分使用视觉条件 v ，而是退化为基于文本先验的生成 $p(y | x_{\text{text}})$ ，而非期望的 $p(y | x_{\text{text}}, v)$ 。

第二，安全对齐可能在模态融合时被稀释。MM-SafetyBench [24] 的实验揭示了一个反直觉现象：即使底层 LLM 已经过严格的安全对齐，接入视觉编码器后，一张与恶意查询语义相关的图片就能让模型“忘记”安全约束，仿佛文本查询本身就是恶意的。这提示视觉特征的注入可能绕过了在纯文本 token 序列上学会的安全路由。

第三，偏好的判定依赖视觉 grounding。标注者比较两个回答哪个更好时，需要核对图像内容；自动奖励模型亦然。这使得多模态偏好数据的标注成本更高、质量更难控制，也催生了“用 AI 反馈替代人类反馈”的研究线（RLAIF-V [16]）。

还有一个更微妙的差异值得指出：**多模态偏好可能是条件性的。**mDPO [20] 的诊断实验表明，直接把文本 DPO 套用到多模态数据上时，模型会学到一种“无条件偏好”——它只根据回答本身的文本特征（长度、流畅度、自信语气）判断好坏，而忽视图像条件。一个语言华丽但与图像无关的回答可能被判为 chosen。这意味着多模态偏好学习必须在目标函数层面显式强化图像条件，否则对齐训练反而可能加剧幻觉：模型学会的是“说得像好答案”，而非“说得对”。

2.2 偏好学习的数学基础

RLHF 两阶段范式。给定提示 x （在多模态场景含图像），模型 π_θ 生成回答 y 。人类标注者对回答对 (y_w, y_l) 给出偏好（ y_w 优于 y_l ）。Bradley-Terry 模型将偏好概率参数化为：

$$P(y_w \succ y_l | x) = \sigma(r_\phi(x, y_w) - r_\phi(x, y_l))$$

其中 r_ϕ 是奖励模型， σ 为 sigmoid。第一阶段通过最大化偏好对数似然训练 r_ϕ ；第二阶段用 PPO [37] 优化策略：

$$\max_{\theta} \mathbb{E}_{y \sim \pi_\theta(\cdot|x)} [r_\phi(x, y)] - \beta \text{KL}(\pi_\theta \| \pi_{\text{ref}})$$

KL 正则项防止策略偏离参考模型 π_{ref} （通常是 SFT 模型）过远，避免奖励黑客（reward hacking）。

DPO：跳过奖励模型。Rafailov 等人 [38] 观察到：在 KL 正则下的最优策略有闭式解，奖励可表示为策略与参考模型的对数比。于是偏好学习可直接对策略做二分类：

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E}_{(x, y_w, y_l)} \log \sigma \left(\beta \log \frac{\pi_\theta(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right)$$

DPO 将两阶段流程压缩为一次监督式优化，训练更稳定、无需在线采样，成为多模态对齐的主流选择（HA-DPO、V-DPO、mDPO 等皆基于此）。

AI 反馈与宪法式对齐。人类反馈昂贵且存在标注者间不一致，Anthropic 的 Constitutional AI [40] 提出替代方案：给模型一组书面原则（“宪法”），让其自我批评初稿回答并修正，再基

于这些自我修正的数据做偏好学习，全程无需人工标注无害性。这一思路奠定了“RLAIF”（AI 反馈强化学习）路线，也是后来多模态侧 RLAIF-V 的直系前身。其哲学预设值得记住：**原则本身来自人类，AI 只是原则的执行放大器**——这与完全放任模型自我定义好坏有本质区别。

GRPO 与序列级变体。DeepSeekMath 提出的 GRPO (Group Relative Policy Optimization) [42] 省略价值网络，对同一提示采样一组回答，用组内相对奖励做优势归一化，显著降低 RL 训练成本。2025 年的 GSPO (Group Sequence Policy Optimization) [36] 进一步将重要性比率从 token 级提升到序列级，缓解了 MoE 模型 RL 训练的不稳定性，为长推理链 MLLM 的 RLHF 提供了更稳的优化器。

2.3 幻觉的定义与分类

幻觉 (hallucination) 指模型生成的内容与输入图像不一致。该术语借自心理学，在图像描述时代就由 CHAIR 论文 [25] 系统化研究。综述 [8][9][10] 通常将其分为四类：

- **对象幻觉**：声称图中存在不存在的物体（“桌上有一只猫”，实际没有）；
- **属性幻觉**：物体的颜色、数量、材质等属性描述错误；
- **关系幻觉**：物体间的空间或交互关系错误（“猫在桌子下面”，实际在桌上）；
- **文本幻觉**：图中 OCR 文字被错误转写或编造。

幻觉与“错误”的区别在于：幻觉输出往往语言流畅、细节具体、自信满满，因此更难被用户察觉，危害也更大。

还有两个与本报告相关但不完全重叠的概念需要区分。其一是**忠实性 (faithfulness) 失败**：模型对图像的理解可能正确，但生成时没有忠实转述（如视觉编码器正确识别了三个苹果，语言头却输出“两个”）；其二是**视觉错觉 (visual illusion)**：图像本身具有歧义或欺骗性（如错觉图），此时“正确”答案本身就依赖上下文。HallusionBench [26] 的贡献之一正是将语言幻觉与视觉错觉放在同一对照框架下诊断——同一张图配两个相互矛盾的问题，检验模型回答的逻辑一致性，从而把“模型说谎”与“图像骗人”分离开来。

2.4 幻觉的三大成因

(a) 语言先验主导。MLLM 的解码本质上是自回归语言建模。POPE 论文 [11] 的关键发现是：在视觉指令中高频出现的对象、以及与图中对象高频共现的对象（如“桌子-椅子”），最容易被幻觉出来。模型学到了 $P(\text{chair} | \text{table})$ 的语言统计规律，在视觉证据不足时用它“脑补”。

(b) 视觉 grounding 不足。视觉 token 经过 projector 进入 LLM 后，在深层注意力中的影响力可能衰减。OPERA [49] 观察到：生成回答时，模型的注意力会坍缩到少数几个“summary token”上，后续 token 的生成几乎不再“看”图像，从而脱离视觉事实。More Thinking, Less Seeing [30] 进一步发现：长推理链会系统性地减少对视觉 token 的注意力分配。

(c) 数据偏置。视觉指令微调数据（如 LLaVA 的 GPT-4 生成数据 [4]）存在系统性偏差：问题集中于常见物体、答案风格单一、负样本稀缺。模型因此倾向于回答“是”（存在性偏置）、描述常见场景模板。LRV-Instruction [12] 正是通过在指令数据中引入负样本与反事实样本来缓解这一问题。

三个成因之间存在因果链：数据偏置塑造了语言先验的具体内容（哪些物体共现、答案该是什么风格）；视觉 grounding 不足决定了模型在多大程度上依赖先验而非证据；而解码动力学（注意力坍塌、长链漂移）则是先验最终“接管”生成的执行机制。这解释了为什么单一干预往往效果有限——只改数据不改解码，先验仍会在长生成中渗透；只改解码不改数据，模型内部的错误关联依然存在。有效的幻觉治理需要沿因果链多点设防，这也是 §6.1 对比表格背后的设计逻辑。

2.5 安全威胁模型的扩展

纯文本 LLM 的输入是离散 token，攻击者需要在离散空间中搜索绕过安全过滤的措辞，难度较高。MLLM 引入连续、高维的图像输入后，攻击面发生质变 [22]：

- **视觉对抗样本**：在图像上叠加人眼不可察觉的扰动，直接操纵视觉编码器的输出特征，可诱导模型执行攻击者指定的任意行为；
- **排版攻击 (typographic attack)**：把有害指令渲染成图片中的文字。文本安全过滤器看到的是无害的图片描述，而视觉通路把指令“走私”进模型 (FigStep [23])；
- **跨模态组合攻击**：单独的文本和图像都无害，组合起来才构成恶意图 (例如无害图片 + 隐晦文本提示)，绕过单模态审核。

防御侧对应三个层次：输入侧（图像净化、ECSO 式的图像转文本 [31]）、模型侧（安全微调、对抗训练、BaThe 的后门触发器视角 [32]）、输出侧（安全解码、内容过滤）。红队评测 (MM-SafetyBench [24]、JailBreakV [33]) 则为攻防提供统一的度量。

理解多模态安全需要建立**威胁模型**的自觉：攻击者知道什么、能控制什么、目标是什么？按知识水平分，白盒攻击（掌握模型权重与梯度，如视觉对抗扰动 [22]）威力最强但部署条件苛刻；黑盒攻击（仅能查询，如 FigStep [23]）更贴近真实滥用场景。按目标分，jailbreak 追求让模型输出受限内容（暴力、违法教程、仇恨言论），而更广义的对抗目标还包括隐私提取（诱导模型复述训练数据中的人脸或文本）与行为劫持（在 Agentic 场景诱导模型执行恶意工具调用）。本报告聚焦 jailbreak 这一当前研究最充分的目标，但其防御思想大多可迁移。

3 经典方法谱系

3.1 对齐：从指令微调到偏好优化

MLLM 对齐的技术底座来自纯文本时代。InstructGPT (OpenAI, 2022) 确立了“SFT + 奖励模型 + PPO”的 RLHF 三步法，Anthropic 同年提出 Constitutional AI [40]，用一组书面原则让 AI 自我批评、自我修正，把无害性反馈的生产也交给模型——这条“AI 反馈”路线日后直接启发了多模态侧的 RLAIIF-V。2023 年 DPO [38] 的出现进一步降低了对齐门槛：无需在线采样与奖励模型，偏好学习退化为一次监督式优化，使资源有限的团队也能做对齐实验。这些文本侧的工具在 2023 年中被整体搬运到视觉-语言场景，但搬运过程中暴露出的不匹配——条件忽视、视觉 grounding 缺失、标注成本倍增——正是 §3.1 后半段那些多模态原生方法要解决的问题。

MLLM 对齐的起点是**视觉指令微调**。LLaVA [4] (2023) 用 GPT-4 生成 15 万余条视觉指

令数据，证明冻结视觉编码器 + 训练 projector + 微调 LLM 即可获得通用视觉助手；Instruct-BLIP [6] (2023) 系统研究了指令微调的任务组织方式，将 26 个数据集统一为指令格式。这一阶段解决的是“让模型听懂指令”的对齐，但未处理真实性——事实上，LLaVA 的数据生产方式本身就埋下了幻觉的种子：GPT-4 只能看到图像的文本化表示（caption 与检测框），它生成的“详细描述”类指令答案中不可避免地包含对视觉细节的臆测，模型在这些数据上微调，等于系统性地学习“语言流畅但视觉无据”的生成风格。POPE [11] 后来用数据证实了这一点：指令数据中高频出现的物体，恰恰是最容易被幻觉的物体。

偏好对齐阶段（2023 下半年起）：

- **LLaVA-RLHF** [17] (2023) 首次将 RLHF 迁移到视觉-语言场景，并提出 Factually Augmented RLHF：在奖励模型中注入额外的图像事实信息，缓解纯偏好标注无法捕捉的事实性错误。
- **Silkie** [15] (2023) 提出“偏好蒸馏”：用 GPT-4V 生成大规模偏好数据集，通过 DPO 蒸馏到开源模型，绕开昂贵的在线 RL。
- **RLHF-V** [14] (2023) 与 **RLAIF-V** [16] (2024) 构成人类反馈 vs AI 反馈的标志性对照，详见第 4 节。
- **DPO 变体群** (2023–2024)：HA-DPO [18] 构建幻觉-非幻觉偏好对；V-DPO [19] 引入视觉引导对比；mDPO [20] 诊断并修复“无条件偏好”问题（模型偏好学习时忽略图像条件，只学文本偏好）；MPO [21] 混合多种偏好信号以提升推理能力。
- **奖励模型与 RL 算法** (2025)：Skywork-VL Reward [35] 训练覆盖理解与推理的多模态奖励模型；GSPO [36] 将 GRPO 的 token 级比率提升为序列级，稳定长序列 RL 训练。

3.2 幻觉：度量、归因与缓解

度量体系按时间演进：CHAIR [25] (2018, 图像描述时代) → POPE [11] (2023, 轮询式探测) → MME [34] (2023, 含幻觉子任务的综合基准) → HallusionBench [26] (2024, 语言幻觉与视觉错觉的纠缠诊断) → MMVP [27] / BLINK [28] / MMStar [29] (2024, 揭示模型“视而不见”与感知短板)。

CHAIR 值得单独一提。它要求生成式图像描述模型在带有物体标注的图像上生成 caption，然后计算两类指标：CHAIR_i（生成句子中提及的物体里，不在图像标注中的比例）与 CHAIR_s（至少包含一个幻觉物体的句子比例）。该工作还做出两个影响深远的诊断：其一，标准 caption 指标（BLEU、CIDEr）与幻觉率相关性很弱——“像人话”不等于“说真话”，这直接推动了后来 POPE 等专门度量的诞生；其二，通过对比不同解码与训练设置，作者发现幻觉既可能来自视觉误识别，也可能来自纯粹的语言先验（如 caption 训练集中“人拿着滑板”的高频搭配），这一二分法至今仍是幻觉归因的基本框架。MME [34] 则从评测供给侧推动了领域成熟：作为首个系统的 MLLM 综合基准，它将幻觉（存在性与数量判断）纳入 14 个子任务，使“幻觉率”成为每个新模型的必报指标；MMBench [48] 与 MM-Vet [47] 随后从不同侧面（全方位能力、综合能力与 LLM-as-a-judge 评分）完善了评测生态。

缓解路线分四类：

路线	代表	思想	代价
数据侧	LRV-Instruction [12]	指令数据注入负样本、反事实样本	需重训
训练侧	RLHF-V/RLAIF-V/HA-DPO [14][16][18]	用偏好学习惩罚幻觉	需偏好数据与训练
推理侧（解码）	VCD [13→ 见 §4]、OPERA [见 §4]	修改解码分布或注意力	零训练成本，略增延迟
后处理	Woodpecker [39]	五阶段流水线检测并修正幻觉	依赖外部工具链

3.3 安全：攻击、防御与评测

攻击侧（详见 2.5 节）：视觉对抗样本 [22]、FigStep 排版攻击 [23]、跨模态组合攻击（MM-SafetyBench [24] 的 query-relevant image 攻击即属此类）。其中视觉对抗样本工作 [22] 的警示尤为深刻：作者指出，视觉输入连续且高维的特性使其成为整条链路上最薄弱的一环，而 LLM 的通用性又把对抗成功的后果从传统的”误分类”扩展为”任意行为”——攻击者可以优化单张对抗图像，让模型对一整批有害问题都给出顺从回答。这意味着一次白盒优化的产物可以成为通用的越狱钥匙，其危害远超传统的单点攻击。

防御侧：安全微调（在指令微调阶段注入安全偏好数据）；ECSO [31] 将图像先转文本描述再交给安全对齐的 LLM，牺牲部分视觉能力换取安全性；BaThe [32] 把越狱指令视作后门触发器，通过对比学习中和触发模式；SmoothGuard [40]（2025）用推理时噪声扰动 + 多次前向聚合实现免训练鲁棒化。

评测体系：MM-SafetyBench [24]（13 类场景、5040 对图文）、JailBreakV [33]（JailBreakV-28K，评估文本越狱技术向 MLLM 的迁移性）、OmniSafeBench-MM [41]（2025，统一攻防工具箱，整合 20+ 攻击算法与 10+ 防御策略）。

将三者连起来看，可以读出一条清晰的演进逻辑：MM-SafetyBench 回答”MLLM 在图像参与下有多不安全”（诊断），JailBreakV 回答”文本时代的攻击武器有多少能直接搬过来”（迁移性量化），OmniSafeBench-MM 则试图把攻防实验工程化、流水线化（标准化）。这条线索的另一面是红队文化的形成：从 2023 年各模型厂商零散的内部测试，到 2025 年出现公开的、可复用的红队工具链，多模态安全正从”论文里的攻击演示”走向”持续的安全运营”。

3.4 关键论文一览表

论文	年份	核心思想	架构/方法要点	备注
CHAIR [25]	2018	首个对象幻觉度量	基于物体标注的幻觉率指标	前 LLM 时代的奠基
LLaVA [4]	2023	视觉指令微调范式	ViT + MLP projector + Vicuna	对齐起点，也埋下幻觉隐患

论文	年份	核心思想	架构/方法要点	备注
LLaVA-RLHF [17]	2023	RLHF 迁移到 VLM	事实增强奖励模型 + PPO	首个多模态 RLHF
POPE [11]	2023	对象幻觉轮询评估	Yes/No 探测 + 三种采样策略	幻觉度量的标准范式
LRV-Instruction [12]	2023	鲁棒指令微调	400K 指令含负样本	数据侧缓解
VCD [13]	2023	视觉对比解码	原始 vs 失真图像分布对比	免训练、即插即用
OPERA [49]	2023	过信任惩罚解码	注意力坍塌检测 + 回溯	免训练、机制优雅
Woodpecker [18]	2023	幻觉后修正	五阶段修正流水线	免训练、可解释
RLHF-V [14]	2023	细粒度修正人类反馈	片段级修正标注 + 稠密 DPO	1.4K 样本高效对齐
Silkie [44]	2023	偏好蒸馏	GPT-4V 偏好数据 + DPO	低成本对齐路线
HA-DPO [18]	2023	幻觉感知 DPO	幻觉-非幻觉偏好对	DPO 多模态化开端
V-Adversarial [22]	2023	视觉对抗越狱	连续扰动攻击视觉编码器	揭示高维攻击面
FigStep [23]	2023	排版攻击越狱	有害指令渲染为图像文字	黑盒、高成功率
MM-SafetyBench [24]	2023	多模态安全基准	13 场景、query-relevant 图像	安全评测标准
RLAIF-V [16]	2024	开源 AI 反馈对齐	多轮自我批评生成偏好	超 GPT-4V 可信度 (开源)
mDPO [20]	2024	条件偏好优化	图像条件偏好 + 奖励锚点	修复无条件偏好问题
JailBreakV [33]	2024	越狱迁移性基准	28K 恶意查询迁移评估	文本攻击 → MLLM
MMVP [27] / BLINK [28]	2024	视觉感知短板诊断	视觉模式失败案例集	”视而不见”现象

论文	年份	核心思想	架构/方法要点	备注
HallusionBenchmark [26]	2024	幻觉-错觉纠缠诊断	人工设计对照组	语言幻觉 vs 视觉错觉
ECSSO [31]	2024	图像转文本防御	视觉内容文本化 + 文本安全机制	免训练防御
BaThe [32]	2024	后门视角防御	有害指令即触发器 + 对比学习	新颖威胁建模
Skywork-VL Reward [35]	2025	多模态奖励模型	Qwen2.5-VL-7B + 奖励头	理解 + 推理双覆盖
GSPO [36]	2025	序列级策略优化	序列似然重要性比率	长推理 RL 稳定化
More Thinking, Less Seeing [30]	2025	推理幻觉放大诊断	RH-AUC 度量	R1-style 模型警示
SmoothGuard [40]	2025	免训练对抗防御	噪声扰动 + 聚类聚合	推理时防御
OmniSafeBenchmark MM [41]	2025	统一攻防工具箱	攻击生成 + 防御评估 + 红队自动化	安全工程化

4 代表作深度剖析

本节深入剖析五篇代表作：POPE（幻觉度量范式）、VCD（推理侧缓解）、RLHF-V 与 RLAIIF-V（对齐两路线对照）、FigStep（越狱攻击代表）。选择标准：问题定义清晰、方法有普适启发、可复现性好。

4.1 POPE：给幻觉建立可量化的”体温计”（EMNLP 2023） [11]

研究问题。 2023 年中，MLLM 的幻觉已是公开的秘密，但缺乏系统度量：此前研究多用人工抽查或 CHAIR（依赖物体标注，且设计于描述生成任务），无法快速、自动地比较不同模型的幻觉程度。

关键洞察。 对象幻觉可以被转化为一个极简的二分类探测问题：直接问模型”图中是否存在物体 X？”这种轮询（polling）式探测把开放生成转化为可自动判分的判别任务，绕开了自由文本评估的困难。

技术方法。 POPE 基于 COCO 验证集构造探测问题，对每张图采样若干物体提问。物体分三类采样：

- **Random：**从 COCO 物体全集随机抽，图中不存在的即为负样本；

- **Popular**: 按数据集中的全局出现频率选高频物体;
- **Adversarial**: 选与图中已存在物体高频共现的物体 (如图中有人则问”是否有滑板”)。

后两种采样策略刻意放大语言先验的诱导作用。评估指标为准确率、精确率、召回率与 F1, 并按 Yes/No 比例分析模型的回答偏置。评估对象包括 MiniGPT-4、LLaVA、InstructBLIP、mPLUG-Owl 等当时的主流模型。

实验结果。论文展示了三个关键现象: (i) 所有受测模型都存在显著的对象幻觉, 尤其在 Popular 与 Adversarial 设置下, 模型对不存在的物体也频繁回答”是”; (ii) 指令微调数据 (visual instructions) 中高频出现的物体最容易被幻觉——幻觉与训练数据的物体分布强相关; (iii) 模型普遍存在”说是”偏置, Adversarial 设置下的召回率畸高而精确率骤降。第三点在 Adversarial 采样下表现得淋漓尽致: 当问题刻意挑选与图中物体高频共现的目标 (如看到人问”是否有手机”), 多个模型的 Yes 比例显著超过 Random 设置, 证明幻觉不是随机噪声, 而是可被语言统计规律系统性预测的行为。

批判性分析。优点: 范式极简、全自动、无需人工标注, 将幻觉从轶事变成可比较的标量, 成为后续几乎所有幻觉工作的标准评测。局限: (i) Yes/No 探测测的是”判别能力”而非”生成中的幻觉倾向”, 模型判别强不代表生成时不说谎 (后续 AMBER、HallusionBench 等补充了生成式评估); (ii) 仅覆盖对象幻觉, 属性与关系幻觉不在射程内; (iii) 基于 COCO 物体词表, 对开放世界场景的泛化有限。可复现性极佳, 数据与评测脚本均开源。

一句话评价: 幻觉研究的”定标之作”——它最大的贡献不是方法新颖, 而是把模糊的抱怨变成精确的度量。评级: ★★★★★ (必读)。

4.2 VCD: 用”看不清”反衬”看得清” (CVPR 2024) [13]

研究问题。既然幻觉源于语言先验与统计偏差的过度主导, 能否在不重新训练的前提下, 在解码时就把这部分”非视觉”成分剥离掉?

关键洞察。幻觉 token 有一个可利用的指纹: 它们对视觉输入的变化不敏感。一个”真实”的物体词 (图中确实有) 应当强烈依赖图像内容; 而一个幻觉词 (如被语言先验诱导的”椅子”) 即使在图像被扰动、视觉信息退化时, 仍会被语言模型以相近的概率生成。VCD (Visual Contrastive Decoding) 的洞察是: 用失真图像作为”对照组”, 对比两个解码分布, 就能抑制不依赖视觉的 token。

技术方法。形式化地, 设原始视觉输入为 v , 失真版本为 v' (对图像加高斯噪声扰动视觉编码器的输入)。在第 t 步解码时, VCD 构造对比分布:

$$p_{\text{vcd}}(y_t) \propto \exp((1 + \alpha) \mathcal{F}(y_t | x, v) - \alpha \mathcal{F}(y_t | x, v'))$$

其中 $\mathcal{F}$ 为对数概率 (logit 的 softmax 归一化), α 为放大系数。直觉: 若某 token 在两个分布中概率相近 (不依赖视觉), 其 logit 差接近零, 对比后得不到增益; 若 token 真正由视觉证据支持, 原始分布的概率显著高于失真分布, 对比后被放大。VCD 还引入自适应合理性约束 (adaptive plausibility constraint), 只在原始分布高置信的候选 token 集合内做对比, 防止放大噪声。

实验结果。在 POPE 上, VCD 使 LLaVA-1.5、MiniGPT-4、InstructBLIP 等模型的 F1 稳定提升; 在 MME 幻觉子集与开放式描述评估 (GPT-4 辅助) 上, 对象幻觉率显著下降, 且无需任何训练或外部知识。消融显示失真程度与放大系数存在甜点区间: 扰动太弱则对比无效

息量，太强则损伤正常生成。

批判性分析。优点：零训练成本、即插即用、理论动机清晰（直接对应 2.4 节的成因 (a)），工程价值极高。局限：(i) 每步解码需两次前向（原始 + 失真），推理开销约翻倍，在高吞吐部署中代价可观；(ii) 对“失真”的设计敏感，高斯噪声是粗糙的视觉退化近似——它均匀地破坏所有视觉信息，而真实的幻觉往往由特定类型的 grounding 失败（小物体、遮挡、罕见属性）触发，针对性失真（如掩蔽特定区域）是尚未充分探索的方向；(iii) 只缓解对象层面的幻觉，对复杂关系与推理幻觉作用有限；(iv) 本质是“症状治疗”，没有改变模型内部的表征缺陷——模型仍然学到了错误的视觉-语言关联，只是解码时被外部校正压住了。可复现性好，官方代码开源。

与同宗方法的关系也值得一提：VCD 继承自文本域的对比解码思想（用大模型与小模型、或强提示与弱提示的分布差来放大“真正由能力贡献”的信号），其贡献在于找到了视觉域合适的“弱分布”构造——失真图像。这一构造的普适性使其迅速成为幻觉缓解的标准基线，后续的 M3ID、ICD 等工作大多是在“如何构造更好的对照分布”这一轴上做文章。

一句话评价：对比解码思想在视觉域的优雅落地——证明了“制造一个更差的自己”可以成为自我纠错的工具。评级：★★★★☆。

4.3 RLHF-V：把“哪里错了、应该怎么改”教给模型（CVPR 2024）[14]

研究问题。LLaVA-RLHF [17] 已验证 RLHF 可迁移到多模态，但其偏好标注是回答级(response-level)的二选一比较。这种粗粒度信号有两个问题：标注者只说“A 比 B 好”，模型却不知道好在哪里、差在哪一句；且回答级奖励对长文本中的局部幻觉定位不准，信用分配(credit assignment)困难。此外，多模态人类偏好数据标注昂贵，样本效率成为瓶颈。

关键洞察。与其让标注者做相对排序，不如让他们**直接修正错误**：把幻觉片段划出来并改写为正确描述。这种“修正性反馈”(correctional feedback)信息密度远高于偏好排序——一次修正同时给出了负样本（原片段）、正样本（修正片段）与精确的错误位置。RLHF-V 赌的是：少量高密度数据胜过大量低密度数据。

技术方法。RLHF-V 的贡献分两层：

(1) 细粒度修正标注。标注者在 MLLM 生成的回答上做片段级(segment-level)修正：定位幻觉片段，直接改写为与图像一致的表述。最终仅用约 1.4K 条修正数据（覆盖幻觉回答的修正对）。

(2) 稠密直接偏好优化 (Dense DPO)。标准 DPO 对整条回答给一个偏好标签；RLHF-V 将偏好信号稠密化到片段级：被修正的片段作为 rejected，修正后片段作为 chosen，在 DPO 损失中对幻觉片段施加更强的对数比惩罚。其损失可视为在式 (DPO) 基础上，将片段级对比项加权聚合，使梯度精确流向出错的 token 区间而非平均分摊到整个序列。

实验结果。在 MME、POPE、AMBER 等五个基准的自动与人工评估上，RLHF-V 微调的 Muffin-13B 在可信度上超过同规模基线（包括 LLaVA-RLHF），同时保持了通用能力不退化。尤其值得注意的是样本效率：约 1.4K 修正样本即带来显著幻觉降低，对比 Silkie [15] 依赖的大规模 GPT-4V 偏好蒸馏，数据量小了一个数量级以上。

批判性分析。优点：(i) 修正性反馈的数据效率论证令人信服，为资源有限的实验室提供了可行的对齐路径；(ii) 片段级稠密监督解决了回答级奖励的信用分配问题，技术上干净利落；(iii) 人类评估 + 自动评估双轨，结论扎实。局限：(i) 1.4K 数据来自特定模型 (Muffin) 的输

出分布，迁移到输出风格迥异的模型时是否需要重新采样修正，论文讨论有限；(ii) 片段级标注虽然总量小，但单条标注的认知负担与成本高于成对排序，规模化路径不明朗；(iii) 主要缓解幻觉，对无害性（安全对齐）未做系统验证。可复现性良好，数据与代码开源。

与前后工作的关系上，RLHF-V 恰好位于 LLaVA-RLHF [17] 与 RLAIIF-V [16] 之间的光谱中点：LLaVA-RLHF 用回答级人类偏好 + 在线 PPO，反馈密度低、训练开销大；RLAIIF-V 用模型自反馈，密度高、零人力但有自我指涉上限；RLHF-V 则证明人类反馈经过“修正化”改造后也能达到高密度，且保留了人类判断对系统性盲区的覆盖能力。这条光谱本身就是多模态对齐方法论演进的最佳注脚。

一句话评价：用“改作业”替代“打分数”——证明了反馈的密度可以补偿反馈的数量。评级：★★★★★。

4.4 RLAIIF-V：让开源模型自己教自己可信（CVPR 2025）[16]

研究问题。 RLHF-V 的数据虽少但仍需人工；Silkie 依赖 GPT-4V 这类闭源模型产偏好数据，成本高且有“蒸馏上限”（学生难以超越老师）。能否完全用开源 MLLM 自动生成高质量偏好反馈，实现不依赖人类与闭源模型的对齐？

关键洞察。同一模型对同一问题的多个回答之间存在质量方差；如果能让模型自我批评——指出自己回答中的幻觉并生成修正版本——就能构造出 chosen/rejected 偏好对。关键挑战是自我反馈的可靠性：模型可能“自圆其说”。RLAIIF-V 的解法是把反馈生成分解为多个小步骤（逐段声明抽取 → 逐声明追问核对），用小步验证降低单步判断的出错率。

技术方法。 RLAIIF-V 的流水线：(i) 对指令-图像对采样多个候选回答；(ii) 将回答分解为原子声明（atomic claims）；(iii) 对每个声明构造针对性的追问（如“图中真的有 X 吗”），用模型自身的回答验证声明真假，实现自反馈的声明级核验；(iv) 依据核验结果将回答分为偏好对，用 DPO 类目标训练。推理阶段，RLAIIF-V 还探索了自反馈引导的推理时扩展（inference-time scaling）：生成多候选后用自我反馈重排序。

实验结果。六个基准的自动与人工评估显示：RLAIIF-V 7B 的对象幻觉相对基线降低 80.7%（按论文报告的 POPE 类指标口径），总体幻觉降低 33.7%；RLAIIF-V 12B 在可信度上超过 GPT-4V（在论文采用的评测口径下），并展现出“自对齐潜力”——模型用自己生成的反馈改进自己，形成闭环。这一结果对开源社区意义重大：可信对齐不再是闭源巨头的专利。

批判性分析。优点：(i) 全开源范式，方法论上打通了“自我改进”路径，成本极低；(ii) 声明级分解核验是对“自我批评不可靠”问题的务实工程解法——它暗合一个认知科学直觉：整体判断容易自欺，逐步核验难以自圆其说；(iii) 训练侧与推理侧（best-of-N 重排序）双管齐下，同一份自反馈能力被复用两次，设计上很经济。局限：(i) 自我反馈的天花板问题未被根本解决——模型无法核验自己“完全看不见”的东西，对系统性视觉盲区的幻觉（MMVP [27] 揭示的感知失败）无能为力；换言之，RLAIIF-V 能修正“看见了但说错了”，却修不了“根本没看见”；(ii) “超过 GPT-4V”的结论严格限定在特定幻觉基准口径，不应外推为全面超越；(iii) 声明核验依赖模型自身的判别能力，判别与生成能力耦合——一个判别能力弱的模型，其自反馈噪声会污染偏好数据，形成“越弱越教不好自己”的负循环，论文未系统给出判别能力门槛的消融；(iv) 多轮追问流水线使偏好数据的生成成本随回答长度线性增长，规模化时的实际开销需要核算。可复现性好，代码与数据开源。

一句话评价：对齐民主化的标志性工作——它证明反馈的“生产者”可以是模型自己，但

也提醒我们自我指涉的改进存在理论上限。评级：★★★★★。

RLHF-V vs RLAIIF-V 对照：前者相信”人的修正最可靠”，用极高密度的人类反馈换取样本效率；后者相信”机器反馈可规模化”，用工程化的自我核验换取零人力成本。实践中两者可组合：用 RLAIIF-V 生成海量初筛偏好，用少量人类修正兜底高难度案例。

4.5 FigStep：把禁令印成图片，安全对齐就失效了（AAAI 2025）[23]

研究问题。主流 MLLM 部署时通常在文本通路设安全过滤（输入审核 + 安全对齐）。攻击者能否利用视觉通路绕过这些防线？

关键洞察。MLLM 的安全对齐几乎全部建立在文本 token 序列上；而视觉编码器把图像映射为连续特征后，这些特征**未经任何安全检查**直接进入 LLM。如果把有害指令从文本通道转移到图像通道——用排版（typography）把禁令文字渲染成图片——文本过滤器看到的是无害文本，而模型的 OCR 能力会把指令从图中”读”出来并执行。安全对齐出现了跨模态的”真空地带”。

技术方法。FigStep 是一个三步黑盒攻击：(i) 将有害指令（如”如何制造 X”）改写为分步列表形式；(ii) 用排版工具将每个步骤的文字渲染成单独的图像；(iii) 向 MLLM 发送这些图像，配一段良性文本提示（如”图片中是一些步骤，请补全细节”）。全程无需梯度访问、无需对抗扰动优化，是纯查询级黑盒攻击。作者在六个主流开源 MLLM 上评估，报告平均攻击成功率达 82.50%。

实验结果与后续影响。FigStep 揭示的不仅是单点漏洞，而是一类系统性缺陷：视觉通路与文本通路的安全水位不一致。后续 MM-SafetyBench [24] 将此类攻击扩展到 query-relevant image 设置（图像本身语义相关，配合无害文本完成越狱），覆盖 13 类场景；JailBreakV [33] 则系统测量了文本越狱技术向 MLLM 的迁移率。防御侧的 ECSO [31] 直接针对此漏洞：既然危险藏在图像通道，就先把图像转成文本描述，复用文本安全机制。

批判性分析。优点：(i) 攻击极其简单却高效，说明问题的结构性而非技术性——这正是最有价值的安全研究；(ii) 黑盒设定贴近真实威胁模型；(iii) 附带对失败模式的分析（如模型 OCR 能力与安全能力的剪刀差）有诊断价值。局限：(i) 对 OCR 能力弱的模型天然免疫，攻击成功率与模型视觉能力正相关——越强的模型越危险，这一悖论值得深思；(ii) 论文以攻击演示为主，提出的防御讨论相对初步；(iii) 攻击模式相对固定，简单的图像文字检测器即可部分拦截，真实攻防会快速演化。可复现性好。

一句话评价：一行排版代码击穿全部安全对齐——它用最朴素的方式证明了多模态安全必须从”文本防线”升级为”全通道防线”。评级：★★★★☆（安全方向必读）。

4.6 补遗：OPERA 与注意力坍塌的解码侧治理（CVPR 2024）[49]

与 VCD 同年出现的 OPERA [49] 是推理侧缓解的另一极，值得作为对照案例理解。VCD 的对照轴是”视觉输入的有无”，OPERA 的对照轴则是”注意力的分布形态”。其出发观察是：MLLM 生成答案时，自注意力矩阵中会出现知识聚合模式——后续 token 的注意力高度集中于少数几个 summary token（通常是序列早期的锚点），而不再均匀回看包括视觉 token 在内的历史内容。一旦生成被这些”摘要锚点”接管，输出就脱离了视觉事实的约束，幻觉随之而来。

OPERA 的机制分两步：**过信任惩罚**（over-trust penalty）在 beam search 的候选打分中，

对注意力过度集中的 token 施加惩罚，抑制“不再看图”的生成路径；**回溯分配**（retrospection-allocation）则检测惩罚集中出现的位置，回滚到 summary token 处重新选择候选词。其吸引力在于机制层面的解释力——它把幻觉与可观测的注意力几何结构关联起来，为“为什么长答案更容易幻觉”给出了一个具体、可检验的答案（这一解释后来被 More Thinking, Less Seeing [30] 在推理模型上再次印证）。局限同样明显：依赖 beam search 使其与当前主流的采样解码不兼容，且注意力坍塌是否为幻觉的“因”而非伴随现象，学界仍有讨论。作为诊断工具，它的价值不低于作为缓解工具的价值。

5 研究前沿 (2025-2026)

5.1 推理模型的幻觉放大：“思考越多，看见越少”

o1/R1 风格的长思维链（long CoT）模型在数学与逻辑任务上突飞猛进，但 More Thinking, Less Seeing [30] 揭示了其阴暗面：随着推理链变长，模型注意力逐渐从视觉 token 漂移到文本上下文，对语言先验的依赖加深，视觉推理任务上的幻觉率显著高于非推理基座。该文提出 RH-AUC 指标量化“感知准确率随推理长度的衰减曲线”，使这一现象可测量。这对 2025-2026 年大量部署的 R1-style 多模态模型是直接警示：**推理能力与感知忠实度可能此消彼长**，需要专门的视觉推理对齐策略（如推理链中强制视觉回查、对视觉证据引用的奖励塑形）。GSPO [36] 等序列级 RL 算法为长链训练提供了稳定化工具，但算法稳定性不解决目标设计问题——奖励什么行为，模型就强化什么行为。

5.2 偏好优化的精细化与统一化

DPO 家族持续分化：mDPO [20] 修复图像条件被忽视的问题，V-DPO [19] 引入视觉引导对比，MPO [21] 混合偏好信号提升推理。2025 年的趋势是**奖励模型的专门化**（Skywork-VL Reward [35] 同时覆盖理解与推理奖励）与**对齐目标的多元化**：从单一“减少幻觉”扩展到真实性、无害性、诚实性（不知为不知）三维对齐。综述 [10] 指出，2025 年对齐研究正从“有用性”单目标向 3H 三维度扩展，多目标间的权衡（如对无害性的过度优化损伤有用性，即“对齐税”）开始被系统量化。

诚实性维度尤其值得关注。传统幻觉缓解的目标是“少说错话”，但更理想的行为是“知道自己不知道”：当视觉证据不足时，模型应当表达不确定性或拒绝断言，而非强行生成自信的答案。这类“校准式对齐”需要新的偏好数据形态（对“合理拒答”给予正奖励）与新的评测口径（区分“拒答率”与“错误率”），目前仍处于早期探索阶段。可以预期，随着 MLLM 进入医疗、法律等对过度自信零容忍的场景，诚实性对齐会从边缘话题变为核心议题。

5.3 幻觉评估的对抗化与动态化

静态基准（POPE、MME）面临污染与饱和：模型可以“背题”。2025 年的方向是动态、对抗性评估——MMStar [29] 筛除可纯文本作答的“视觉非必要”样本以杜绝数据泄漏；BLINK [28] 聚焦“看见但未感知”的细粒度感知失败；综述 [46] 系统梳理了 2023-2025 年幻觉评估从静态基准向动态对抗评估的演进，并分析了 LLM-as-a-judge 与人工评估的一致性差距。ClearSight [43] (2025) 则代表缓解侧新思路：在视觉信号通路本身做增强，而非仅在解码或数据层面补救。

还有两个值得关注的评测扩展方向。其一是**视频幻觉**：随着视频理解模型普及，幻觉从静态物体扩展到时序事件（动作顺序、因果关系、持续时间），评估需要在时间维度上定位幻觉片段，难度远高于静态图像。其二是**跨模态一致性的内生度量**：与其用外部基准事后检测，不如让模型在生成时自我报告视觉证据强度（如每个物体词附带来源 token 的注意力溯源），将幻觉检测从”外部审计”变为”内生信号”。ClearSight [43] 代表的视觉信号增强路线与此互补：一个在证据入口处加固，一个在证据使用处留痕。

5.4 安全的自动化与体系化

多模态红队从手工构造走向自动化：OmniSafeBench-MM [41] 整合攻击生成、防御评估与红队自动化为统一工具链，支持 20 余种攻击与 10 余种防御的标准化对比；SmoothGuard [40] 的推理时随机化防御无需重训即可部署。治理层面，Agentic MLLM（调用工具、浏览网页、执行代码）把攻击面从”内容生成”扩展到”行动执行”，安全研究开始关注**行为级安全**——不仅要过滤说什么，还要审计做什么。

6 技术路线对比与权衡

6.1 幻觉缓解路线对比

维度	数据侧（LRV-Inst [12]）	训练侧（RLHF-V/RLAIF-V）	解码侧（VCD/OPERA）	后处理（Woodpecker）
训练成本	高（全量微调）	中（偏好数据 +DPO）	零	零
推理开销	无额外	无额外	约 1.5-2×	高（多轮工具调用）
缓解上限	高（改表征）	高（改行为）	中（治标）	中（依赖检测精度）
泛化性	受数据分布限制	受偏好覆盖限制	与模型无关、通用	依赖外部视觉工具
可组合性	与所有路线兼容	与解码侧兼容	可叠加于任何模型	可叠加于任何模型

权衡分析。工程实践中的常见组合是”训练侧打底 + 解码侧兜底”：先用 RLAIF-V 式低成本

本偏好训练把幻觉率压低一个台阶，部署时再叠加 VCD/OPERA 做零成本的进一步抑制。后处理路线（Woodpecker）适合对延迟不敏感、对准确率敏感的场景（如医疗报告生成）。纯数据侧方案的风险在于：负样本会同时抑制模型的描述丰富度，需要在”多说多错”与”少说少错”之间校准——过度使用负样本会让模型变得”什么都说没有”，把幻觉率换成了召回率的损失，这同样是一种不可信。

一个常被忽视的维度是**评估口径与优化目标的错配**。POPE 式判别指标改善，不必然意味着开放式生成中幻觉减少：模型可以学会在 Yes/No 探测中更谨慎，却在自由描述时依旧幻觉。因此选择缓解路线时，应同步确认其论文中的验证是否覆盖自己关心的生成形态；同样，报告自己方法的收益时，也应在判别式与生成式两类口径下分别呈现，避免”指标套利”。

6.2 对齐范式对比

范式	代表	反馈来源	成本	质量上限	风险
在线 RLHF	LLaVA-RLHF [17]	人类 + 奖励模型	最高	高	训练不稳定、奖励黑客
偏好蒸馏	Silkie [15]	闭源强模型	中	受教师上限约束	蒸馏偏见继承
细粒度人类修正	RLHF-V [14]	人类（稠密）	低（1.4K 级）	高	单条标注认知负担重
AI 自反馈	RLAIF-V [16]	开源模型自身	最低	受自我核验能力约束	系统性盲区无法自纠
DPO 变体	HA-DPO/V-DPO/mDPO	多种	低	依偏好数据质量	无条件偏好、多样性坍缩

6.3 攻防权衡

防御没有银弹。ECSO [31] 的图像转文本策略以牺牲细粒度视觉能力为代价换取安全性，在需要精确视觉理解的任务上不可接受；对抗训练提升鲁棒性但引入”对齐税”；输出过滤（如关键词审核）易被语义改写绕过。当前共识是**纵深防御**（defense in depth）：输入净化 + 安全微调 + 解码约束 + 输出审计多层叠加，并接受每层都有残余风险。安全水平应以红队评测（MM-SafetyBench/JailBreakV 口径）的持续度量为准，而非一次性验收。

6.4 可信 MLLM 的治理视角

技术防线之外，可信部署还需要治理框架的配合。当前社区正在形成的实践包括：**模型卡片（model card）**——随模型发布声明其训练数据来源、已知幻觉倾向与禁用场景；**事件报告制度**——对部署中出现的幻觉事故与越狱事件进行记录与复盘，类似航空业事故调查报告；**分级发布**——对未充分红队测试的模型限制 API 能力范围（如关闭代码执行、限制图像上传类

型)；**可追溯性**——通过输出水印与日志审计，使幻觉与越狱事件可归因、可追责。对研究者而言，治理视角的价值在于：它把”多安全算安全”这个模糊问题转化为可操作的问题——在给定的场景风险等级下，需要哪几层防御、达到什么评测水位、保留哪些人工兜底。技术报告 [7] 与综述 [10] 均指出，评测-防御-治理的闭环是 MLLM 可信化的必由之路。

7 开放问题与未来方向

回看全报告，幻觉、对齐、安全三条线索在每个层面都相互咬合：缓解幻觉的对齐训练可能引入对齐税，安全微调可能改变幻觉分布，推理模型的能力升级同时放大两类风险。以下七个开放问题，正是这些咬合点上尚未解开的结。

1. **幻觉的统一理论**。现有研究按现象分治（对象/属性/关系幻觉），缺乏一个从表征层面解释”为何语言先验会压过视觉证据”的统一框架。一个有前景的方向是将幻觉形式化为条件互信息 $I(y; v | x)$ 的退化问题，建立可计算的 grounding 强度度量——即不再满足于事后统计幻觉率，而是追问：在模型的内部表征里，这个 token 的生成究竟动用了多少视觉信息？
1. **对齐的泛化与分布外安全**。现有对齐在基准分布内有效，面对分布外输入（新型攻击、低资源语言、未见场景）时安全约束失效。安全对齐如何获得类似对抗鲁棒性的泛化保证，是理论瓶颈。
1. **对齐税的量化与帕累托前沿**。安全性与能力的权衡缺乏系统度量。社区需要标准协议刻画”安全-能力帕累托曲线”，使对齐强度成为可告知用户的显式旋钮。
1. **推理链的过程监督**。R1-style 模型的幻觉发生在推理中段而非最终答案。如何在干扰推理的前提下监控与干预中间步骤（过程奖励模型、视觉证据回查机制），是推理时代对齐的核心问题。
1. **红队的标准化**。攻击成功率（ASR）的计算口径、有害内容的判定标准、多轮攻击的协议目前各自为政，跨研究可比性差。OmniSafeBench-MM [41] 是朝标准化迈出的重要一步，但社区级共识尚未形成。
1. **从内容安全到行为安全**。Agentic MLLM 时代，风险单位从”一句有害的话”变为”一次有害的操作”。行为级审计、工具调用的权限沙箱、不可逆操作的二次确认机制，都是待建的工程与研究基础设施。
1. **多模态对齐的奖励黑客**。文本 RLHF 中已观察到模型学会迎合奖励模型的表面特征（长度、礼貌用语）而非真正改进质量。多模态场景下，奖励模型自身的视觉理解能力有限，被奖励黑客利用的空间更大——例如奖励模型无法分辨细粒度数量错误时，策略模型可能学会生成”看起来 grounded”的模板化描述。Skywork-VL Reward [35] 等专门化奖励模型是对这一问题的回应，但奖励模型与策略模型的”军备竞赛”才刚刚开始。

8 研究机会点评（给入门研究者的建议）

算力门槛适中、问题清晰的切入点：

- **解码侧幻觉缓解的改进** (VCD/OPERA 家族)：无需训练，单卡即可复现与迭代。开放空间包括：更好的“失真对照”设计（如基于注意力掩码而非高斯噪声）、对关系幻觉与推理幻觉的扩展、与 speculative decoding 结合降低开销。顶会潜力：中高，需超越增量改进。
- **细粒度幻觉归因**：借助 MMVP/BLINK 式诊断集，研究特定视觉结构（projector 信息瓶颈、位置编码）与幻觉类型的因果关联。干预实验（ablation + probing）门槛不高，但洞见可以很深。
- **小数据高效对齐**：延续 RLHF-V 的数据效率路线，探索主动学习（挑最值得标注的样本）、合成修正数据的质量控制等。数百张 GPU 时即可做出有说服力的结果。
- **幻觉评测方法论**：构造抗污染、抗“背题”的动态评测，或系统审计 LLM-as-a-judge 在幻觉判定中的偏置。这类工作几乎不需要训练算力，但需要严谨的实验设计，是入门者建立学术声誉的快车道。

需要谨慎评估投入的方向：

- **大规模偏好数据构建与全量对齐训练**：Silkie/RLAIF-V 级别的数据生产与 70B 级模型训练是机构级游戏，个人或小团队宜站在其开源产物上做二次研究。
- **端到端安全底座**：与闭源前沿模型比拼综合安全水位意义不大；但攻击技术本身（新型攻击面发现）门槛不高且影响力大，适合作为切入点——发现一个新攻击面往往比刷高 1% 防御率更有价值。
- **多模态奖励模型**：Skywork-VL Reward 级别的奖励模型训练需要大量偏好数据与算力，但“奖励模型的失败模式分析”“奖励黑客的案例研究”是低门槛高价值的研究。
- **推理模型的视觉忠实度对齐**：More Thinking, Less Seeing [30] 指出了问题（长推理链漂移），但解决方案几乎是空白。具体可做：推理链中的视觉证据引用监督、过程奖励模型对“没看图”的判别、RH-AUC 指标的改进与跨模型横向测量。这是 2025-2026 年时效性最强的窗口之一，且实验可在 7B 级开源模型上完成。

坦诚的建议：本方向的一个隐形优势是——很多重要问题（评测设计、失败模式归因、攻击面发现）不需要巨额算力，需要的是细致的观察与严谨的实验。对入门者而言，“把一个问题测量清楚”常常是比“提出一个新方法”更好的第一篇论文。而本方向恰好为这种研究风格提供了异常丰富的素材：每个新发布的模型都带来新的失败模式等待归因，每种新的对齐技术都带来新的副作用等待量化，攻击与防御的赛跑则保证问题永远不会枯竭。

9 术语表

- **对齐 (Alignment)**：使模型行为符合人类意图与价值观的训练过程，多模态场景下含预训练对齐、指令微调对齐与偏好对齐三层。
- **RLHF**：基于人类反馈的强化学习，两阶段范式：训练奖励模型 + PPO 优化策略。
- **DPO**：直接偏好优化，用闭式解将 RLHF 压缩为单阶段监督式偏好学习。

- **GRPO / GSPO**: 组相对/组序列策略优化, 省略价值网络、用组内相对奖励或序列级比率稳定 RL 训练。
- **幻觉 (Hallucination)**: 模型生成与输入图像不一致的流畅文本, 分对象、属性、关系、文本四类。
- **语言先验 (Language Prior)**: 语言模型从文本语料学到的统计共现规律, 幻觉的主要驱动之一。
- **Grounding**: 将生成内容锚定到视觉证据的能力; grounding 不足是幻觉的核心成因。
- **CHAIR**: Caption Hallucination Assessment with Image Relevance, 基于物体标注的图像描述幻觉度量。
- **POPE**: Polling-based Object Probing Evaluation, 用 Yes/No 轮询探测对象幻觉的基准。
- **VCD**: 视觉对比解码, 对比原始与失真图像的解码分布以抑制非视觉 token。
- **OPERA**: 基于过信任惩罚与回溯分配的免训练幻觉缓解解码方法。
- **修正性反馈 (Correctional Feedback)**: RLHF-V 提出的标注形式——直接改写错误片段而非成对排序, 信息密度更高。
- **越狱 (Jailbreak)**: 构造输入诱导模型绕过安全对齐输出受限内容的攻击。
- **排版攻击 (Typographic Attack)**: 将有害指令渲染为图像文字, 经视觉通路绕过文本安全过滤。
- **跨模态攻击**: 文本与图像单独无害、组合后构成恶意意图的攻击形式。
- **红队 (Red-teaming)**: 主动模拟攻击以暴露模型安全缺陷的评测实践。
- **对齐税 (Alignment Tax)**: 安全/对齐训练对模型通用能力造成的性能损失。
- **LLM-as-a-judge**: 用强语言模型自动评估生成质量的范式, 幻觉评测中需注意其自身偏置。
- **攻击成功率 (ASR)**: 越狱攻击成功诱导有害输出的比例, 安全评测核心指标。
- **防御纵深 (Defense in Depth)**: 输入、模型、输出多层叠加的安全防护架构原则。
- **对齐税 (Alignment Tax) 的帕累托前沿**: 刻画安全强度与通用能力权衡关系的曲线, 用于指导对齐强度的显式选择。
- **过程监督 (Process Supervision)**: 对推理链中间步骤而非仅最终结果施加奖励或监控的对齐技术, 推理模型时代的关键工具。
- **RH-AUC**: 量化感知准确率随推理长度衰减曲线的指标, 用于诊断推理模型的幻觉放大。
- **信用分配 (Credit Assignment)**: 将整条回答的最终奖励归因到具体生成步骤或片段的问题, 细粒度对齐方法 (如稠密 DPO) 的核心动机。
- **攻击面 (Attack Surface)**: 系统中可被攻击者利用的输入接口与路径的总和; 多模态化使攻击面从离散文本扩展到连续视觉信号。

10 参考文献

-
- [1] Flamingo: a Visual Language Model for Few-Shot Learning, Alayrac et al. (DeepMind), 2022, arXiv:2204.14198, <https://arxiv.org/abs/2204.14198>
- [2] BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models, Li et al. (Salesforce), 2023, arXiv:2301.12597, <https://arxiv.org/abs/2301.12597>
- [3] Language Is Not All You Need: Aligning Perception with Language Models (Kosmos-1), Huang et al. (Microsoft), 2023, arXiv:2302.14045, <https://arxiv.org/abs/2302.14045>
- [4] Visual Instruction Tuning (LLaVA), Liu et al. (UW – Madison / Microsoft), 2023, arXiv:2304.08485, <https://arxiv.org/abs/2304.08485>
- [5] Kosmos-2: Grounding Multimodal Large Language Models to the World, Peng et al. (Microsoft), 2023, arXiv:2306.14824, <https://arxiv.org/abs/2306.14824>
- [6] InstructBLIP: Towards General-purpose Vision-Language Models with Instruction Tuning, Dai et al. (Salesforce), 2023, arXiv:2305.06500, <https://arxiv.org/abs/2305.06500>
- [7] A Survey on Multimodal Large Language Models, Yin et al. (PKU), 2023, arXiv:2306.13549, <https://arxiv.org/abs/2306.13549>
- [8] Hallucination of Multimodal Large Language Models: A Survey, Bai et al., 2024, arXiv:2404.18930, <https://arxiv.org/abs/2404.18930>
- [9] Hallucination in Multimodal Foundation Models: A Survey on Causes, Corrections, and Evaluations, 2024, arXiv:2410.15359, <https://arxiv.org/abs/2410.15359>
- [10] A Survey of State of the Art Large Vision Language Models: Alignment, Benchmark, Evaluations and Challenges, 2025, arXiv:2501.02189, <https://arxiv.org/abs/2501.02189>
- [11] Evaluating Object Hallucination in Large Vision-Language Models (POPE), Li et al. (RUC / MSRA), 2023, arXiv:2305.10355, <https://arxiv.org/abs/2305.10355>
- [12] Mitigating Hallucination in Large Multi-Modal Models via Robust Instruction Tuning (LRV-Instruction), Liu et al., 2023, arXiv:2306.14565, <https://arxiv.org/abs/2306.14565>
- [13] Mitigating Object Hallucinations in Large Vision-Language Models through Visual Contrastive Decoding (VCD), Leng et al. (NUS), 2023, arXiv:2311.16922, <https://arxiv.org/abs/2311.16922>
- [14] RLHF-V: Towards Trustworthy MLLMs via Behavior Alignment from Fine-grained Correctional Human Feedback, Yu et al. (THU / ByteDance), 2023, arXiv:2312.00849, <https://arxiv.org/abs/2312.00849>
- [15] Beyond Hallucinations: Enhancing LVLMs through Hallucination-Aware Direct Preference Optimization (HA-DPO), Zhao et al., 2023, arXiv:2311.16839, <https://arxiv.org/abs/2311.16839>
- [16] RLAIIF-V: Open-Source AI Feedback Leads to Super GPT-4V Trustworthiness, Yu et al. (THU / ByteDance), 2024, arXiv:2405.17220, <https://arxiv.org/abs/2405.17220>
- [17] Aligning Large Multimodal Models with Factually Augmented RLHF (LLaVA-RLHF), Sun et al. (CMU), 2023, arXiv:2309.14525, <https://arxiv.org/abs/2309.14525>

- [18] Woodpecker: Hallucination Correction for Multimodal Large Language Models, Yin et al. (USTC / MSRA), 2023, arXiv:2310.16045, <https://arxiv.org/abs/2310.16045>
- [19] Towards Mitigating Hallucination in Large Vision-Language Models via Visual-Guided Direct Preference Optimization (V-DPO), 2024, arXiv:2411.02712, <https://arxiv.org/abs/2411.02712>
- [20] mDPO: Conditional Preference Optimization for Multimodal Large Language Models, Wang et al., 2024, arXiv:2406.11839, <https://arxiv.org/abs/2406.11839>
- [21] MPO: Mixed Preference Optimization for Enhancing Reasoning in Multimodal Large Language Models, 2024, arXiv:2411.10442, <https://arxiv.org/abs/2411.10442>
- [22] Visual Adversarial Examples Jailbreak Aligned Large Language Models, Qi et al. (Google DeepMind / UW), 2023, arXiv:2306.13213, <https://arxiv.org/abs/2306.13213>
- [23] FigStep: Jailbreaking Large Vision-Language Models via Typographic Visual Prompts, Gong et al. (NUS), 2023, arXiv:2311.05608, <https://arxiv.org/abs/2311.05608>
- [24] MM-SafetyBench: A Benchmark for Safety Evaluation of Multimodal Large Language Models, Liu et al. (SJTU / Shanghai AI Lab), 2023, arXiv:2311.17600, <https://arxiv.org/abs/2311.17600>
- [25] Object Hallucination in Image Captioning (CHAIR), Rohrbach et al. (UC Berkeley), 2018, arXiv:1809.02156, <https://arxiv.org/abs/1809.02156>
- [26] HallusionBench: An Advanced Diagnostic Suite for Entangled Language Hallucination and Visual Illusion in Large Vision-Language Models, Guan et al. (OSU), 2023, arXiv:2310.14566, <https://arxiv.org/abs/2310.14566>
- [27] Eyes Wide Shut? Exploring the Visual Shortcomings of Multimodal LLMs (MMVP), Tong et al. (NYU / CMU), 2024, arXiv:2401.06209, <https://arxiv.org/abs/2401.06209>
- [28] BLINK: Multimodal Large Language Models Can See but Not Perceive, Fu et al., 2024, arXiv:2404.12390, <https://arxiv.org/abs/2404.12390>
- [29] MMStar: Are We on the Right Way for Evaluating Large Vision-Language Models?, Chen et al., 2024, arXiv:2403.20330, <https://arxiv.org/abs/2403.20330>
- [30] More Thinking, Less Seeing? Assessing Amplified Hallucination in Multimodal Reasoning Models, 2025, arXiv:2505.21523, <https://arxiv.org/abs/2505.21523>
- [31] Eyes Closed, Safety On: Protecting Multimodal LLMs via Image-to-Text Transformation (ECSO), Gou et al., 2024, arXiv:2403.09572, <https://arxiv.org/abs/2403.09572>
- [32] BaThe: Defense against the Jailbreak Attack in Multimodal Large Language Models by Treating Harmful Instruction as Backdoor Trigger, 2024, arXiv:2408.09093, <https://arxiv.org/abs/2408.09093>
- [33] JailBreakV: A Benchmark for Assessing the Robustness of MultiModal Large Language Models against Jailbreak Attacks, Luo et al., 2024, arXiv:2404.03027, <https://arxiv.org/abs/2404.03027>
- [34] MME: A Comprehensive Evaluation Benchmark for Multimodal Large Language Models, Fu et al., 2023, arXiv:2306.13394, <https://arxiv.org/abs/2306.13394>

- [35] Skywork-VL Reward: An Effective Reward Model for Multimodal Understanding and Reasoning, 2025, arXiv:2505.07263, <https://arxiv.org/abs/2505.07263>
- [36] Group Sequence Policy Optimization (GSPO), Zheng et al. (Qwen Team), 2025, arXiv:2507.18071, <https://arxiv.org/abs/2507.18071>
- [37] Proximal Policy Optimization Algorithms, Schulman et al. (OpenAI), 2017, arXiv:1707.06347, <https://arxiv.org/abs/1707.06347>
- [38] Direct Preference Optimization: Your Language Model is Secretly a Reward Model, Rafailov et al. (Stanford), 2023, arXiv:2305.18290, <https://arxiv.org/abs/2305.18290>
- [39] Training a Helpful and Harmless Assistant with Reinforcement Learning from Human Feedback, Bai et al. (Anthropic), 2022, arXiv:2204.05862, <https://arxiv.org/abs/2204.05862>
- [40] Constitutional AI: Harmlessness from AI Feedback, Bai et al. (Anthropic), 2022, arXiv:2212.08073, <https://arxiv.org/abs/2212.08073>
- [41] SmoothGuard: Defending Multimodal Large Language Models with Noise Perturbation and Cluster Aggregation, 2025, arXiv:2510.26830, <https://arxiv.org/abs/2510.26830>
- [42] DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models (GRPO), Shao et al. (DeepSeek), 2024, arXiv:2402.03300, <https://arxiv.org/abs/2402.03300>
- [43] ClearSight: Visual Signal Enhancement for Object Hallucination Mitigation in MLLMs, 2025, arXiv:2503.13107, <https://arxiv.org/abs/2503.13107>
- [44] Silkie: Preference Distillation for Large Visual Language Models (LLaVA-1.5-Silkie), Li et al., 2023, arXiv:2312.10665, <https://arxiv.org/abs/2312.10665>
- [45] OmniSafeBench-MM: A Unified Toolbox for Multimodal Jailbreak Attack and Defense Evaluation, 2025, arXiv:2512.06589, <https://arxiv.org/abs/2512.06589>
- [46] A Survey on Multimodal Hallucination Evaluation and Mitigation, 2025, arXiv:2508.01781, <https://arxiv.org/abs/2508.01781>
- [47] MM-Vet: Evaluating Large Multimodal Models for Integrated Capabilities, Yu et al. (Microsoft), 2023, arXiv:2308.02490, <https://arxiv.org/abs/2308.02490>
- [48] MMBench: Is Your Multi-modal Model an All-around Player?, Liu et al., 2023, arXiv:2307.06281, <https://arxiv.org/abs/2307.06281>
- [49] OPERA: Alleviating Hallucination in Multi-Modal Large Language Models via Over-Trust Penalty and Retrospection-Allocation, Huang et al., 2023, arXiv:2312.07553, <https://arxiv.org/abs/2312.07553>