多模态大模型系列报告

多模态评测如何产生可信结论

先定义估计对象，再处理配对、方差、泄漏和判分器

多模态大模型系列报告

2026-10-16

本报告为系列技术综述，内容基于公开论文整理，仅供学习研究使用。

目录

1 先写 estimand **3**

2 相同五个百分点，信息可能完全不同 **3**

2.1 独立单位可能不是题 4

2.2 从配对表算出标准误 5

2.3 边际分数相同，协方差可以相反 5

2.4 同一批记录，换成按视频独立会怎样 5

3 判分器也是需要验证的测量设备 **6**

3.1 judge 的 90% 一致率能隐藏什么 6

4 MMMU：同一名称也有多种结果列 **7**

5 切片、选择与多重比较 **8**

6 先复核一张结果表，再扩大评测 **8**

7 参考文献与证据 **8**

摘要 “平均分提升两点”缺少至少四项信息：测试的是哪类样本、两个系统是否回答同一批题、变化来自哪些题，以及评分规则是否可靠。本章从一个可复算的配对例子出发，区分单题、视频、任务轨迹等统计单位；说明 bootstrap、切片与 judge 校准各回答什么问题；最后重读 MMMU 的一个固定版本表格，展示分数、split 和模型版本如何共同定义结果。

1 先写 estimand

设目标人群/任务分布为 $\mathcal{D}$，系统 f，判分函数为 s，目标量为 $\mu = \mathbb{E}_{x\sim\mathcal{D}}[s(f(x), x)]$。benchmark 平均值是对这个量的一个估计，但测试集是否代表实际用途，需要论证，而不是由数据集名称保证。

例如一项多选题准确率，可能估计固定候选集合、固定 prompt 和固定答案解析器下的正确比例；它不直接估计开放问答、复杂文档或真实工具任务的成功率。API 模型还需要记录访问日期和可识别的版本，因为相同名称可能对应更新过的系统。

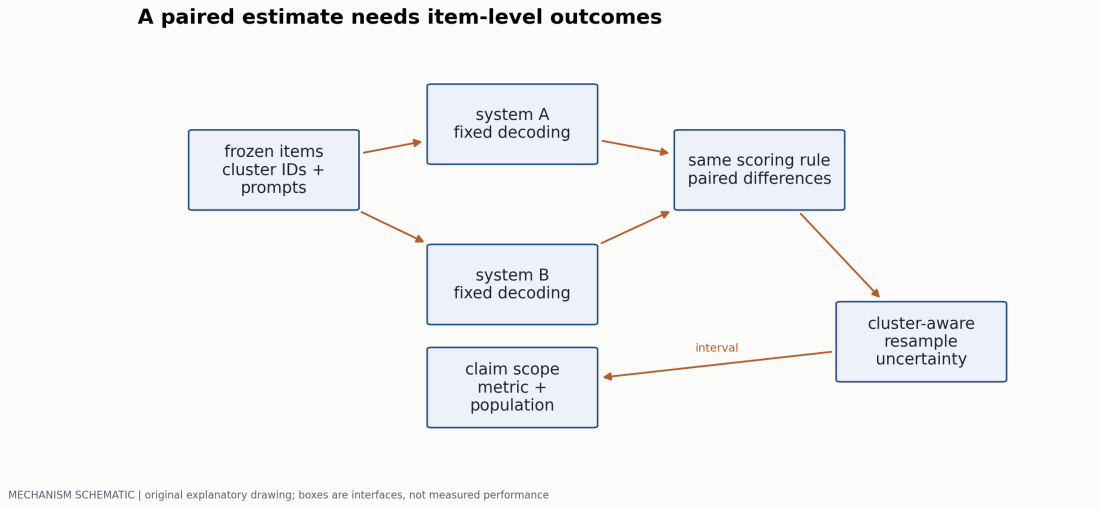


图 1 冻结题目和协议后运行两个系统，形成逐项差值，再按正确统计单位重采样。评分规则位于实验内部，也要验证。

一个最小实验记录应包含：dataset/version/split、题目 ID、模态开关、图像/视频预算、prompt 模板、模型标识、decoding、评分与解析版本、原始输出、时间和失败原因。采样温度为零也不保证所有服务后端逐次 bitwise 一致，需要实际检查。

2 相同五个百分点，信息可能完全不同

比较 A 与 B 时，优先对同一组题运行并保存 $d_i = s_i^B - s_i^A$。差值估计为 $\hat{\Delta} = n^{-1}\sum_i d_i$，方差取决于 d_i 的分布，而不只取决于两个边际准确率。

构造 200 道教学题的结果：80 题两者都对，10 题仅 A 对，20 题仅 B 对，90 题都错。于是 A 准确率 45%，B 为 50%，配对差为 5 个百分点。这组数据是明确构造、用于统计教学的结果表，不来自任何模型调用。

结果	题数	对 B−A 的贡献
都对	80	0
仅 A 对	10	−10
仅 B 对	20	+20
都错	90	0

```
# Executed equivalent is in labs/run_probes.py.
d = [0]*80 + [-1]*10 + [1]*20 + [0]*90
# Resample paired item IDs, not A and B independently.
for repeat in range(4000):
    delta_star = mean(sample_with_replacement(d, size=200))
```

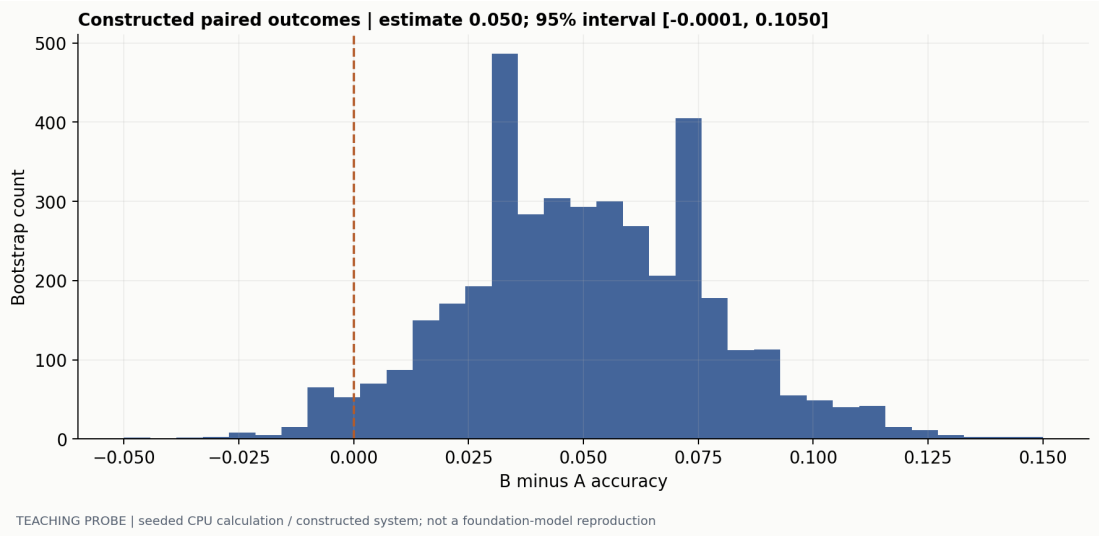


图 2 实际运行的 4000 次配对 bootstrap，seed 336。样本是上述构造结果，纵轴为重采样计数；图上的区间是本次计算得到的 percentile interval。

区间跨零时，不能仅凭点估计宣称稳定优于基线。区间不跨零也不等于改进足够实用；应与效应大小、成本和所选任务分布一起解释。Bootstrap 不会修复测试集泄漏或错误判分器。

2.1 独立单位可能不是题

同一视频可产生多道问题，同一文档可有多个页面，同一用户可贡献多个任务。它们共享背景与难度；逐题独立重采样可能低估不确定性。应按视频、文档、用户等实验设计中的 cluster 重采样，并在系统比较中保留配对关系。

如果随机性还来自模型采样，要区分题目变动与同题多次生成的变动。重复生成不能凭空增加独立题目数；应保留题目层和生成层的结构，或按预先定义的 aggregation 统计。

2.2 从配对表算出标准误

对上述 200 题构造例，令 $d_i \in \{-1, 0, 1\}$ 表示 B 与 A 的逐题正确性差。30 题不一致，因此 $\overline{d^2} = 30/200 = 0.15$，$\bar{d} = 0.05$，用样本方差得到

$$s_d^2 = \frac{n}{n-1}(\overline{d^2} - \bar{d}^2), \qquad \widehat{SE}(\bar{d}) = \frac{s_d}{\sqrt{n}} = \sqrt{\frac{0.15 - 0.05^2}{199}} \approx 0.0272.$$

这相当于 2.72 个百分点。正态近似的 95% 区间约为 $5 \pm 1.96 \times 2.72$ 个百分点，即 $[-0.34, 10.34]$；本文实际运行的 percentile bootstrap 给出约 $[-0.0125, 10.5]$ 个百分点。两种区间使用不同构造方法，数值不必完全相同；原始配对表和区间算法都应保存。这里的 bootstrap 下界由有限次重采样与 percentile 插值产生，不能把其小数位当成真实测量精度。

2.3 边际分数相同，协方差可以相反

保留 A=45%、B=50%，改用另一张构造配对表：

结果	第一组题数	第二组题数
都对	80	0
仅 A 对	10	90
仅 B 对	20	100
都错	90	10
总数	200	200

第二组有 190 题不一致，$\overline{d^2} = 0.95$，因此 $\widehat{SE}(\bar{d}) = \sqrt{(0.95 - 0.0025)/199} \approx 6.90$ 个百分点。相同的五点提升，在第二组远不如第一组稳定。两系统得分的经验协方差分别为 $0.40 - 0.45 \times 0.50 = 0.175$ 和 $0 - 0.45 \times 0.50 = -0.225$；差值方差包含 $-2\,\mathrm{Cov}(A, B)$。若将 A/B 题目独立重采样，会丢掉这个配对项，两组都得到约 4.99 个百分点的独立近似标准误，既可能高估，也可能低估实际配对不确定性。

区间的推广对象也要写明。若系统确定性地回答了一个固定 200 题集合，45% 和 50% 就是该集合上的精确描述；题目 bootstrap 将其视为来自某个任务分布的样本，所作的是对该分布的推广，而非给固定集合增加原本不存在的抽样随机性。95% 覆盖是说重复按同一抽样和构造程序生成区间，长期约 95% 的区间覆盖固定目标量；它不直接表示目标量有 95% 概率位于本次已经算出的区间。

2.4 同一批记录，换成按视频独立会怎样

另外实际运行一个有 cluster 的构造：20 个视频，每视频 10 道题，同视频内十题的 A/B 正误完全相同。8 个视频都答对、1 个仅 A 对、2 个仅 B 对、9 个都错，逐题边际计数仍是 80/10/20/90；独立单位却只有 20 个视频。

这张图使用新增的独立 RNG 子流，不能拿其 item 区间替换前面独立题目实验的具体落盘区间。边界落在零也不支持稳定优势。关键变化来自构造中明确加入的题内相关性；不是把

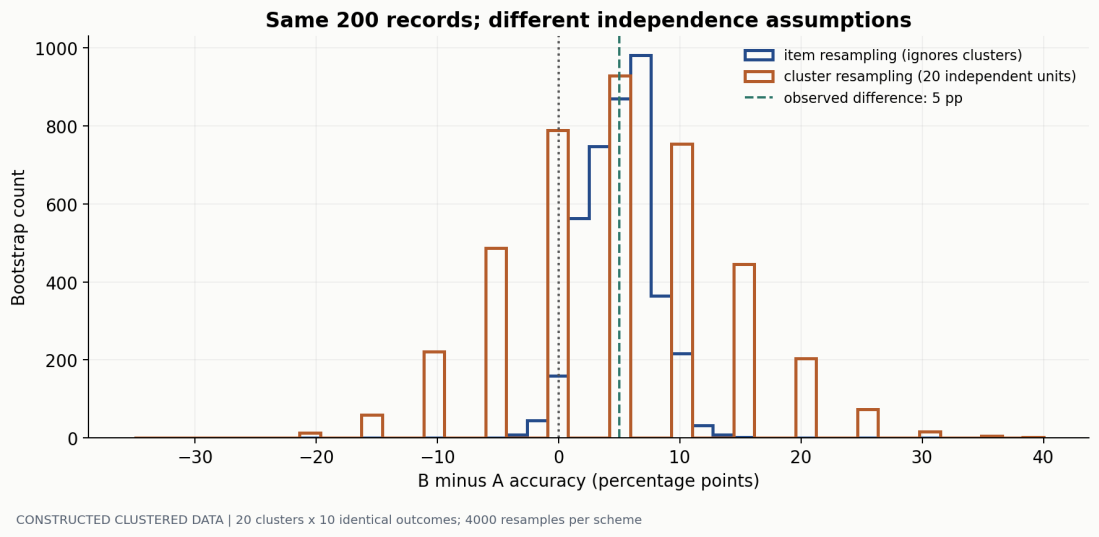


图 3 同一组有 cluster 的构造记录，错误地按 item 重采样得到 95% percentile 区间 [0,10.5] 个百分点；按 20 个 cluster 重采样为 [-10,20] 个百分点。实际运行各 4000 次，独立子流保存于 sources/mechanism-checks.json，原始配对与抽样结果在 sources/raw/check-10-*.csv。

所有 benchmark 的题数机械除以十。真实数据要保存 video/document/user ID，按其抽样设计选择独立单位。

3 判分器也是需要验证的测量设备

选择题解析应明确处理多个选项、无选项、解释中的字母和无效输出。开放问答的 exact match 容易受格式影响，模型 judge 则可能受位置、长度、语言和风格影响。先抽取一批盲审的人类标签，检查 judge 的错误类型，而不只是报总体一致率。

对 pairwise judge，可以交换答案顺序重复评分；对长度偏好，用事实内容相同而表达长度不同的样本作对照；对图像理解，检查 judge 是否实际接收所需图像。如果 judge 只读文字解释，就无法验证解释是否与图像一致。

模型自己给出的置信度也不是自动校准的概率。若记录置信分数，可将预测分桶比较经验准确率，或用 proper scoring rules；需要同时报告 bucket 样本数，避免把稀疏高置信区间画得很确定。

3.1 judge 的 90% 一致率能隐藏什么

以下再构造一批 100 条人工盲审金标，目标是判定“回答是否可接受”。其中 90 条可接受、10 条不可接受，judge 的混淆矩阵为：

人工金标	judge 接受	judge 拒绝	总数
可接受	86	4	90
不可接受	6	4	10

总体 agreement 为 90%，与永远判“接受”的常数判分器相同。真正需要注意的是：不可接受回答有 6/10 被错误接受；judge 接受的 92 条中有 6 条错误，错误接受占比为 6/92。前者的分母是全部真负例，后者的分母是全部接受输出，它们回答不同问题。

再按任务 slice 分解同一批结果：

slice	TP	FN	FP	TN	agreement	不可接受回答被放过
普通视觉，80 条	74	2	1	3	77/80=96.25%	1/4
OCR，20 条	12	2	5	1	13/20=65%	5/6

总体 agreement 掩盖了 OCR 的严重失准，但 OCR 中只有 6 条真负例，不能把 5/6 写成精确总体错误率；应保留原始分母、补充定向抽检，并说明抽检样本怎样选取。金标本身也要保存至少两名独立标注者的原始判定、分歧数和裁决规则；用于校准 judge 的开发样本与最终评价样本分开。

对于 pairwise judge，另取 50 对回答，固定内容，交换左右顺序各判一次，并将选择映射回原始系统身份。假设 40 对保持同一选择，10 对在交换后改变，顺序不一致率就是 10/50=20%；若其中 8 对总选左侧、2 对总选右侧，这提供了位置敏感的诊断。单次交换只能测到位置变化与 judge 自身随机性的合计影响，还需同顺序重复判分估计后者。保存 judge 版本、prompt、图像输入、温度、各次原始判分和答案长度，再讨论位置、冗长或视觉缺失造成的偏差。所有这些计数是构造演示，真实实验需运行后填写。

4 MMMU：同一名称也有多种结果列

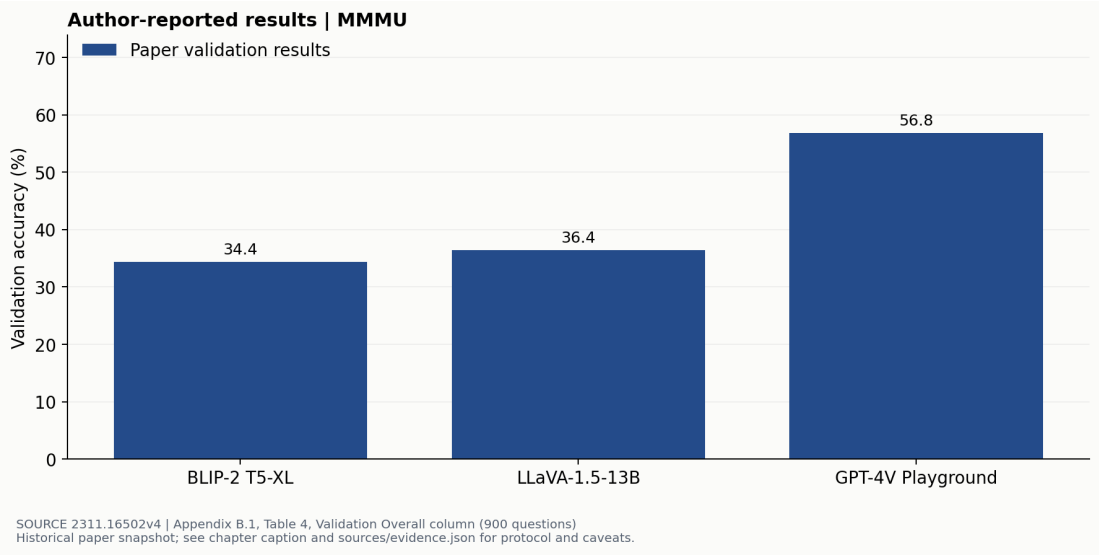


图 4 MMMU v4 Appendix B.1、Table 4（PDF 第 15 页）的 Validation Overall 列（900 题）：BLIP-2 FLAN-T5-XL 34.4、LLaVA-1.5-13B 36.4、GPT-4V Playground 56.8。Table 5 的 Art & Design 子集只有 120 题，其 44.2/51.7/65.8 不能当总分。

这张图描述一个历史表格中的系统表现，不是截至 2026-10-16 的实时排行榜，也不是只改变模型大小的消融。不同训练数据、访问条件与提示设置都可能参与结果差异。将早期摘要中的某个分数、后续表格的 test overall 和当前在线 leaderboard 放进一列，表面精确却无法比较。

MMMU 的专业题目还提醒我们区分“图像出现在题里”和“回答依赖图像”。应使用仅文本、OCR 文本、图像条件等对照，观察哪些题能被语言先验解决。单项总分难以揭示模型对图表、几何、密集文档与自然图像的不同能力。

5 切片、选择与多重比较

事先确定主指标与主要 slice，避免从几十个子集里只展示上升最大的几个。对模型、prompt、阈值反复在同一 validation 上调参，会使该集合逐渐变成训练决策的一部分；最终 test 应保持冻结。

报告失败请求也很重要。若只有成功返回的题被计入分母，延迟高或容易超时的系统可能被不公平地高估；若把所有技术失败都计零，也需要说明它估计的是端到端系统还是模型条件正确率。两种量都可以有用，但应分开命名。

把 benchmark 分数作为研发决策时，还要考虑最坏或高风险 slice。一个整体准确率提高但特定语言明显退化的模型，不能仅凭总平均数替换旧模型。slice 样本少时应展示原始分子分母和区间，而不是把小样本波动写成结论。

6 先复核一张结果表，再扩大评测

建议按顺序完成四项工作：复跑同一 checkpoint 的固定配置；保存逐题输出并手工审查解析器；完成一次 A/B 配对比较；再增加模型与数据集。任何新增维度都应明确它回答什么问题。

实验清单可以很具体：原图/错图检查视觉依赖；固定总帧预算检查时间覆盖；相同答案交换位置检查 judge 偏差；按来源划分检查泄漏。这些对照往往比增加十个模型条目更能解释问题。

`python labs/run_probes.py` 会重新生成上述配对例子的区间，`sources/probes.json` 保存实际数值与构造说明。本站没有为未运行的模型填写分数；原论文数字统一保存在 `sources/evidence.json`，连同 split、指标和来源位置。

7 参考文献与证据

[1] Yue et al. MMMU: A Massive Multi-discipline Multimodal Understanding and Reasoning Benchmark for Expert AGI. v4，Appendix B.1–B.2、Tables 4–5 与版本说明。原文

[2] Li et al. Evaluating Object Hallucination in Large Vision-Language Models. 评分指标与提示敏感性。原文

[3] Stanford CS336. Evaluation lecture，用于从测量对象推到具体协议的组织参照。原文