
多模态大模型系列报告

潮水的方向：2025-2026 多模态研究前沿专题

把十一篇报告的前沿章节织成一张大图，并冷静追问：下一个范式转移可能在哪里

多模态大模型系列报告

2026-09-29

本报告为系列技术综述，内容基于公开论文整理，仅供学习研究使用。

目录

1	引言：本方向在多模态版图中的位置	3
2	基础知识	4
2.1	表示之争：离散 token 还是连续嵌入	4
2.2	后训练新范式：从 RLHF 到 RLVR 与 GRPO	5
2.3	世界模型：一个被反复定义的词	5
2.4	拼装 vs 原生：多模态训练的两条道路	6
3	经典方法谱系	6
4	代表作深度剖析	8
4.1	Emu3：极简主义的宣言（2024）	9
4.2	BAGEL：统一预训练的涌现证据（2025）	10
4.3	Vision-R1：推理革命的迁移方法论（2025）	10
4.4	Cosmos：世界模型的平台化野心（2025）	11
4.5	V-JEPA 2：不在像素里做梦（2025）	12
5	研究前沿（2025–2026）：六股结构性趋势	13
5.1	趋势一：统一理解-生成——单一 Transformer 的大一统	13
5.2	趋势二：多模态推理革命——R1 时刻的视觉回响	14
5.3	趋势三：世界模型——从生成视频到生成现实	14
5.4	趋势四：原生多模态预训练——从拼接到原生	15
5.5	趋势五：架构多样化与超长上下文——Transformer 之外的传檄文与 1M token 的多模态意义	16
5.6	趋势六：AI for Science 的多模态维度与科研自动化	16
5.7	六股趋势的合流：一张大图	17
6	技术路线对比与权衡	18
7	开放问题与未来方向	19
8	研究机会点评（给入门研究者的建议）	20
9	术语表	20
10	参考文献	21

摘要 本篇是多模态大模型系列报告的收官之作。前面十一篇分别深入了视觉语言、语音、视频、全模态、生成、具身、智能体、效率、安全、评测与数据训练等方向，每一篇都勾勒了各自的前沿轮廓；本篇的任务不是重复这些轮廓，而是把它们叠在同一张地图上，辨认那些跨越单一方向的结构性潮流。我们识别出六股正在重塑整个领域的趋势：其一，统一理解-生成——从”理解的归理解、生成的归扩散”的分工时代，走向单一 Transformer 大一统的架构收敛（Transfusion、Emu3、Janus、BAGEL）；其二，多模态推理革命——o1/R1 式长思维链与可验证奖励强化学习（RLVR）向视觉领域的大规模迁移（Vision-R1、Visual-RFT、R1-Onevision）；其三，世界模型——从视频生成到可交互环境的野心，以及围绕”视频生成器是否学到了物理”的尖锐争议（Genie、Cosmos、V-JEPA 2）；其四，原生多模态预训练——从”语言模型 + 视觉适配器”的拼装范式到从预训练第一天起就吃多模态数据的原生范式（Chameleon、InternVL3）；其五，架构多样化——线性注意力、混合架构与 1M+ 超长上下文带来的多模态意义；其六，AI for Science 的多模态维度与科研自动化的兴起。对每一股趋势，我们都给出”炒作 vs 实质”的冷静评估，并深度剖析五个代表性工作：Emu3、BAGEL、Vision-R1、Cosmos 与 V-JEPA 2。我们的总体判断是：架构统一与推理革命是真实且深刻的，世界模型与科研自动化则处在”愿景远超现状”的阶段；下一个范式转移的种子，很可能埋在”推理、生成与世界模型的交汇处”——一个能够先想、后画、再校验的闭环智能体之中。![2025-2026 多模态时间线总览](../figures/fig_timeline_vlm.png)

1 引言：本方向在多模态版图中的位置

十一篇报告之后，我们有了一张颇为详细的多模态地图：视觉语言模型如何从 CLIP 对齐走向原生高分辨率，语音如何从级联系统走向端到端全双工，视频如何从秒级片段走向小时级长上下文，生成如何从扩散一枝独秀走向自回归与扩散的正面交锋，具身智能如何把多模态模型塞进机器人的躯干，智能体如何学会使用工具，效率工程如何把模型推向端侧，安全与评测如何追赶能力的狂奔。然而，地图越详细，越需要一张更高层级的”大地图”：这些方向之间是否存在共同的底层运动？哪一些看似独立的进展，实际上是同一股潮流在不同水域激起的浪花？

本篇的定位正是这张大地图。我们不再按模态或任务划分领地，而是按**趋势**组织——一种趋势往往横跨多个模态、多个任务、多个子领域。例如，”统一理解-生成”既是视觉问题（图像生成），也是全模态问题（omni 模型的生成头），还是具身问题（动作序列的生成）；”推理革命”既是语言问题（o1/R1），也是视觉问题（Vision-R1），还是科学问题（科研 agent 的多步推理）。按趋势组织的好处在于，它让我们看到范式层面的迁移：一个想法在语言领域被验证之后，如何在六个月内席卷所有模态——这种迁移速度本身，就是 2025-2026 年最值得注意的现象。

学习地图。本篇的先修概念是整个系列的全部内容，但并不要求精读：你只需要（1）理解多模态模型的基本架构要素——视觉编码器、connector、LLM 主干、生成头（第 01、05 篇）；（2）理解强化学习后训练的基本框架——PPO、奖励模型、可验证奖励（第 09 篇）；（3）理解视频生成与扩散模型的基础（第 03、05 篇）。本篇的核心问题是三个：”哪些 2025-2026 年的进展是范式性的、哪些只是渐进改良？””为什么这些进展集中在此时此刻发生？””下一个范式转移最可能出现在哪条裂缝上？”

在正式进入趋势分析之前，有必要先回答一个方法论问题：凭什么说”趋势”而不是”热点”？热点的特征是数量——某个关键词在论文标题中频率飙升；趋势的特征是**结构**——多个独立团队在没有协调的情况下收敛到相似的设计选择，且这种收敛改变了后续工作的默认假设。按这个标准，2023 年的”视觉指令微调”是热点（人人都在做，但默认假设没变），而 2025 年的”统一架构”是趋势（新工作必须先回答”你为什么不一”）。本篇筛选六股趋势时用的正是

后一个标准，这也是我们把 GUI grounding、端侧部署、全双工语音等活跃方向留给相应专篇、而不在这里重复的原因——它们是垂直方向的深化，而非跨方向的结构运动。

另一个需要预先声明的立场：本篇对“范式转移”的用法比流行话语保守。在我们看来，过去两年真正称得上范式性的事件只有两件：其一是 RLVR 证明了后训练可以系统性地激发（而非仅仅对齐）能力；其二是统一架构证明理解与生成的分裂并非必然。其余——包括声量最大的世界模型——目前仍是“候选范式”。这个保守并非贬低：科学史上大多数候选范式最终被淘汰，识别哪些候选值得下注，正是收官篇应该提供的价值。

与其他方向的关系。本篇是汇流处而非新的支流：视觉语言篇讲的是感知能力的深化，本篇讲感知如何与推理、生成重新整合；生成篇讲的是生成范式的内部竞争，本篇讲生成与理解如何在单一模型中和解；具身与智能体篇讲的是模型如何行动，本篇讲世界模型如何成为行动的模拟器。阅读本篇的最佳姿势，是把它当作一次回顾性的旅行：沿着六条趋势线，重新走遍整个领域，但这一次，你的目光不再停留在单个模型上，而是停留在模型之间的引力场上。

2 基础知识

在进入趋势之前，我们需要建立四个贯穿全篇的基础概念。它们分别对应理解、生成、训练与模拟这四个维度，是阅读 2025-2026 前沿文献的共同语言。

2.1 表示之争：离散 token 还是连续嵌入

一切多模态架构争论的源头，是“如何把非文本模态变成 Transformer 能吃的东西”。答案有两大家族。

离散 token 路线：用一个向量量化器（如 VQ-VAE 的 codebook）把图像或视频压缩为离散码本索引序列 $z = (z_1, \dots, z_N)$, $z_i \in \{1, \dots, K\}$ ，其中 K 是码本大小。此后图像与文本在形式上完全同构——都是离散的符号序列——可以直接拼接进语言模型的词表，用标准的下一 token 预测损失训练：

$$\mathcal{L}_{\text{AR}} = -\sum_{t=1}^T \log p_{\theta}(x_t | x_{<t})$$

这条路线优雅、统一，与 LLM 生态无缝衔接（Emu3、Chameleon 均取此道），但代价是量化损失：连续像素被硬塞进有限码本，细节与生成的可控性都会受损。

连续嵌入路线：保留连续表示，理解侧用预训练视觉编码器（CLIP/SigLIP）产生特征向量，生成侧用扩散模型在连续潜空间中操作。扩散损失写为：

$$\mathcal{L}_{\text{diff}} = \mathbb{E}_{x_0, \epsilon, t} [\|\epsilon - \epsilon_{\theta}(x_t, t, c)\|^2]$$

其中 c 是条件（如文本嵌入）。这条路线生成质量高，但意味着模型内部同时存在两种“语法”——自回归的与扩散的——统一性受损。

2025-2026 年的统一架构之争，本质上就是这两条路线之争的高级形态：是“一切皆 token”（Emu3），还是“同一主干、双损失”（Transfusion），抑或“折中的解耦”（Janus）？

理解这两条路线的一个有用类比是文字与绘画的关系：离散 token 化相当于要求画家用文字描述每一笔画，连续嵌入则允许画家直接调色。前者的损失在“翻译”环节，后者的损失在“统一”环节。值得注意的是，2025 年的实证并未给出终局答案：Transfusion 的 scaling 实验表

明连续路线在图像生成的样本效率上占优，而 Emu3 与 BAGEL 表明离散/混合路线的统一性红利真实存在。这个僵局本身就是第 5.1 节与第 7 节开放问题的来源。

2.2 后训练新范式：从 RLHF 到 RLVR 与 GRPO

推理革命的技术底座是可验证奖励强化学习 (Reinforcement Learning with Verifiable Rewards, RLVR)。经典 RLHF 依赖一个学习出来的奖励模型 $r_\phi(x, y)$ ，它容易过拟合人类标注偏好、容易被 reward hacking；而 RLVR 的奖励是程序化的：数学题答案对不对、代码能不能跑通，都可以用规则直接判定。奖励信号因此变得廉价、准确且难以作弊。

GRPO (Group Relative Policy Optimization, 组相对策略优化) 是 RLVR 最常用的优化算法。其核心思想是：对同一个问题 q 采样一组 G 个回答 $\{o_1, \dots, o_G\}$ ，以组内平均奖励为基线计算优势：

$$A_i = \frac{r_i - \text{mean}(\{r_1, \dots, r_G\})}{\text{std}(\{r_1, \dots, r_G\})}$$

然后最大化带有 KL 正则的策略目标：

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \min \left(\frac{\pi_\theta(o_i|q)}{\pi_{\theta_{\text{old}}}(o_i|q)} A_i, \text{clip}(\cdot, 1 \pm \varepsilon) A_i \right) - \beta D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}}) \right]$$

与 PPO 相比，GRPO 去掉了 value network，用组内基线替代，实现更简单、显存更省——这一点对显存本就紧张的多模态模型尤为关键。当我们谈论“R1 式推理迁移到视觉”，实质上就是在谈论：哪些视觉任务存在可程序化验证的奖励（数学、计数、检测、OCR），以及如何设计奖励使得长思维链真正扎根于视觉证据而非语言先验。

一个常被忽略的要点是：RLVR 的“可验证性”在多模态语境下有微妙的变化。文本数学题的验证器只需比对符号答案；视觉任务的验证器往往需要先把模型的输出解析为结构（坐标、计数、选项），再与图像标注比对——这意味着奖励的可靠性上限由**标注质量**而非**验证程序**决定。Visual-RFT 之所以选择检测、分类这类标注成本低的任务作为突破口，正是看中这一点。反过来说，凡是标注本身模糊或主观的视觉任务（美学评价、开放式描述），RLVR 都不适用，必须退回奖励模型或人类偏好——这条边界划定了推理革命的势力范围。

2.3 世界模型：一个被反复定义的词

“世界模型” (World Model) 是 2025–2026 年最时髦也最混乱的术语。在强化学习传统中，世界模型是一个学习环境动态 $p(s_{t+1} | s_t, a_t)$ 的模型，智能体可以在其中“做梦”以规划动作；在 2024 年后的视频生成语境中，它被重新定义为“能预测世界如何演化的生成模型”——给一段视频开头和一个动作（或文本指令），模型生成后续帧。两种定义共享一个核心：**模型内化了某种世界运转的因果结构，可以回答“如果我这样做，会发生什么”**。

需要建立的关键区分是**生成式**与**预测式**世界模型：前者 (Genie、Sora 谱系) 在像素空间生成未来帧，保真度高但计算昂贵；后者 (V-JEPA 谱系) 在抽象表征空间预测未来的嵌入，放弃像素级重建换取效率与语义性。评估世界模型的根本困难在于：生成一段“看起来合理”的视频不等于理解了物理——模型可能学到的是视觉统计规律而非因果规律。这个张力将贯穿第 5 节的讨论。

还应指出“世界模型”与“视频生成模型”在评估逻辑上的根本差异：视频生成的成功标准是感知质量（人眼觉得真实、流畅、美观），世界模型的成功标准是**决策质量**（基于模型预测做出的动作是否在真实世界奏效）。一个视觉上惊艳但物理上错误的模型可以是优秀的视频生成

器，却是糟糕的世界模型；反过来，一个视觉粗糙但动态正确的模型（比如简笔画级别的模拟器）可能对规划更有价值。当前领域的混乱很大程度上源于用前一把尺子量后一类对象。第 5.3 节的”炒作 vs 实质”将反复回到这把尺子上。

2.4 拼装 vs 原生：多模态训练的两条道路

2023–2024 年的主流配方是”拼装”：拿一个训练好的 LLM，冻结或半冻结，接一个视觉编码器，用投影层对齐，再做指令微调（LLaVA 范式）。这条路便宜、有效，但有一个结构性缺陷：模型的语言能力在视觉训练前已经定型，视觉始终是”外来器官”，深度的跨模态融合（比如对图像内部的细粒度推理）受到先天限制。

原生多模态预训练（native multimodal pretraining）则从一开始就混合训练：文本语料、图文对、交错图文文档、视频转录同时进入预训练阶段，模型从未”见过”一个纯文本的自己。原生路线的理论诱惑在于能力涌现的对称性——理解与生成、视觉与语言在共享的梯度流中共同成长；工程代价则是训练稳定性与数据配方的复杂度大幅上升。Chameleon 与 InternVL3 分别代表了”从零原生”与”联合原生”两种实现。理解这两条道路的张力，是理解第 5.4 节的前提。

一个折中而日益流行的立场是”功能上的原生”：架构上仍保留预训练视觉编码器（享受其表征红利），但训练流程上把视觉数据前移到预训练阶段（享受联合学习的红利）。InternVL3 属于此类。这说明”原生 vs 拼装”在实践中不是二元对立，而是一个谱系——光谱的一端是 LLaVA 式的纯后适配，另一端是 Chameleon 式的从零全融合，大多数 2025 年的旗舰停在中间偏原生的位置。评估任何号称”原生”的新模型时，第一个该问的问题是：它在光谱上的确切位置在哪里？

3 经典方法谱系

本篇的”经典谱系”不是按时间复述模型史，而是三条**范式演化的脉络**，它们最终在 2025–2026 年交汇。

脉络一：从对齐到统一（2022–2025）。Flamingo（2022）用 Perceiver Resampler 把冻结的视觉与语言模型缝合，确立了”冻结主干 + 可学习接口”的拼装范式；LLaVA 的视觉指令微调（2023）把这个范式民主化，人人都能在消费级显卡上”造”一个多模态模型。但拼装的天花板很快显现：理解强、生成弱，模型对图像是”看得见却画不出”。Chameleon（2024，Meta）第一次认真地尝试了早期融合——图像与文本从预训练起就是同一种 token；Transfusion（2024，Meta）给出另一种答案——同一 Transformer，语言部分用自回归损失、图像部分用扩散损失；Janus（2024，DeepSeek）则发现理解与生成对视觉编码的需求本质冲突，选择解耦编码路径。到 Emu3（2024）与 BAGEL（2025），”单一架构统一一切”已经从异端变成显学。

脉络二：从感知到推理（2023–2026）。早期多模态评测（MME、MMBench，2023）主要测感知与浅层问答；MMMU（2023）与 MathVista（2023）第一次把专家级推理摆上桌面，暴露了模型”看得见但不会想”的窘境。语言领域 o1（2024）与 DeepSeek-R1（2025 年初）证明了 long CoT + RLVR 的威力，随后三个月内，Vision-R1、Visual-RFT、R1-Onevision 等密集出现，把同样的配方迁移到视觉。到 2025 年中，”视觉推理模型”已从新奇物种变成一个完整的子领域，MathVista 上的成绩水涨船高（据多模态 CoT 综述 [1] 的统计，头部模型已从 50% 区间推进到 70% 以上）。

脉络三：从观看到模拟（2024–2026）。视频生成模型（Sora, 2024）展示了令人惊叹的物理直觉——物体守恒、光影一致——引发”视频生成器即世界模型”的大讨论；Genie（2024, DeepMind）补上了关键一环：交互性，即从无标注视频中推断潜在动作空间，让生成的世界可以被”玩”；Cosmos（2025, NVIDIA）把世界模型工程化为面向物理 AI 的平台；V-JEPA 2（2025, Meta）则代表另一条路线：放弃像素生成，在表征空间预测未来，并用极少量的机器人数据赋予其规划能力。

三条脉络的交汇不是巧合。对齐到统一的脉络解决了”表示”问题——视觉与语言如何在同一模型内共处；感知到推理的脉络解决了”训练”问题——能力如何被后训练系统性激发；观看到模拟的脉络解决了”目标”问题——模型学习的究竟是数据还是世界。2025–2026 年的前沿工作几乎都坐落在这三条脉络的交叉点上：BAGEL 是统一 × 原生的交叉，Vision-R1 是推理 × 感知的交叉，V-JEPA 2 是模拟 × 自监督的交叉。读懂这个坐标系，比记住任何一个模型都重要。

关键论文一览表（本篇核心引用的 30 篇，全部来自已验证文献清单）：

论文	年份	核心思想	架构要点	备注
Flamingo [7]	2022	交错图文少样本学习	Perceiver Resampler + 冻结 LM	拼装范式确立
LLaVA (Visual Instruction Tuning) [8]	2023	视觉指令微调	线性投影 + LLM	民主化对齐
InstructBLIP [9]	2023	指令感知的 Q-Former	26 数据集统一微调	数据工程先声
Qwen-VL [10]	2023	多语言多任务 VLM	位置感知视觉适配	开源旗舰起点
VILA [11]	2023	预训练配方研究	交错数据至关重要	数据配比科学化
mPLUG-Owl3 [12]	2024	长图像序列理解	交错图文超注意力	长上下文先声
Molmo & PixMo [13]	2024	完全开源权重与数据	从零收集 PixMo	开放科学标杆
DeepSeek-VL2 [14]	2024	MoE 视觉语言模型	动态分辨率切片	稀疏化开端
Chameleon [15]	2024	混合模态早期融合	全离散 token + 稳定化技巧	原生路线宣言
Transfusion [16]	2024	下一 token + 扩散双损失	单 Transformer 双目标	连续路线代表
Show-o [17]	2024	单 Transformer 统一	自回归 + 离散扩散混合	折中探索
Emu3 [18]	2024	一切皆下一 token 预测	图像/视频全离散化	极简统一 (§4.1)
Janus [19]	2024	解耦视觉编码	双编码路径单主干	冲突诊断经典

论文	年份	核心思想	架构要点	备注
MetaMorph [20]	2024	指令微调即可生成	预测视觉 token	轻量统一证据
Genie [21]	2024	无动作标注的交互环境	潜在动作 + ST tokenizer	世界模型元年
Sora 综述 [22]	2024	Sora 技术与局限	DiT 视频生成	争议起点
LongVILA [23]	2024	长上下文 VLM 系统	多模态序列并行	1M token 系统路
LongVA [24]	2024	语言到视觉的上下文迁移	短视训、长视推	低成本长上下文
Qwen2.5-VL [25]	2025	动态分辨率与文档理解	原生分辨率 ViT	工程集大成
Qwen2.5-Omni [26]	2025	全模态流式	TMRoPE + Thinker-Talker	omni 范式样板
InternVL3 [27]	2025	原生多模态预训练	单阶段联合预训练	原生范式证据
Qwen3-VL [28]	2025	256K 原生上下文 + MoE	dense + MoE 全谱系	规模化现状
GLM-4.5V [29]	2025	可扩展 RL 多模态推理	RLVR 全流程	推理旗舰之一
BAGEL [30]	2025	统一预训练涌现特性	decoder-only + 交错万亿 token	涌现分析 (§4.2)
Vision-R1 [31]	2025	冷启动 + GRPO 视觉推理	PTST 抑制过度思考	RLVR 迁移 (§4.3)
R1-Onevision [32]	2025	跨模态形式化推理	视觉转形式化语言	推理桥接
Visual-RFT [33]	2025	视觉强化微调	可验证奖励检测/分类	奖励设计样本
OpenVLThinker [34]	2025	迭代 SFT-RL 循环	自举式数据生成	训练范式探索
Cosmos [35]	2025	物理 AI 世界基础模型平台	全栈数据-模型-部署	平台化 (§4.4)
V-JEPA 2 [36]	2025	自监督视频理解-预测-规划	表征空间预测 + 潜在动作	预测派 (§4.5)

4 代表作深度剖析

我们从六股趋势中选出五个代表性工作：Emu3 与 BAGEL 代表统一架构的两种答案，Vision-R1 代表推理革命的迁移方法论，Cosmos 与 V-JEPA 2 代表世界模型的两条对立路线。选择标




图 1 全模态的 hub-spoke 格局

准有三：是否提出了可迁移的方法论、是否有充分的公开细节、是否能体现该趋势的核心张力。

4.1 Emu3：极简主义的宣言（2024）

研究问题。多模态建模能否完全抛弃扩散模型与组合式架构，只用“下一 token 预测”这一个目标函数，同时做好理解、图像生成与视频生成？

关键洞察。Emu3 的洞察不是技术创新，而是信仰确认：把图像、视频、文本全部离散化为 token 之后，多模态建模与普通语言建模在数学上没有任何区别。此前的主流观点认为离散化的信息损失会让生成质量永远追不上扩散模型，Emu3 赌的是：只要分词器足够好、数据与算力足够多，scaling 会抹平这个差距。

技术方法。架构是一个从零训练的 decoder-only Transformer。图像与视频经由视觉分词器转为离散 token，与文本 token 混合成统一序列，用标准交叉熵损失训练，不需要任何扩散目标、对比目标或组合模块。生成图像时逐 token 自回归解码，再经分词器解码器还原为像素；生成视频则是预测下一帧 token 序列。

实验结果。论文报告 Emu3 在图像生成上超过 SDXL 等扩散旗舰，在理解任务上超过 LLaVA-1.6 等组合式模型，同时能生成高保真视频——三个赛道用同一模型、同一损失。这是“单一目标函数统一多模态”的第一次大规模正面证明。

批判性分析。优点：概念上极致简洁，训练、推理、scaling 全部复用 LLM 基础设施，工程复利巨大。局限同样清晰：（1）自回归逐 token 生成图像在推理速度与扩散模型存在数量级差距，高质量大图意味着上万次串行解码；（2）Transfusion 的 scaling law 对比实验 [16] 显示，在同等计算量下，连续扩散路线在图像生成上的样本效率显著优于离散 token 路线——Emu3 赢在统一性，不是赢在效率；（3）离散分词器成为新的能力瓶颈，重建质量上限锁死了生成质量上限。可复现性良好：模型与代码开源。

横向看，Emu3 的历史角色类似语言模型史上的 GPT-1：它本身未必是最强的，但它把“这条路走得通”变成了公共知识，此后 Chameleon 式的质疑（“离散化会丢信息”）从致命伤降级为工程问题。值得注意的是，Emu3 的开源使学术界第一次能够亲手解剖一个统一模型的内部表征——第 8 节建议的“统一模型机制分析”正是以此为基础。

一句话评价：一篇“哲学大于技术”的里程碑——它证明的是道路的可行性而非最优性，但它证明得足够干净。评级：★★★★☆

4.2 BAGEL：统一预训练的涌现证据（2025）

研究问题。如果 Emu3 证明了“可以统一”，BAGEL 追问的是更进一步的问题：统一训练之后，理解与生成是互相竞争还是互相增强？统一的规模红利在哪里涌现？

关键洞察。BAGEL 的核心 claim 是“涌现”（emerging properties）：当 decoder-only 统一模型在万亿级交错多模态 token（文本、图像、视频、网页）上预训练并越过某个规模阈值后，会自发出现训练目标中没有显式编码的能力——自由形式的图像编辑、未来帧预测、3D 视角操纵、世界导航。这与语言模型中的涌现叙事一脉相承：统一架构 + 数据多样性 + 规模 = 意料之外的泛化。

技术方法。BAGEL 是 7B 量级的开源 decoder-only 统一模型，原生支持多模态理解与生成。预训练数据为大规模交错的文本-图像-视频-网页 token（万亿级）。论文的贡献与其说是架构创新，不如说是一份详尽的“统一预训练实验报告”：数据创建协议、训练细节、规模与能力的关系曲线全部公开。

实验结果。在标准理解与生成基准上显著超过此前的开源统一模型，并展示了若干“高级推理”能力样例：给定图像进行自由形式编辑、预测视频未来帧、根据指令进行 3D 操纵与导航。这些能力被解释为理解任务向生成任务的迁移——因为模型“理解”了场景，所以能“生成”合理的编辑。

批判性分析。优点：（1）完全开源（代码、权重、数据协议），是统一模型方向最慷慨的公开资产；（2）“涌现”分析为统一路线提供了超越“工程合并”的科学论据。局限：（1）“涌现”的界定偏定性，展示的更多是 cherry-picked 样例而非系统性基准，涌现阈值与数据构成之间的因果关系尚不清晰；（2）与同期顶级闭源统一系统（如 GPT-4o 级别的图像生成）相比仍有可见差距，7B 规模的“涌现”在多大程度上能外推到更大规模是开放问题；（3）交错数据的策展成本极高，数据协议虽公开但复现的数据工程投入不可小觑。

一句话评价：统一路线从“能做”到“值得做”的关键证据，开源社区的统一模型基石。评级：★★★★☆

4.3 Vision-R1：推理革命的迁移方法论（2025）

研究问题。DeepSeek-R1-Zero 证明了纯 RL 可以在语言模型中激发出反思式推理，但直接把同样的 RL 套在多模态模型上却不奏效——为什么？怎么修？

关键洞察。Vision-R1 对失败原因的诊断非常诚实：语言模型坐拥海量数学/代码推理语料，RL 只需“唤醒”已有能力；而多模态语料中高质量的长推理链几乎不存在，视觉模型对“先观察、再推理”的行为模式没有先验，纯 RL 在巨大的搜索空间中找不到奖励信号。换言之，RLVR 的迁移瓶颈不是算法而是数据。

技术方法。两阶段配方。第一阶段冷启动：利用"模态桥接"——让现有 MLLM 描述图像，把视觉内容转成本上下文，再让 DeepSeek-R1 在其上生成推理链，经过滤后得到 20 万条多模态 CoT 数据 (Vision-R1-cold)，完全无人工标注。第二阶段 RL：用 GRPO 配合"硬格式结果奖励"（答案正确与否可程序化判定）继续训练。针对冷启动后普遍出现的"过度思考"（overthinking，推理链冗长且性能反降）问题，提出渐进式思考抑制训练（Progressive Thinking Suppression Training, PTST），在训练早期刻意压缩推理长度、后期逐步放开。

实验结果。在多个视觉推理基准上取得显著提升，成为 2025 年初视觉 RLVR 浪潮中被广泛引用的配方模板：冷启动数据 → 抑制过度思考 → GRPO 精炼。

批判性分析。优点：（1）对"为什么直接 RL 失败"的诊断清晰且可操作，冷启动数据构造方法是真正的贡献；（2）PTST 直面了 R1 式模型在多模态上的特异病症——推理链越长，幻觉风险越高（安全篇第 5.1 节称之为"思考越多，看见越少"），这与推理模型幻觉放大的独立观察相互印证。局限：（1）冷启动数据本质上是 R1 推理风格的蒸馏，模型学到的是"像 R1 那样说话"，其中有多少是真正基于视觉证据的推理、多少是语言先验的复读，缺乏机制层面的分析；（2）奖励限于答案可验证的任务（数学为主），对开放式视觉推理的泛化未经验证；（3）与 Visual-RFT [33]、R1-Onevision [32] 等同期工作结论部分重叠，各家配方的消融对比仍不充分——后来"SFT or RL?" [37] 的研究表明，SFT 冷启动可能引入"伪推理路径"（imitated 的冗长、犹豫、低信息量步骤），反而损害后续 RL，这与 Vision-R1 的冷启动设计构成了需要正视的张力。

横向看，Vision-R1、Visual-RFT 与 R1-Onevision 构成了一个自然实验：三家几乎同时出发，选择了冷启动、直接 RL 与形式化桥接三条不同的路，最终都报告了显著提升。这种"条条大路通罗马"的结果有两种解读：乐观的解读是视觉 RLVR 的底层红利足够厚，任何合理的配方都能分到一杯羹；悲观的解读是当前基准（以数学为主）的信号太粗，不足以区分配方的优劣。真相可能居中：奖励信号的"有无"是一阶效应，配方的"优劣"是二阶效应——这与语言领域 RLVR 早期的历史惊人地一致。

一句话评价：视觉 RLVR 的"零号配方"，诊断比药方更有价值；其冷启动路线与后来者"RL 优先"路线的争论至今未分胜负。评级：★★★★☆

4.4 Cosmos：世界模型的平台化野心（2025）

研究问题。NVIDIA 把问题从"如何训练一个世界模型"改写为"如何让每个物理 AI 开发者都能定制自己的世界模型"——世界模型能否像基础模型一样，预训练一次、下游微调？

关键洞察。Cosmos 的定位陈述值得逐字玩味："物理 AI 需要先在数字世界中被训练——它需要自己的数字孪生（策略模型），以及世界的数字孪生（世界模型）。"其核心洞察是世界基础模型（World Foundation Model）的概念：一个通用的、大规模预训练的视频世界模型，可以通过后训练定制为特定场景（仓库、马路、手术室）的专用模拟器。这把世界模型从研究对象变成了基础设施。

技术方法。Cosmos 是一个全栈平台而非单一模型：视频数据策展管线（从海量视频中筛出物理上信息丰富的片段）、预训练的世界基础模型（扩散与自回归两个家族）、后训练示例（如面向自动驾驶场景的条件化）、以及视频分词器。全部以宽松许可证开源开放权重。

实验结果。论文的重点是平台能力与下游定制的可行性展示（例如用预训练 WFM 微调到特定机器人/驾驶场景），而非在统一基准上与 Genie 等模型正面对比——这本身就揭示了领域现状：世界模型缺乏公认评估标准。

批判性分析。优点：(1) 数据策展管线的公开是实打实的贡献，物理 AI 数据的筛选与标注方法论此前几乎是黑箱；(2) 开源 + 宽松许可在巨头世界模型竞赛中独树一帜；(3) "预训练-微调" 的平台范式如果被验证，将极大降低机器人仿真数据的获取成本。局限：(1) "世界基础模型" 的通用性主张缺乏严格证据——微调后的模型在分布外物理情境中是否仍保持因果一致性，论文未系统检验；(2) 与 NVIDIA 的 Omniverse/Isaac Sim 商业生态深度绑定，"开放" 中带有明确的平台战略意图，这无可厚非，但研究者应意识到评估其主张时的利益背景；(3) 回避了最根本的质疑：生成的视频在多大程度上编码了物理因果而非视觉统计？一段看起来合理的货架倒塌视频，与一段物理正确的货架倒塌视频，在训练信号中是无法区分的。

一句话评价：世界模型从论文走向平台的标志性事件；它回答的是工程问题，回避的是科学问题。评级：★★★★☆

4.5 V-JEPA 2: 不在像素里做梦 (2025)

研究问题。理解世界、预测未来、规划动作，能否全部在抽象表征空间完成，而完全不生成像素？

关键洞察。V-JEPA 2 代表世界模型的"预测派"哲学，与生成派针锋相对：像素级生成是对算力的浪费——要预测"球会滚向哪里"，你不需要渲染球的纹理。联合嵌入预测架构 (JEPA) 在表征空间中预测未来的编码 s_{t+1} 而非像素 x_{t+1} ，把容量集中在语义与动态上。这条路线继承了 LeCun 长期以来对"生成式 AI 并非通向世界模型的正道"的论战立场，因此它的成败具有超出单个模型的意义。

技术方法。三阶段：(1) 无动作预训练——在超过 100 万小时的互联网视频与图像上训练 joint-embedding-predictive 架构；(2) 与 LLM 对齐——得到视频问答能力；(3) 动作条件化——仅用不到 62 小时的无标注机器人轨迹，后训练出潜在动作条件的世界模型 V-JEPA 2-AC，用于规划。

实验结果。论文报告了多项硬指标：运动理解 Something-Something v2 上 77.3 top-1 准确率；人类动作预期 Epic-Kitchens-100 上 39.7 recall-at-5 (超过此前任务专用模型)；与 LLM 对齐后在 8B 规模取得视频问答 SOTA (PerceptionTest 84.0、TempCompass 76.9)；机器人规划任务上，V-JEPA 2-AC 展示了零样本的规划能力。

批判性分析。优点：(1) 数据效率惊人——62 小时机器人数据赋予百万小时视频预训练模型以规划能力，是"互联网视频是机器人训练的免费午餐"这一假说迄今最有力的证据之一；(2) 在"理解"类基准上同时拿高分，反驳了"表征学习牺牲细粒度感知"的疑虑；(3) 不生成像素意味着评估更诚实——你无法被漂亮画面蒙蔽，规划成功率是硬指标。局限：(1) 规划展示限于相对简单的抓取/到达任务，与"通用世界模拟器"的愿景之间还有数量级的任务复杂度差距；(2) 表征空间的预测是不可可视化的，模型的"世界理解"对调试与审计更不透明；(3) 与生成派的对比并不公平——两者目标函数不同，一个是规划工具一个是内容引擎，所谓"路线之争"在应用层面可能根本不是零和。

一句话评价：自监督路线最优雅的现代样本；"世界模型必须生成世界"这一流行直觉的最有力反例。评级：★★★★★

把 § 4.4 与 § 4.5 放在一起读，会得到一个比单独读任一篇都更清晰的图景。Cosmos 与 V-JEPA 2 的分歧不在技术细节，而在对"智能栖身何处"的根本判断：Cosmos 赌智能在生成能力中——能造出世界才算懂世界；V-JEPA 2 赌智能在预测抽象中——能预见后果才算懂世界，生

成只是昂贵的副产品。耐人寻味的是，两者在工程实践中正在悄悄互相借用：Cosmos 平台包含自回归家族（向序列预测靠拢），V-JEPA 2 的规划需要动作条件的潜在生成（向生成靠拢）。路线之争的终局很可能不是一方胜出，而是“生成用于交互与数据、表征用于规划与理解”的功能性分工——正如人脑既能在想象中渲染场景，也能在概念层面推演因果。

5 研究前沿 (2025-2026): 六股结构性趋势

本节是全篇主体。每一股趋势按统一的三段式展开：潮流描述（发生了什么）、驱动机制（为什么是现在）、炒作 vs 实质（冷静评估）。

5.1 趋势一：统一理解-生成——单一 Transformer 的大一统

潮流描述。2023 年的多模态世界是分裂的：理解属于“ViT + connector + LLM”，生成属于扩散模型，两个阵营共享很少的技术栈。2024-2025 年，这个分裂以出人意料的速度弥合。架构答案收敛为三个家族：(a) 全离散派——一切皆 token，Emu3 [18]、Chameleon [15]，图像视频经 VQ 分词器离散化后与文本同构；(b) 双损失派——同一主干，文本用自回归损失、图像用扩散损失，Transfusion [16]，以及 BAGEL [30] 的 decoder-only 统一预训练；(c) 解耦派——共享主干但理解与生成使用不同的视觉编码路径，Janus [19] 及其后继者 Janus-Pro，理由是“理解需要语义抽象、生成需要像素保真，两者对编码器的需求本质冲突”。工业界方面，Qwen3-VL [28] 等旗舰已把“统一理解与生成”写进技术报告的核心卖点，GPT-4o 级别的闭源系统则早已把原生图像生成作为默认能力。

驱动机制。三股力量合流：其一，LLM 基础设施的引力——统一架构意味着训练框架、推理引擎、scaling 经验全部复用，工程复利诱人；其二，数据形态的自然演化——互联网原生数据本来就是交错的图文视频流，“为理解与生成分别建管线”在数据层面越来越像人为割裂；其三，涌现假说的诱惑——BAGEL 声称观察到的理解-生成协同增强，给了统一路线超越工程便利的科学叙事。

炒作 vs 实质。实质部分：统一架构的可行性已经无可争议，开源 7B 级模型（BAGEL）即可兼得体面的理解与生成，这在两年前是难以想象的；“理解增强生成”的迁移效应有初步但真实的证据（自由形式编辑、指令式 3D 操纵）。炒作部分：(1) “涌现”叙事被过度消费——多数所谓涌现能力缺乏系统性基准，样例展示居多；(2) 统一模型在纯生成质量上仍未追平最好的专用扩散模型，在纯理解上也未明显超越最好的拼装模型——统一目前的红利主要是工程与叙事，而非能力上限；(3) Janus 揭示的编码冲突并未被解决，只是被绕开：全离散派牺牲保真度，双损失派牺牲简洁性，解耦派牺牲统一性。真正的“大一统”——单一表示、单一损失、单一架构同时做到 SOTA——仍然是一个未被领取的悬赏。

与前篇的分工。生成篇（第 05 篇）已详述扩散与自回归作为生成范式的内部竞争，全模态篇（第 04 篇）已讨论 omni 模型的生成头设计；本节的焦点不重复这些细节，而在“统一”作为跨方向引力的后果：一旦理解与生成分属两个模型的假设被打破，评测体系（如何评估一个既能答又能画的模型）、数据工程（交错数据取代图文对）、安全议题（生成能力引入新的滥用面）都要跟着改写。统一不是架构师的审美偏好，而是一次牵动全栈的重新组织。

5.2 趋势二：多模态推理革命——R1 时刻的视觉回响

潮流描述。2025 年第一季度是多模态研究史上罕见的密集爆发期：DeepSeek-R1 发布（2025 年 1 月）后数周内，Vision-R1 [31]（3 月）、Visual-RFT [33]（3 月）、R1-Onevision [32]（3 月）、OpenVLThinker [34]（3 月）、Skywork R1V2 [38]（4 月）接连出现，“视觉 RLVR”从无人区变成显学。配方迅速分化为三个流派：(a) 冷启动 + RL (Vision-R1)：先用蒸馏的长 CoT 数据初始化，再 GRPO 精炼；(b) 直接 RL (Visual-RFT)：跳过 SFT，直接用可验证奖励微调，论文报告在分类、检测等任务上百条数据即可取得显著收益；(c) 迭代 SFT-RL (OpenVLThinker)：SFT 学基础 → RL 优化推理 → 生成新数据 → 再 SFT，自举式循环。评测侧，MathVista [39]、MMMU [40]、OlympicArena [41] 等推理基准成绩水涨船高，据综述 [1] 的口径，头部模型在 MathVista 上已从 50% 区间推进至 70% 以上。

驱动机制。为什么迁移如此迅速？因为 RLVR 的三个前提在多模态上恰好成立：(1) 可验证奖励的存在——视觉数学、计数、检测、OCR 都有程序化答案校验，奖励信号廉价且防作弊；(2) GRPO 的工程友好——去掉 value network 后对显存紧张的多模态训练格外友好；(3) 基座能力的就位——2024 年底的开源 VLM (Qwen2-VL 级别) 感知能力已经足够强，瓶颈从“看不见”变成“不会想”，推理训练恰好打在缺口上。

炒作 vs 实质。实质部分：在可验证任务上，RLVR 带来的提升是真实的、可复现的，多家独立工作相互印证；更重要的是方法论的迁移——“模态桥接造数据 + 可验证奖励 + GRPO”已成为标准工具箱，VTool-R1 [42] 甚至把 RLVR 推广到工具使用。炒作部分：(1) 推理增益高度集中于数学与逻辑任务，向开放式视觉推理（因果、反事实、组合推理）的泛化证据薄弱——组合视觉推理综述 [6] 明确指出当前 MLLM 在复杂组合推理上仍远低于人类；(2) “思考越多，看见越少”：多项独立观察（含安全篇第 5.1 节）发现长推理链放大视觉幻觉，模型在冗长推理中逐渐脱离图像证据，复读语言先验——Vision-R1 的 PTST 恰恰是对这个病症的补丁；(3) “SFT or RL?” [37] 揭示的伪推理路径问题提醒我们：很多模型学到的是“推理的修辞”而非“推理的能力”，推理链看起来头头是道，与最终答案却可能仅有弱因果关联。推理链的可验证性——如何知道中间步骤本身是对的——是整个方向最大的暗礁。

与前篇的分工。推理训练的具体配方（GRPO 超参、奖励塑形、与 SFT 的交替节奏）在第 11 篇（数据与训练）中展开；推理带来的安全代价在第 09 篇中剖析。本节只保留结构性的判断：推理革命是六股趋势中可证伪性最强的一股——可验证奖励意味着提升可以精确归因，泡沫难以长期存活。这也是为什么我们对它的长期判断最为乐观：不是因为现在的数字最亮眼，而是因为它的反馈回路最诚实。

5.3 趋势三：世界模型——从生成视频到生成现实

潮流描述。世界模型是 2025-2026 年声量最大、争议也最大的趋势。三条路线同台竞技：(a) 生成交互派——Genie [21] (11B，从无标注互联网视频中学习潜在动作空间，生成可逐帧交互的环境) 及其闭源后继 Genie 2/3，把“可玩的生成视频”推向越来越长的时域一致性；(b) 物理 AI 平台派——Cosmos [35]，§ 4.4 已详述；(c) 表征预测派——V-JEPA 2 [36]，§ 4.5 已详述。应用叙事同样激进：机器人策略在世界模型中训练、自动驾驶在生成的世界中做安全测试、游戏资产由交互式生成替代手工建模。

驱动机制。两股深层力量：其一是数据的绝望与希望——机器人与自动驾驶的真实数据采集昂贵且危险，而互联网视频近乎无限，如果视频模型真的内化了物理，仿真成本将崩塌式下

降；其二是叙事的引力——"世界模型"是通向 AGI 叙事中少数既能吸引资本又有科学传统的概念 (Ha & Schmidhuber 2018 的遗产)，LeCun 与视频生成阵营关于"通往自主智能的路线"的公开论战进一步放大了关注度。

炒作 vs 实质。实质部分：V-JEPA 2 的 62 小时机器人数据规划实验是硬证据——视频预训练确实包含了可迁移到物理决策的结构；Genie 式潜在动作学习是真实的方法论创新（无动作标注学到可控性）；Cosmos 的数据管线是真实的工程贡献。炒作部分：(1) "看起来像物理"不等于"是物理"——视频生成模型学到的是视觉统计规律，物体守恒、重力方向等只在统计平均意义上成立；没有任何公开证据表明当前模型能对分布外的物理情境（新的材料、新的力学构型）做出因果正确的预测；(2) 评估真空——世界模型综述 [4] 坦承该领域缺乏统一评估标准，各家用自己的 demo 视频说话，"世界模型"一词正在经历与"AGI"类似的语义通胀；(3) 时域一致性的天花板——交互式生成在数十秒尺度上仍会出现状态漂移（物体消失、场景突变），而机器人规划需要分钟级以上的因果一致性。我们的判断：世界模型作为数据增强工具（为策略训练生成多样化场景）已经实用；作为物理模拟器（替代物理引擎做因果推演）仍是愿景。两者被刻意混用，是本趋势最大的认知污染。

与前篇的分工。具身篇（第 06 篇）讨论了世界模型作为机器人"训练场与评估器"的具体用法，视频篇（第 03 篇）讨论了视频生成模型的技术细节。本节保留的是最具争议的哲学问题：像素空间里能否长出因果？我们的立场是——可以作为归纳偏置的来源（预训练出对物理敏感的特征，V-JEPA 2 的规划迁移是证据），但不能作为因果知识的充分载体（分布外推定需要干预数据或显式结构）。这个区分决定了世界模型研究的合理期待：追求"更好的数据引擎"是健康的，宣称"替代物理引擎"是危险的。

5.4 趋势四：原生多模态预训练——从拼接到原生

潮流描述。2025 年，"原生多模态"完成了从口号到主流工程实践的转身。InternVL3 [27] 是标志性事件：它放弃了"先训 LLM 再适配视觉"的两阶段配方，在单一预训练阶段就同时消化多模态数据与纯文本语料，论文报告这一范式"有效解决了传统后适配管线的复杂性与对齐难题"。Chameleon [15] 则是更激进的从零原生。与此同时，预训练数据的形态也在原生化：从图文对 (image-caption pairs) 转向交错文档 (interleaved documents)、视频-转录流、网页快照——VILA [11] 早在 2023 年就证明交错数据对少样本能力的关键作用，2025 年这已成为默认配方。BAGEL 的万亿级交错 token 预训练，正是这一潮流在统一架构上的投影。

驱动机制。核心是对"对齐税"的觉醒：拼装范式中，视觉信息被压缩进 connector 的有限带宽，语言模型对视觉的理解永远隔一层翻译；原生训练中，跨模态关联从预训练第一步就写入权重，模型对"图像内部的推理"（而非"关于图像的推理"）有结构性优势。训练基础设施的成熟（异构数据混采、多模态 packing、稳定化技巧从 Chameleon 开始积累）则扫清了工程障碍。

炒作 vs 实质。实质部分：InternVL3 与 Chameleon 提供了原生路线可行且更优的直接证据，且原生范式天然兼容统一架构（趋势一）与交错数据（趋势四内部），是事实上正在发生的基础设施换代。炒作部分：(1) "原生"的边界模糊——绝大多数号称原生的模型仍使用预训练视觉编码器 (SigLIP 等)，真正的"从像素到权重全原生"只有 Chameleon 级别的工作尝试过，而 Chameleon 的理解性能恰恰暴露了其代价；(2) 原生预训练是巨头游戏——数据策展与算力门槛远超拼装微调，学术界能做的大多仍是"拼装优化"，"原生"作为研究口号对多数实验室并不可操作；(3) 原生 vs 拼装的对比研究大多出自推销原生路线的团队，独立的、控制变量的第三方对比仍然稀缺。谨慎的结论：原生是未来，但"拼装"在相当长时间内仍是学术界的现实，两

者之间的能力差距究竟有多少来自范式、多少来自数据规模,是一个被有意无意回避的问题。

与前篇的分工。数据与训练篇(第 11 篇)讨论了交错数据策展、混采配比与课程设计的具体技术;本节只强调一个结构性后果:原生范式改变了研究的最小可行单元。拼装时代,一个研究生可以在单卡上做出有意义的贡献(更好的 connector、更好的指令数据);原生时代,有意义的问题被前移到预训练,学术界的比较优势被迫从"建造"转向"分析"——剖析原生模型、审计其数据、设计诊断基准。这不是学术界的退场,而是角色的再定位,第 8 节将把这个判断落到具体建议上。

5.5 趋势五: 架构多样化与超长上下文——Transformer 之外的传檄文与 1M token 的多模态意义

潮流描述。两条看似独立的架构线索在 2025 年交汇于多模态。第一条是注意力之外的探索: Mamba 式状态空间模型、RWKV 式线性 RNN、线性注意力的多模态化尝试持续出现,混合架构(Transformer 层 + Mamba 层交替)在语言侧已被验证可行,向多模态迁移的逻辑直白——视觉 token 数量是文本的数十倍,二次方注意力的代价被等比放大。第二条是超长上下文的实用化: LongVILA [23] 以系统方法(多模态序列并行)把视频理解推进到百万 token 级, LongVA [24] 证明语言模型的长上下文能力可以零成本迁移到视觉(短视训练、长视推理), mPLUG-Owl3 [12] 处理交错长图像序列, Qwen3-VL [28] 原生支持 256K 交错上下文。1M+ token 的多模态意义不是"更长的视频"这么简单——它意味着模型第一次有能力在单次前向中容纳一整部电影、一整本扫描书、一次完整的实验记录。

驱动机制。多模态是长上下文需求最刚性的场景: 一分钟视频轻松产生数万 token, 文档理解、多图推理、GUI 操作历史都在膨胀上下文需求;而效率篇讨论的视觉 token 压缩与 KV cache 优化则从供给侧提供支撑。

炒作 vs 实质。实质部分: 长上下文的系统与迁移技术(LongVILA、LongVA)是扎实的工程科学;"上下文即记忆"对智能体(长操作历史)与科学(长实验记录)场景的使能价值是真实的。炒作部分: (1) 线性注意力/SSM 的多模态化至今没有产生一个在前沿基准上能与同规模 Transformer 正面对抗的旗舰模型——它仍然是一个"成本叙事"而非"能力叙事",且混合架构的流行恰恰说明纯替代路线尚未成立;(2) "1M token"的营销浓度很高: 有效上下文(模型真正利用远程信息的能力)与名义上下文(能塞进去的 token 数)之间的差距在视频场景尤为刺眼, Video-MME [43] 等基准显示长视频理解的提升远慢于上下文窗口的扩张;(3) 架构多样化的真正价值可能不在替代注意力,而在揭示注意力的哪些性质是本质的——这是一个科学贡献,但不是产品贡献。

与前篇的分工。效率篇(第 08 篇)系统讨论了 KV cache 压缩、视觉 token 剪枝与投机解码;本节关心的是架构层面的问题: 当上下文从万级跨入百万级,"把所有东西塞进注意力"是否还是正确的抽象? 越来越多的证据指向否定——长视频理解中模型对中段信息的利用显著弱于两端("lost in the middle"的多模态版本),这说明瓶颈已从"容量"转向"寻址"。显式记忆、检索增强与层级摘要很可能是超长上下文的下一站,而非更宽的窗口。

5.6 趋势六: AI for Science 的多模态维度与科研自动化

潮流描述。第六股趋势处于多模态研究与科学研究的边界上。Agentic science 综述 [5] 提出"感知-推理-行动"的科学发现闭环——文献综述、假设生成、实验设计、数据分析、结论验证——

而多模态理解是闭环中多个环节的底座: 论文中的图表与公式、实验产出的图像与信号、仪器读数的时序。CharXiv [44] 等基准表明, 即便是最强的模型, 在真实论文图表理解上与专家仍有明显差距。与此同时, ai-researcher 式的科研自动化生态在 2025 年快速膨胀: 从文献调研 agent 到端到端的"AI 科学家" 系统, 多模态能力决定了这些系统能读懂多少科学——毕竟科学的很大一部分知识不在文字里, 而在图里。

驱动机制。科学文献是天然的多模态语料且标注质量高 (图注-正文对、公式-推导对); 科学任务天然具有可验证奖励 (数值答案、可复现实验), 与 RLVR (趋势二) 一拍即合; 科研劳动力的昂贵则为自动化提供了强劲的需求牵引。

炒作 vs 实质。实质部分: 图表理解、公式识别、跨模态文献挖掘是真实且被低估的瓶颈, 进展扎实 (尽管缓慢); "AI 辅助" 在材料筛选、天文巡天等数据密集型学科已经产生真实产出。炒作部分: (1) "自主科学发现" 的演示距离真实的科学实践还很远——当前系统擅长的闭环是"文献 → 假设 → 计算验证", 而真实科学的瓶颈常在物理实验的脏活与负结果的解释, 这些环节的多模态理解 (显微镜图像的伪影判别、异常曲线的物理解读) 恰是模型最弱处; (2) 幻觉在科学场景的代价被放大: 一个虚构的引用或误读的图表足以摧毁整个发现链, 可靠性工程远落后于能力演示; (3) 科学多模态数据的获取受版权与学科壁垒限制, 数据飞轮转得比通用领域慢得多。我们的判断: 这是六股趋势中社会期望值与现实差距最大的一股, 但也是长期复利最确定的一股——因为科学的反馈回路是客观的, 泡沫会在实验台前被戳破, 真正的进展会被留下。

与前篇的分工。智能体篇 (第 07 篇) 讨论了工具使用与多步规划的通用机制; 本节聚焦科学场景的特殊性——可验证性与高利害性并存。科学是少有的既能提供客观奖励信号 (趋势二的 RLVR 可以直接应用)、又对错误零容忍的领域, 这种张力使 AI4Science 成为检验前五股趋势成色的天然试金石: 一个推理模型如果会在图表上幻觉, 一个统一模型如果生成不了实验设置的示意图, 一个世界模型如果模拟不了烧杯里的反应, 它们在通用基准上的高分就要大打折扣。

5.7 六股趋势的合流: 一张大图

把六股趋势叠在一起, 可以看到清晰的耦合结构: 趋势一 (统一架构) 与趋势四 (原生预训练) 互为表里——统一架构需要原生数据, 原生训练天然走向统一; 趋势二 (推理) 正渗入一切——推理增强理解、引导生成 (先想后画)、驱动世界模型的规划、构成科研 agent 的内核; 趋势三 (世界模型) 是趋势一生成能力的时域延伸; 趋势五 (长上下文) 是所有趋势的基础设施; 趋势六 (AI4Science) 则是前五股趋势的第一个"高利害应用考场"。如果必须预测下一个范式转移的位置, 我们押注在推理、生成与世界模型三者的交汇处: 一个先推理出"应该看见什么"、再生成候选世界、再用理解能力校验生成结果的闭环系统。这个闭环一旦打通, "模型欺骗评估者" 与"模型欺骗自己" 的难度将同步上升——那才是真正的智能体征。

作为收官篇, 我们还欠读者一组可证伪的预测。我们对未来 18-24 个月的具体押注是: (1) 统一架构将在开源社区成为默认选项, 但"单一表示同时 SOTA 理解与生成" 不会被领取, 解耦与混合设计继续主导旗舰系统; (2) 视觉 RLVR 的提升将在数学类基准上饱和, 研究重心转向推理链的过程监督与视觉接地校验; (3) 世界模型将产出一个小众公认的小型因果评估协议, 届时大量当前宣称将被迫撤回或降调; (4) "原生预训练" 一词将因边界模糊而逐渐失去营销价值, 被更精确的数据-流程描述取代; (5) 科研 agent 将在一到两个数据密集型窄领域 (如特定材料族筛选、特定巡天数据分类) 产生经得起同行评议的成果, 但"通用 AI 科学家" 不会出现。如果五年后回看, 这些预测错了一半, 那多半是因为我们低估了闭环系统 (推理-生成-校验) 的涌

现速度——那是我们唯一愿意承认自己可能过度保守的地方。

6 技术路线对比与权衡

表 1：统一理解-生成的三条架构路线

维度	全离散 (Emu3/Chameleon)	双损失 (Transfusion/BAGEL)	解耦编码 (Janus)
表示	全部离散 token	文本离散 + 图像连续	理解/生成各自编码器
损失	单一交叉熵	AR + 扩散	AR 为主
统一性	最高	高 (单主干)	中 (编码分裂)
生成保真	受分词器上限锁死	高 (连续扩散)	高
推理成本	逐 token 串行, 昂贵	扩散迭代, 中等	中等
样本效率	较低 (Transfusion scaling 对比 [16])	较高	较高
基础设施复用	完全复用 LLM 栈	需双目标训练支持	复用度高
代表风险	分词器成能力瓶颈	两目标优化干扰	"统一" 名不副实

表 2：视觉推理训练三条路线

维度	冷启动 + RL (Vision-RL)	直接 RL (Visual-RFT)	迭代 SFT-RL (OpenVlThinker)
数据需求	20 万级蒸馏 CoT	百级可验证样本即可起步	多轮自举生成
对基座要求	低 (冷启动补足)	中高 (需初步推理先验)	中
主要风险	伪推理路径、过度思考	小模型搜索空间过大	计算成本、误差累积
可复现性	高 (数据构造公开)	高	中 (流程复杂)
适用场景	复杂推理任务	数据稀缺的可验证任务	持续自我提升

文献综述中关于 SFT 与 RL 的对比结论值得引用：SFT 在数据充足时样本效率高但易导致灾难性遗忘，RL 更稳定但收敛慢，"SFT 冷启动 + RL 精炼" 是当前最佳实践——但 [37] 的警告同样成立：冷启动数据的质量与"推理风格的原生性" 决定了这条路的成色。

表 3：世界模型的两条哲学

维度	生成式（Genie/Cosmos/Sora 谱系）	预测式（V-JEPA 2）
预测对象	像素	抽象表征
计算开销	高	低
可解释性	可视化，直观但易被"漂亮画面"误导	不透明，但指标诚实
物理因果	视觉统计意义上学到部分规律	在规划任务上间接验证
数据效率	需海量视频	海量视频 + 极少量交互数据即可规划
适合任务	内容生成、数据增强、仿真可视化	规划、控制、理解
核心质疑	"像物理"而非"是物理"	规划任务复杂度尚低

7 开放问题与未来方向

1. 统一架构的表示终局。离散与连续之争仍未有理论裁决：是否存在一种表示，既保住生成的保真度又保住理解的语义性？"连续 token + 单损失"或新型分词器（如语义-像素双通道）是可能的突破口。更深层的开放问题是：理解与生成共享表示的理论最优性条件是什么？
1. 推理链的可验证性。当前 RLVR 只验证最终答案，中间步骤的真实性无人担保——"伪推理路径"问题 [37] 只是冰山一角。过程奖励模型（PRM）在多模态上如何落地？视觉证据与推理步骤之间的接地校验（每一步推理指向图像的哪个区域）可能是比答案奖励更本质的信号。
1. 世界模型的因果性检验。领域急需超越"demo 视频"的评估协议：分布外物理预测、反事实一致性（"如果球更重会怎样"）、长时域状态追踪。在评估缺位的情况下，"世界模型"一词的语义通胀将持续。
1. 原生预训练的成本-收益解剖。原生 vs 拼装的差距中，多少来自范式、多少来自数据规模与算力？需要一个控制变量的公开实验，这本身可以成为有影响力的学术研究。
1. 有效上下文 vs 名义上下文。1M token 窗口中，模型真正利用了多少？长视频/长文档理解需要"利用率"维度的诊断基准，以及显式记忆机制（而非暴力扩展注意力）的架构探索。
1. 科学多模态的可靠性工程。科研 agent 的瓶颈不是能力而是可信：幻觉检测、不确定性量化、可审计的推理链。这是少有的"工程投入直接兑换科学价值"的方向。

1. 闭环系统的涌现条件。推理-生成-校验闭环在什么规模与训练配方下会自稳？这既是工程问题，也可能触及“智能需要几种功能模块”的理论问题。

8 研究机会点评（给入门研究者的建议）

算力门槛适中、问题清晰、值得投入：

- 推理链与视觉证据的接地校验。用中等规模开源模型（7B 量级）研究“推理步骤是否真正引用了图像内容”，方法可以是注意力分析、反事实编辑（改掉图像关键区域看推理链是否变化）、或设计需要逐步视觉校验的新任务。问题清晰、算力友好、顶会潜力高，且直击趋势二最大的暗礁。
- RLVR 的奖励设计。为新的视觉任务设计可验证奖励（文档结构、图表数值、GUI 状态），Visual-RFT 证明了小数据 + 好奖励的杠杆，任务空间远未被穷尽。
- 世界模型的小型因果基准。构造受控的合成物理场景，系统测试生成模型在分布外参数（质量、摩擦、光照）下的预测一致性。这是评测类工作，算力需求低，但领域渴求度高（趋势三的评估真空）。

需要一定资源但学术机构可及：

- 统一模型的机制分析。在开源统一模型（Emu3、BAGEL）上做表示层面的解剖：理解与生成在哪些层共享、哪些层分化？这类“机制可解释性 × 统一架构”的工作几乎空白。
- 科学图表理解的细粒度诊断。CharXiv 级别的基准 + 错误类型学分析，门槛在于标注质量而非算力。

坦诚告知是巨头游戏：

- 原生多模态预训练、旗舰级世界模型、1M+ token 系统工程——这些方向的边际贡献与算力投入强正相关，学术机构更适合做它们的“分析者”（评测、解剖、批评）而非“建造者”。历史经验（效率方法、对齐技术、评测基准）反复表明，分析者的工作同样产生高影响力成果。
- 全模态 omni 系统的端到端训练同理；但 omni 系统的评测（全双工交互质量、跨模态一致性）是开放的荒地。

元建议：2025–2026 年的领域迁移速度意味着，最值钱的技能不是精通某个架构，而是识别一个已验证范式向新模态/新任务迁移的可行性——R1→ 视觉的六周窗口期未来还会反复出现。保持对语言、生成、机器人三个相邻领域的文献敏感度，是多模态研究者最高杠杆的时间投资。

9 术语表

1. RLVR（可验证奖励强化学习）：用程序化规则（答案对错、代码通过）而非学习出的奖励模型提供 RL 信号的后训练范式。

2. GRPO (组相对策略优化): 对同题采样一组回答、以组内均值作基线计算优势的 PPO 变体, 免去 value network。
3. Long CoT (长思维链): 模型在作答前生成数百至数千 token 的显式推理过程, 是 o1/R1 式推理模型的标志。
4. 冷启动 (Cold Start): 在 RL 之前先用蒸馏的 CoT 数据做 SFT, 为模型注入初步的推理格式与行为先验。
5. 伪推理路径 (Pseudo Reasoning Path): SFT 从专家模型模仿来的、形似推理但冗长犹豫且低信息量的输出模式, 会损害后续 RL。
6. 过度思考 (Overthinking): 推理模型生成过长思维链导致性能反降、幻觉上升的现象。
7. 统一模型 (Unified Model): 单一架构同时承担多模态理解与生成的模型。
8. 早期融合 / 原生多模态: 从预训练阶段就混合训练多模态数据, 而非在预训练 LLM 上后接视觉适配器。
9. 离散 token 化 (Tokenization): 用 VQ 类方法把图像/视频压缩为离散码本索引序列, 使其与文本同构。
10. Transfusion: 在同一 Transformer 中对文本用自回归损失、对图像用扩散损失的双目标训练范式。
11. 世界模型 (World Model): 学习环境动态、能预测"采取某动作后世界如何演化"的模型; 当代语境中常指基于视频生成或表征预测的模拟器。
12. 潜在动作 (Latent Action): 从无标注视频中推断出的、解释帧间变化的隐变量动作空间 (Genie 的核心概念)。
13. JEPA (联合嵌入预测架构): 在抽象表征空间而非像素空间预测未来的自监督架构。
14. 交错数据 (Interleaved Data): 图文/视频与文本自然混排的文档级预训练数据, 区别于孤立图文对。
15. 测试时扩展 (Test-Time Scaling): 通过增加推理时计算 (更长 CoT、多次采样投票) 提升性能, 与训练时扩展并列的第三轴。
16. 涌现 (Emergence): 随规模增长突然出现、未在训练目标中显式编码的能力。
17. MoE (混合专家): 稀疏激活的条件计算架构, 多模态中用于动态分辨率与任务路由。
18. Agentic Science (智能体化科研): 由 AI 智能体自主完成文献-假设-实验-分析闭环的科研自动化范式。
19. 有效上下文 (Effective Context): 模型实际利用的上下文长度, 通常显著小于名义窗口。
20. 对齐税 (Alignment Tax): 拼装范式中因视觉-语言模块分离训练而损失的跨模态融合深度。

10 参考文献

[1] Multimodal Chain-of-Thought Reasoning: A Comprehensive Survey, 2025, arXiv:2503.12605, <https://arxiv.org/abs/2503.12605>

[2] From Perception to Cognition: A Survey of Vision-Language Interactive Reasoning in Multi-

- modal Large Language Models, 2025, arXiv:2509.25373, <https://arxiv.org/abs/2509.25373>
- [3] Vision Language Models: A Survey of 26K Papers, 2025, arXiv:2510.09586, <https://arxiv.org/abs/2510.09586>
- [4] World Models: A Comprehensive Survey of Architectures, Methodologies, Reasoning Paradigms, and Applications, 2026, arXiv:2606.00133, <https://arxiv.org/abs/2606.00133>
- [5] From AI for Science to Agentic Science: A Survey on Autonomous Scientific Discovery, 2025, arXiv:2508.14111, <https://arxiv.org/abs/2508.14111>
- [6] Explain Before You Answer: A Survey on Compositional Visual Reasoning, 2025, arXiv:2508.17298, <https://arxiv.org/abs/2508.17298>
- [7] Flamingo: a Visual Language Model for Few-Shot Learning, DeepMind, 2022, arXiv:2204.14198, <https://arxiv.org/abs/2204.14198>
- [8] Visual Instruction Tuning (LLaVA), 2023, arXiv:2304.08485, <https://arxiv.org/abs/2304.08485>
- [9] InstructBLIP: Towards General-purpose Vision-Language Models with Instruction Tuning, 2023, arXiv:2305.06500, <https://arxiv.org/abs/2305.06500>
- [10] Qwen-VL: A Versatile Vision-Language Model for Understanding, Localization, Text Reading, and Beyond, Alibaba, 2023, arXiv:2308.12966, <https://arxiv.org/abs/2308.12966>
- [11] VILA: On Pre-training for Visual Language Models, NVIDIA, 2023, arXiv:2312.07533, <https://arxiv.org/abs/2312.07533>
- [12] mPLUG-Owl3: Towards Long Image-Sequence Understanding in Multi-Modal Large Language Models, 2024, arXiv:2408.04840, <https://arxiv.org/abs/2408.04840>
- [13] Molmo and PixMo: Open Weights and Open Data for State-of-the-Art Vision-Language Models, AI2, 2024, arXiv:2409.17146, <https://arxiv.org/abs/2409.17146>
- [14] DeepSeek-VL2: Mixture-of-Experts Vision-Language Models for Advanced Multimodal Understanding, DeepSeek, 2024, arXiv:2412.10302, <https://arxiv.org/abs/2412.10302>
- [15] Chameleon: Mixed-Modal Early-Fusion Foundation Models, Meta, 2024, arXiv:2405.09818, <https://arxiv.org/abs/2405.09818>
- [16] Transfusion: Predict the Next Token and Diffuse Images with One Multi-Modal Model, Meta, 2024, arXiv:2408.11039, <https://arxiv.org/abs/2408.11039>
- [17] Show-o: One Single Transformer to Unify Multimodal Understanding and Generation, 2024, arXiv:2408.12528, <https://arxiv.org/abs/2408.12528>
- [18] Emu3: Next-Token Prediction is All You Need, BAAI, 2024, arXiv:2409.18869, <https://arxiv.org/abs/2409.18869>
- [19] Janus: Decoupling Visual Encoding for Unified Multimodal Understanding and Generation, DeepSeek, 2024, arXiv:2410.13848, <https://arxiv.org/abs/2410.13848>
- [20] MetaMorph: Multimodal Understanding and Generation via Instruction Tuning, 2024, arXiv:2412.14164, <https://arxiv.org/abs/2412.14164>
- [21] Genie: Generative Interactive Environments, Google DeepMind, 2024, arXiv:2402.15391, <https://arxiv.org/abs/2402.15391>

- [22] Sora: A Review on Background, Technology, Limitations, and Opportunities of Large Vision Models, 2024, arXiv:2402.17177, <https://arxiv.org/abs/2402.17177>
- [23] LongVILA: Scaling Long-Context Visual Language Models for Long Videos, NVIDIA, 2024, arXiv:2408.10188, <https://arxiv.org/abs/2408.10188>
- [24] LongVA: Scaling Long-Context Visual Language Models from Language to Vision, 2024, arXiv:2406.16852, <https://arxiv.org/abs/2406.16852>
- [25] Qwen2.5-VL Technical Report, Alibaba, 2025, arXiv:2502.13923, <https://arxiv.org/abs/2502.13923>
- [26] Qwen2.5-Omni Technical Report, Alibaba, 2025, arXiv:2503.20215, <https://arxiv.org/abs/2503.20215>
- [27] InternVL3: Exploring Advanced Training and Test-Time Recipes for Open-Source Multimodal Models, 2025, arXiv:2504.10479, <https://arxiv.org/abs/2504.10479>
- [28] Qwen3-VL Technical Report, Alibaba, 2025, arXiv:2511.21631, <https://arxiv.org/abs/2511.21631>
- [29] GLM-4.5V: Versatile Vision-Language Model with Scalable Reinforcement Learning, Zhipu AI, 2025, arXiv:2507.01006, <https://arxiv.org/abs/2507.01006>
- [30] BAGEL: Emerging Properties in Unified Multimodal Pretraining, ByteDance Seed, 2025, arXiv:2505.14683, <https://arxiv.org/abs/2505.14683>
- [31] Vision-R1: Incentivizing Reasoning Capability in Multimodal Large Language Models, 2025, arXiv:2503.06749, <https://arxiv.org/abs/2503.06749>
- [32] R1-Onevision: Advancing Generalized Multimodal Reasoning through Cross-Modal Formalization, 2025, arXiv:2503.10615, <https://arxiv.org/abs/2503.10615>
- [33] Visual-RFT: Visual Reinforcement Fine-Tuning, 2025, arXiv:2503.01785, <https://arxiv.org/abs/2503.01785>
- [34] OpenVLThinker: Complex Vision-Language Reasoning via Iterative SFT-RL Cycles, 2025, arXiv:2503.17352, <https://arxiv.org/abs/2503.17352>
- [35] Cosmos World Foundation Model Platform for Physical AI, NVIDIA, 2025, arXiv:2501.03575, <https://arxiv.org/abs/2501.03575>
- [36] V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning, Meta, 2025, arXiv:2506.09985, <https://arxiv.org/abs/2506.09985>
- [37] SFT or RL? An Early Investigation into Training R1-Like Reasoning Large Vision-Language Models, 2025, arXiv:2504.11468, <https://arxiv.org/abs/2504.11468>
- [38] Skywork R1V2: Multimodal Hybrid Reinforcement Learning for Reasoning, Skywork, 2025, arXiv:2504.16656, <https://arxiv.org/abs/2504.16656>
- [39] MathVista: Evaluating Mathematical Reasoning of Foundation Models in Visual Contexts, 2023, arXiv:2310.02255, <https://arxiv.org/abs/2310.02255>
- [40] MMMU: A Massive Multi-discipline Multimodal Understanding and Reasoning Benchmark for Expert AGI, 2023, arXiv:2311.16502, <https://arxiv.org/abs/2311.16502>

- [41] OlympicArena: Benchmarking Multi-discipline Cognitive Reasoning for Superintelligent AI, 2024, arXiv:2406.12753, <https://arxiv.org/abs/2406.12753>
- [42] VTool-R1: VLMs Learn to Think with Images via Reinforcement Learning on Multimodal Tool Use, 2025, arXiv:2505.19255, <https://arxiv.org/abs/2505.19255>
- [43] Video-MME: The First-Ever Comprehensive Evaluation Benchmark of Multi-modal LLMs in Video Analysis, 2024, arXiv:2405.21075, <https://arxiv.org/abs/2405.21075>
- [44] CharXiv: Charting Gaps in Realistic Chart Understanding in Multimodal LLMs, 2024, arXiv:2406.18521, <https://arxiv.org/abs/2406.18521>
- [45] Kimi-VL Technical Report, Moonshot AI, 2025, arXiv:2504.07491, <https://arxiv.org/abs/2504.07491>
- [46] Kosmos-1: Language Is Not All You Need —Aligning Perception with Language Models, Microsoft, 2023, arXiv:2302.14045, <https://arxiv.org/abs/2302.14045>
- [47] Kosmos-2: Grounding Multimodal Large Language Models to the World, Microsoft, 2023, arXiv:2306.14824, <https://arxiv.org/abs/2306.14824>
- [48] MME: A Comprehensive Evaluation Benchmark for Multimodal Large Language Models, 2023, arXiv:2306.13394, <https://arxiv.org/abs/2306.13394>
- [49] MMBench: Is Your Multi-modal Model an All-around Player?, 2023, arXiv:2307.06281, <https://arxiv.org/abs/2307.06281>
- [50] Open Eyes, Then Reason: Fine-grained Visual Mathematical Understanding in MLLMs, 2025, arXiv:2501.06430, <https://arxiv.org/abs/2501.06430>