多模态大模型系列报告

视觉证据门控解码：待验证的实验方案

从可疑主张检测、局部证据到预算匹配的对照实验

多模态大模型系列报告

2026-10-16

本报告为系列技术综述，内容基于公开论文整理，仅供学习研究使用。

目录

1 将目标限制在可以核验的视觉主张 3

2 一个最小而明确的算法 3

3 核验器何时才可能提供额外信息 4

4 先登记对照，再运行实验 4

5 指标不能奖励空回答 5

6 三个能推翻方案的结果 5

7 当前交付与执行顺序 5

8 参考文献与证据 6

摘要 视觉语言模型可能把语言先验当成当前图像中的事实。这里提出一个可检验的解码方案：先识别需要视觉支持的原子主张，再用独立的局部证据检查决定是否保留、重采样或拒答。本方案没有训练 verifier、没有运行大模型对照，也没有建立性能或新颖性结论。价值取决于三个尚待验证的问题：核验器是否提供独立信息、纠错收益能否抵消额外计算、门控是否只通过缩短回答获得较低幻觉率。旧版页面与 PDF 曾把没有真实实验支持的提升幅度写入摘要和结果；这些数字已撤回。本修订删除相应结果和优越性宣称，保留下面可实际执行、也可能得到负结果的研究方案。原 PDF 链接指向此修订，避免旧下载入口继续提供错误结论。

1 将目标限制在可以核验的视觉主张

考虑输入图像 I、问题 x 和生成前缀 $y_{<t}$。基础模型给出 $p_\theta(y_t \mid I, x, y_{<t})$。某个续写概率很高，只说明它符合模型分布；是否得到图像支持仍是另一个问题。

首个实验只研究可定位物体、属性与二元空间关系，不同时声称解决文字识别、计数、时序因果与常识推理。对每个候选主张 c_j，保存文本 span、证据区域、核验分数、决策和最终输出。抽取失败、定位失败和无法判断应保留为独立状态，避免被并入“事实正确”。

例如“桌上有两个蓝杯子”至少含存在、数量、颜色和位置几项主张。一个检测器发现一个杯子，不能支持整句；核验器必须按主张类型定义所需证据。图像分辨率不足以读清标签时，系统应承认不可判定，不能让语言模型自行补全。

2 一个最小而明确的算法

先在句子或短 span 边界产生候选 u，抽取主张集合 $C(u)$。对局部证据 E_j，核验器输出分数 $v_\phi(c_j, E_j)$。该分数在经过校准前只是排序信号，不当作真实正确概率。

候选分数可以写成：

$$S(u) = \frac{1}{|u|^\gamma} \log p_\theta(u \mid I, x, y_{<t}) + \lambda \frac{1}{|C(u)|} \sum_{c_j \in C(u)} v_\phi(c_j, E_j),$$

其中无主张时的第二项单独定义为零。γ 是长度惩罚指数，λ 控制核验分数权重。两项尺度不同，需要在训练/开发划分上设定并冻结；不能用最终测试结果选择权重。

```
observe image and question
repeat until stop or total budget exhausted:
  propose at most K short continuations from the same prefix
  extract typed visual claims from each continuation
  gather local evidence; mark missing or ambiguous evidence
  score candidates using frozen verifier and fixed rule
  accept, resample, or abstain under a bounded retry budget
  commit accepted text; log every decision and tool call
```

这段伪代码没有被当作已实现系统。实际实现必须处理三个边界：前文已经承诺错误实体时，后文局部修正可能不够；没有被抽取的主张不会受到检查；所有候选都不可靠时，重采样并不保证正确。第一版宜允许撤回最近一个尚未展示的句子，并设置明确的最大重试次数。

门控也可以采用硬阈值，但阈值会改变覆盖率。若只有非常简单的主张通过，低幻觉率可能伴随信息量骤降。最终目标应是保留有用、正确的信息，而不是最大限度减少可被判错的文本。

3 核验器何时才可能提供额外信息

把基础模型同一前缀再问一遍“是否正确”，可能产生相关错误。独立性不是由“额外调用一次”保证的，需要通过错误相关性实验检查。

候选实现可以从冻结的检测/区域表征与关系分类器开始，或使用不同训练来源的视觉模型；两种实现都需要真实 checkpoint、版本、输入尺寸、许可与输出日志。本方案没有预先指定未经接通的服务端点，也不声称已经获得其输出。

训练核验器时，应按图像来源与近重复族划分。对存在性、属性与关系分别建立 positive/negative 配对，并保留困难负例：同类近邻物体、颜色接近、遮挡、关系方向交换。所有负例标签需要图像证据或人工核对，不能把文本替换自动视为错误。

如果用 CLIP 相似度作初始信号，只能把它当全局匹配基线。其对比目标 [1] 不直接估计一个局部主张的真假。应测同物体属性交换、关系交换和无关背景变化；若分数主要响应背景，就不适合担当该主张类型的 verifier。

4 先登记对照，再运行实验

冻结基础 checkpoint、图像预处理、问题集、prompt、解码温度、最大长度及随机种子。比较以下几组，所有组使用相同逐题输入：

组别	目的	必须记录的预算
基础解码	测量原始错误与覆盖	模型调用、输出 token、延迟
等预算多候选，不用 verifier	分离多采样本身的收益	相同候选数与生成计算
随机门控或打乱证据	检查收益是否来自选择/缩短	相同拒答率或输出长度分布
真实局部证据门控	待验证方法	verifier、裁剪与定位全部成本
人工主张/证据标注的诊断上界	定位抽取和核验瓶颈	人工参与，独立列出

时间预算与调用数预算不完全等价，因此至少给出两种比较：固定生成/核验计算的质量比较，以及固定服务延迟约束下的质量比较。裁剪、数据传输、候选缓存和失败重试都应计入端

到端开销。

开发集用于调阈值和检验流程，最终测试集只在协议冻结后运行。基础系统和门控系统要回答同一题目；同一图像的多个问题按图像 cluster 处理，不把它们当完全独立样本。

5 指标不能奖励空回答

POPE [2] 将物体存在性问题转成判别评测，适合检查一类幻觉，但不能代表开放描述中的所有主张。首轮应同时保留判别题与开放描述，并报告拒答、解析失败和超时。

开放描述采用盲审的原子主张标签，至少记录正确、错误、图像无法判断、非视觉主张四类。报告受支持主张精确率、每图受支持信息量、覆盖率、任务正确率，以及长度。先以双人标注的一部分样本检查标注一致性和争议类型，再扩大规模。

对系统差值使用逐题配对估计，并按图像重采样区间。不要只给平均分；保留细小目标、遮挡、关系、密集文字等切片及其样本数。任何“显著”宣称都要对应预先定义的比较与误差处理。

效率报告给出相同机器或相同服务条件下的 p50/p95 延迟、首 token 延迟、总调用数、GPU 时间或可核验账单。尚未运行时这些单元格保持未测量，不填写预测提升。

6 三个能推翻方案的结果

若打乱证据仍得到相同收益，应优先解释为重采样或输出控制，而非视觉核验。若控制回答长度与拒答率后收益消失，方法可能只是减少了可被判错的主张。若人工主张与证据条件下仍没有收益，就应重新考虑核验信号是否足以纠正生成，而非继续堆叠抽取模块。

还需检查分布变化：开发集上校准的阈值在新图像来源上可能失效；检测器漏掉小物体会把真实主张错误拒绝；门控选择后的样本分布与核验器校准集不同。风险—覆盖曲线及错误明细比单个阈值分数更能解释这些问题。

这里没有“预期提升两点”或“固定增加某个倍数延迟”的结果。只有真实实现、逐项日志、冻结的评测与独立复查完成后，才能把研究方案改写成实验报告。

7 当前交付与执行顺序

当前交付是算法定义、数据划分、对照与判定标准。下一步先实现一个物体存在性子问题，连通真实模型与视觉核验器，保存 checkpoint 标识和一次端到端 trace；随后完成标签质量检查，再运行小规模配对测试。只有这些检查说明信号确有信息量，才扩大到属性和关系。

没有模型结果不妨碍判断设计是否清楚，但不能据此主张方法有效或具有首创性。发表前还需专门检索解码对照、视觉反事实、局部 grounding、selective prediction 与 verifier 方法的相关工作，逐项比较；本站当前没有完成这项穷尽性新颖性审查。

8 参考文献与证据

[1] Radford et al. Learning Transferable Visual Models From Natural Language Supervision. 2021. 对比训练目标，而非局部事实验证器。原文

[2] Li et al. Evaluating Object Hallucination in Large Vision-Language Models. 2023. POPE 与开放描述指标的边界。原文

[3] Rafailov et al. Direct Preference Optimization: Your Language Model is Secretly a Reward Model. 2023. 偏好目标与视觉证据的区别见本系列第 09 章。原文